

머신 러닝 기반 기업 부도 위험 예측 모델 검증 및 정책적 제언

- 스테킹 앙상블 모델을 통한 개선을 중심으로 -



재무분석



머신러닝



앙상블 모델

발표자: 전찬휘

2025. 07. 17.

논문 선정 이유



흥미로운 내용
(스태킹 앙상블)



기존 모델들에 대해
살펴볼 수 있는 기회



부도예측을 다루고
있어 유관성이 있을
것으로 생각

목차

1 💡 서론

- 연구 배경 및 필요성
- 연구 목적 및 차별점

2 ⚙️ 분석 방법론

- 부도위험 기준: Merton 모형
- 개별 예측 모델: RF, MLP, CNN
- 모델 통합: 스택킹 앙상블

3 📈 실증 분석

- 데이터 설명 및 기초 통계
- 분석 모형 설계
- 예측 결과 및 성능 비교
- 통계적 유의성 검증

4 🚩 결론

- 연구 요약



연구 배경 및 필요성

문제 제기: 왜 새로운 부도 예측 모델이 필요한가?



기업 부도 위험 판단의 중요성

- ✓ 건전한 시장 경제의 근간: 투명성분의 효율성 증대
- ✓ 강건한 기업은 성장 동력 확보, 부실기업은 경영 개선 유도



기존 신용평가 체계의 한계

- ✗ 후행성: 신용 사건 발생 후 등급이 조정되는 경향
- ✗ 긴 갱신 주기: 시장의 급격한 변화를 적시에 반영하기 어려움
- ✗ 적용의 제약: 비상장, 초기 단계 기업에 대한 평가 정보 부족



머신러닝 기반 연구의 한계

- ≡ 데이터 불균형: 부도 사건 자체가 매우 희소하여 학습에 어려움 (정보 왜곡 가능성)
- ✗ 단일 모델의 편향: 특정 모델에 의존할 경우, 해당 모델이 갖는 고유의 편향이 결과에 반영될 위험



시장 변화를 적시에 반영하고, 다양한 기업에 적용 가능하며, 모델 자체의 편향을 최소화한 강건한(Robust) 예측 모델의 필요성이 대두

연구 목적 및 차별점

🎯 연구 목적

기존 부도 예측 연구의 한계를 극복하고, **안정적이고 신뢰성 높은 머신러닝 기반 부도위험 예측 모델을 검증**하고 정책적 활용 가능성을 제시하고자 함

★ 연구의 차별점



Merton 모형 기반 부도위험 산출

- ✓ 부도 '여부'가 아닌, 연속적인 부도 '확률'을 사용
- ✓ 데이터 불균형 문제를 근본적으로 해결
- ✓ 정상기업 내에서도 존재하는 위험 수준의 차이를 반영



스태킹 앙상블 모델 적용

- ✓ 랜덤 포레스트, MLP, CNN 등 서로 다른 강점을 가진 모델 결합
- ✓ 단일 모델의 편향(bias) 경감
- ✓ 예측의 안정성과 정확도 향상



비상장 기업 적용 가능성

- ✓ 학습 시에는 시장 정보(Merton 모형) 활용
- ✓ 예측에 사용되는 입력 변수는 재무제표 정보만으로 구성
- ✓ 주가 정보가 없는 비상장 기업에도 시장의 판단을 모사한 부도위험 평가 가능

부도위험 기준: Merton 모형

종속변수: 시장은 기업의 부도위험을 어떻게 평가하는가?

Merton(1974) 모형은 기업의 주식 가치를 '부채'를 행사가격으로 하는 콜옵션으로 간주하여, 자산가치가 부채가치보다 낮아질 확률, 즉 **내재부도확률 (Implied Probability of Default)**을 계산합니다.



핵심 가정

기업의 자산가치(V)는 기하 브라운 운동(Geometric Brownian Motion)을 따릅니다.

$$\frac{dV}{V} = \mu dt + \sigma_A dW_t \quad (1)$$

주식가치(E)와 부도확률(π) 산출 공식

• 주식가치(E)는 블랙-숄즈 옵션 가격 결정 모형을 통해 산출됩니다.

$$E = VN(d_1) - e^{-rT}F(d_1) \quad (2)$$

• 자산가치(V)와 자산가치 변동성(σ_V)은 연립방정식(3)을 통해 반복적으로 추정합니다.

$$d_1 = \frac{\ln(V/F) + (r + 0.5 \times \sigma_V^2)}{\sigma_V \sqrt{T}} \quad d_2 = d_1 - \sigma_V \sqrt{T}$$
$$\sigma_E = \frac{V}{E} N(d_1) \sigma_V$$

• 최종적으로 산출된 값을 통해 내재부도확률(π)을 계산합니다.

$$\pi = N\left(-\left(\frac{\ln(V/F) + (r - 0.5 \times \sigma_V^2)}{\sigma_V \sqrt{T}}\right)\right) \quad (4)$$

본 연구에서는 이 부도확률(π)을 예측 대상인 **종속변수(Target Variable)**로 사용합니다.

$$\frac{dV}{V} = \mu dt + \sigma_A dW_t \quad (1)$$

$$E = VN(d_1) - e^{-rT}F(d_1) \quad (2)$$

$$d_1 = \frac{\ln(V/F) + (r + 0.5 \times \sigma_V^2)}{\sigma_V \sqrt{T}}$$
$$d_2 = d_1 - \sigma_V \sqrt{T} \quad (3)$$

$$\sigma_E = \frac{V}{E} N(d_1) \sigma_V$$


V: 자산가치(주식가치 + 부채가치)
F: 부채가치 = (유동부채 + 고정부채*0.5)
r: 무위험이자율 (국고채 3년 수익률)
 σ_V : 자산가치 변동성
 σ_E : 주식가치변동성

개별 예측 모델 (Base Learners)

다양한 관점에서 부도위험을 학습하는 서브 모델들



랜덤 포레스트 (Random Forest)



- ⚙️ 핵심 로직: 다수의 결정 트리를 생성하고, 그 결과를 종합(투표)하여 최종 예측
- ⊕ 장점: 과적합 방지에 효과적, 변수 중요도 해석 용이
- 👤 역할: Base Learner 1



다층 퍼셉트론 (MLP)



- ⚙️ 핵심 로직: 입력층-은닉층-출력층 구조의 인공신경망으로, 가중치를 통해 비선형 관계 학습
- ⊕ 장점: 복잡한 비선형 관계 학습에 강점
- 👤 역할: Base Learner 2



합성곱 신경망 (CNN)




- ⚙️ 핵심 로직: 필터를 사용하여 데이터의 지역적 특징(패턴)을 추출하고 이를 종합하여 예측
- ⊕ 장점: 데이터의 내재적 구조 및 패턴 포착에 유리
- 👤 역할: Base Learner 3

개별 예측 모델 (Base Learners)

다양한 관점에서 부도위험을 학습하는 서브 모델들




랜덤 포레스트
(Random Forest)



(Figure 1) Random Forest Method




다층 퍼셉트론
(MLP)



(Figure 2) Multi-layer Perceptron (MLP) Method



합성곱 신경망
(CNN)



(Figure 3) Convolutional Neural Networks (CNN) Method


(Figure 1) Random Forest Method

개별 예측 모델 (Base Learners)

다양한 관점에서 부도위험을 학습하는 서브 모델들



랜덤 포레스트
(Random Forest)



숲 속 여러 나무(결정 트리)가 각자 “이 열매는 맛있다/맛없다”를 판단한 뒤, 숲 전체의 다수결(투표)로 최종 결론을 내리는 과일감별사 나무들!



다층 퍼셉트론
(MLP)



대학교 강의실 구조로 비유: 1학년(입력층)부터 시작해 과목이 갈수록 심화되는 여러 학년(은닉층)을 거치며 정보(지식)가 가중치와 활성화 함수(시험·과제)를 통해 정제되고, 졸업반(출력층)에 가서야 최종 학위를 받는 과정과 비슷.



합성곱 신경망
(CNN)




대학사진을 퍼즐 조각으로 잘게 나눠놓고(필터) 각 조각에서 특징을 찾은 뒤(합성곱), 중요하지 않은 부분은 치우고(풀링), 남은 퍼즐 조각을 차곡차곡 쌓아 전체 그림을 알아맞히는 구조.

모델 통합: 스택킹 앙상블

"집단 지성"의 원리: 개별 모델의 예측을 다시 학습하여 성능 극대화

스태킹 앙상블(Stacking Ensemble)은 서로 다른 유형의 여러 개별 모델(Base Learner)들의 예측 결과를 다시 새로운 학습 데이터로 사용하여, 최종 예측을 수행하는 메타 모델(Meta Learner)을 학습시키는 기법입니다.



작동 방식

- 1단계 (Base Model Training): 원본 학습 데이터를 여러 Fold로 나누어 랜덤 포레스트, MLP, CNN 모델을 각각 학습시키고, 각 Fold의 검증 데이터에 대한 예측값을 생성합니다.
- 2단계 (Meta Model Training): 1단계에서 생성된 각 Base 모델들의 예측값들을 새로운 **입력(Feature) 데이터**로 사용하고, 원본 데이터의 실제값(부도확률)을 **타겟(Target) 데이터**로 하여 최종 Meta 모델(여기에서는 MLP 사용)을 학습시킵니다.

기대 효과

- 각 모델의 장점은 취하고 약점은 보완하여, 단일 모델보다 **더 안정적이고 일반화 성능이 높은 예측**을 수행할 수 있습니다.
- 다양한 학습 알고리즘의 **편향(bias)**을 경감시키고 예측의 정확도를 높입니다.
- 모델 간 **상호보완적 학습**을 통해 복잡한 패턴을 더 효과적으로 포착합니다.

데이터 설명

분석에 사용된 데이터



분석 대상

2,194개 코스피/코스닥 상장 기업



분석 기간

K-IFRS가 정착된 2012년 ~ 2018년 (7개년)



데이터 출처

에프앤가이드(FnGuide)



데이터 구성

총 10,545개 관측치 (기업-연도), 160개 변수

변수 구성

구분	세부 항목	변수 개수
종속 변수	Merton 모형 기반 부도위험	1
	재무상태표 (자산, 부채, 자본 등)	38
	포괄손익계산서 (매출, 이익 등)	26
독립 변수	현금흐름표 (영업, 투자, 재무 활동)	11
	재무비율 (안정성, 성장성, 수익성 등)	76
	기타 (연도 더미 변수, 종업원 수 등)	8
총 변수 개수		160



시장 정보를 담은 종속변수와 기업의 내재적 가치를 담은 독립변수(재무정보) 간의 관계를 학습합니다.

기술 통계 및 상관관계


주요 변수들의 특징과 관계

아래 표는 분석에 사용된 주요 변수들의 기술 통계량을 보여줍니다. 부도확률(V1)은 0과 1 사이의 값을 가지며, 평균은 약 0.348입니다.

주요 변수 기술 통계량 (단위: 십억원, 명)

변수	내용	평균	표준편차	최소값	최대값
V1	부도확률	0.348	0.368	0.0	1.0
V2	시가총액	761.0	6,550.0	3.3	329,000.0
V5	유동부채	458.0	2,440.0	0.1	69,100.0
V11	매출액	1,280.0	7,720.0	0.0	244,000.0
V15	영업이익	84.9	1,090.0	-3,270.0	58,900.0
V25	영업활동현금흐름	115.0	1,400.0	-3,460.0	67,000.0


주요 변수 상관관계 분석



분석 결과:

- 재무지표들 간에는 높은 상관관계가 나타나지만, 부도확률(V1)은 대부분의 재무 변수들과 뚜렷한 선형 관계를 보이지 않습니다.
- 이는 부도확률이 재무지표뿐만 아니라 주가, 변동성 등 시장의 복합적인 판단을 통해 도출 되었기 때문으로 해석할 수 있으며, 비선형 관계를 포착할 수 있는 머신러닝 모델의 필요성을 시사합니다.

분석 모형 설계



데이터 준비 및 타겟 변수 생성

상장기업의 재무 데이터와 시장 데이터를 수집하고, Merton 모형을 이용해 기업별/연도별 부도위험(확률) 산출

Meta 모델 학습

생성된 서브 모델들의 예측값을 입력으로 하여 스택킹

데이터 분할

전체 데이터를 학습 데이터(70%)와 테스트 데이터(30%)로 무작위 분할

모델 성능 검증

테스트 데이터를 이용해 최종 스택킹 모델과 개별 모델

Base 모델 학습

학습 데이터 내에서 7-fold 교차검증을 통해 RF, MLP, CNN 서브 모델을 학습하고, 각 모델의 예측값 생성

연구의 전체적인 흐름

데이터 수집부터 모델 성능 검증까지 체계적인 과정을

하이퍼파라미터 설정


모델의 성능과 재현성을 위해 설정된 주요 하이퍼파라미터는 다음과 같습니다.

구분	모델	하이퍼파라미터	설정값
서브 모델	Random Forest	생성할 트리 개수 (n_estimators)	1000
		손실 함수 (criterion)	MSE
	MLP	은닉층 수 / 노드 수	2개 / 각 100개
		최적화 함수 (optimizer)	Adam
		에포크 (epochs)	300
	CNN (1D)	필터 크기 (filter size)	2
		풀링 크기 (pool size)	2
		최적화 함수 (optimizer)	Adam
메타 모델	Stacking (MLP)	은닉층 수 / 노드 수	2개 / 각 100개
		최적화 함수 (optimizer)	Adam


예측 결과 (시각화)

테스트 데이터에 대한 각 모델의 예측값(가로축)과 실제 부도위험 값(세로축)을 비교한 산점도입니다. **붉은색 대각선에 데이터가 밀집할수록 예측이 정확함**을 의미합니다.


🌲 랜덤 포레스트 (Random Forest)




🏠 MLP (Multi-Layer Perceptron)



🏠 CNN (Convolutional Neural Network)



🏠 스택킹 앙상블 (Stacking Ensemble)




예측 결과 (성능 평가)

모델의 예측 오차를 정량적으로 평가하기 위해 MAE, MSE, RMSE 지표를 사용했습니다. 모든 지표에서 값이 낮을수록 성능이 우수함을 의미합니다.

모형별 예측 오차 결과

평가지표	Random Forest (Model 1)	MLP (Model 2)	CNN (Model 3)	Stacking Ensemble (Model 4)
MAE (Mean Absolute Error)	0.09475	0.11171	0.13489	0.09079
MSE (Mean Squared Error)	0.02226	0.03605	0.03749	0.02217
RMSE (Root Mean Squared Error)	0.14921	0.18988	0.19363	0.14891

오차 지표 시각화



분석 결과

- 모든 오차 지표에서 스택킹 앙상블 모델이 가장 낮은 오차를 기록하며, 예측 성능이 가장 우수함을 확인했습니다.
- 단일 모델 중에서는 랜덤 포레스트의 성능이 가장 뛰어났습니다.
- 스택킹 앙상블 모델은 가장 성능이 좋았던 단일 모델인 랜덤 포레스트보다도 더 향상된 예측력을 보여주었습니다.
 - MAE 기준: RF 대비 1.04배 우수
 - RMSE 기준: RF 대비 1.002배 우수

통계적 유의성 검증 (1) 정규성 검정


❓ 질문: 스택킹 모델과 개별 모델의 예측값 차이는 통계적으로 유의미한가?

이를 확인하기 위해 먼저 두 모델 예측값 차이의 분포가 **정규성을 따르는지** 검정했습니다.

큐큐플롯(Q-Q Plot)을 통한 시각적 검정

데이터가 붉은색 직선을 벗어나 있어 정규분포를 따르지 않음을 시사합니다.

그림 12: 정규 Q-Q Plot을 이용한 정규성 검정 결과



〈Figure 12〉 Results of normality test using normal Q-Q plot

샤피로-윌크 검정(Shapiro-Wilk test)을 통한 통계적 검정

모든 Pair에서 p-value가 0.05보다 작아, **정규성 가정이 기각**되었습니다.

표 6: Shapiro-Wilk 정규성 검정 결과

〈Table 6〉 Results of normality test (Shapiro-wilk normality test)

Division	Pair composition		Shapiro-wilk normality test		
	Set 1	Set 2	W	p-value	Results
Pair 1	Stacking Ensemble	Random Forest	0.98303	< 2.2e-16	Non-normal
Pair 2	Stacking Ensemble	MLP	0.89026	< 2.2e-16	Non-normal
Pair 3	Stacking Ensemble	CNN	0.95428	< 2.2e-16	Non-normal

→ 결론: 정규성 가정이 만족되지 않으므로, 비모수 검정 방법(데이터가 정규분포 등 특정 분포를 따르지 않아도 쓸 수 있는 검정법)인 **윌콕슨 순위합 검정(Wilcoxon rank sum test)**를 통해 두 그룹 간의 차이를 검증해야 함.

통계적 유의성 검증 (2) Wilcoxon 검정

? 스택킹 모델은 개별 모델과 '실질적으로' 다른 예측을 하는가?


윌콕슨 순위합 검정을 통해 스택킹 앙상블 모델과 각 개별 모델 예측값 분포 간에 통계적으로 유의미한 차이가 있는지 확인했습니다.

📊 <표 7> Wilcoxon Rank Sum Test 결과

구분	Pair 구성	W 통계량	p-value	결과 (유의수준 5%)
Pair 1	Stacking Ensemble vs Random Forest	4,920,409	0.2596	차이 없음 (Non-difference)
Pair 2	Stacking Ensemble vs MLP	4,687,668	1.479e-05	차이 있음 (Difference)
Pair 3	Stacking Ensemble vs CNN	4,753,811	0.0006236	차이 있음 (Difference)

💡 결과 해석:

- 스택킹 앙상블 모델은 MLP, CNN 모델과는 통계적으로 **유의미하게 다른 예측 결과**를 보여주었습니다. 이는 스택킹 기법이 MLP와 CNN의 예측을 효과적으로 보완하여 새로운 예측을 생성했음을 의미합니다.
- 반면, 랜덤 포레스트 모델과는 통계적으로 유의미한 차이를 보이지 않았습니다. 이는 스택킹 모델의 예측 성능 향상이 주로 가장 강력한 Base Learner였던 랜덤 포레스트의 예측 패턴을 기반으로 이루어졌음을 시사합니다.



4. 결론 - 연구 요약

본 연구는 다음의 결론을 도출했습니다.



Merton 모형과 머신러닝의 결합은 유효했다.

시장의 평가를 반영한 Merton 모형 기반 부도 확률을 종속변수로 사용함으로써,

- 기존 연구의 데이터 희소성 및 불균형 문제를 효과적으로 해결
- 기업별 위험 수준을 세밀하게 측정 가능



스태킹 앙상블은 예측 성능을 개선했다.

다양한 개별 모델(RF, MLP, CNN)을 결합한 스태킹 앙상블 모델은,

- 모든 오차 지표(MAE, MSE, RMSE)에서 가장 우수한 예측 성능 달성
- 개별 모델의 편향을 제어하고 안정적인 예측을 산출하는 스태킹 기법의 효과성 검증



모델 간 통계적 차이를 확인했다.

스태킹 앙상블 모델은,

- MLP, CNN 모델과는 통계적으로 유의하게 다른 예측을 수행
- 이는 모델 결합을 통한 성능 개선이 실제로 이루어졌음을 뒷받침

“ 결론적으로, Merton 모형으로 시장의 판단을 포착하고 스태킹 앙상블 기법으로 모델의 안정성을 높인 본 연구의 접근 방식은, 기존 머신러닝 기반 부도 예측 모델의 한계를 극복하고 실무적 활용도를 높일 수 있는 효과적인 대안임을 확인했습니다.”



학문적 기여

- ✓ **과적합 문제 경감**
단일 모델이 아닌, 메타-서브(Meta-Sub) 구조의 스택킹 앙상블을 도입하여 개별 모델이 과거 데이터에 과적합되는 문제를 완화하고 일반화 성능을 높였습니다.
- ✓ **Merton 모형의 한계 보완**
주가의 비정상적 변화에 민감할 수 있는 Merton 모형을 대량의 회계 정보와 결합하여 학습함으로써, 개별 기업의 이상치에 덜 민감하고 안정적인 위험 예측을 가능하게 했습니다.
- ✓ **부도위험 연구의 확장**
부도 '여부'의 이진 분류 문제를 넘어, 부도 '확률'이라는 연속적인 값으로 위험을 세분화하여 예측의 정교함을 더했습니다.



실무적 및 정책적 기여

- ✓ **비상장 기업 평가 모델**
주가 정보가 없는 비상장 기업도 보유한 회계 정보를 통해 시장의 평가를 모사한 부도위험을 산출할 수 있는 길을 열었습니다. (e.g., 중소기업, 스타트업 대상 신용평가 서비스)
- ✓ **모델의 유연성 및 확장성**
스택킹 앙상블의 서브 모델로 전통적인 통계 기반 신용평가 모델(e.g., 로짓, 판별분석)도 포함할 수 있어, 기존 신용평가기관의 노하우와 머신러닝 기술을 결합할 수 있는 유연성을 제공합니다.
- ✓ **규제 준수 가능성**
금융당국이 요구하는 '평가방법의 적정성 검증' 기준에 대해, 다양한 서브모델의 조합과 검증을 통해 대응할 수 있는 방법론적 근거를 제시합니다.

⚠ 한계점 (Limitations)



등급 체계와의 연계 부족

본 연구에서 산출한 0~1 사이의 확률값을 실제 신용평가 시장에서 사용되는 AAA~D 등급 체계로 변환(Mapping)하지 못했고, 기존 신용등급과의 비교를 수행하지 못했습니다.



서브 모델의 제한성

분석의 편의를 위해 대표적인 3개의 머신러닝 모델만을 서브 모델로 사용했습니다. 더 많고 다양한 유형의 서브 모델을 활용할 경우, 스택킹 앙상블의 성능이 더욱 향상될 수 있습니다.

💡 향후 연구 제언 (Future Research)



예측 결과의 등급화 및 비교 연구

본 모델의 예측 확률을 시장 등급으로 변환하는 최적의 기준점을 찾고, 실제 신용평가기관의 등급과 비교하여 실무적 적합성을 검증하는 후속 연구가 필요합니다.



다양한 서브 모델 활용

XGBoost, LightGBM, SVM 등 더 다양한 머신러닝 모델과 전통적 통계 모델을 서브 모델로 추가하여 스택킹 앙상블 모델의 강건성(Robustness)을 강화하는 연구가 필요합니다.



비재무 정보의 활용

뉴스 기사, 소셜 데이터 등 비정형 텍스트 데이터를 분석에 포함하여, 재무제표에 드러나지 않는 위험 요인을 포착하고 예측력을 높이는 연구를 제안합니다.

용어 설명

부도위험 기준: Merton 모형

- ☞ Merton 모형: 기업의 파산 위험을 평가하기 위해 개발된 신용 리스크 모델.
Robert C. Merton이 1974년 제안한 이 모델은 기업의 총자산 가치를 기하 브라운 운동과 같은 확률 과정으로 모델링함. 이를 바탕으로 부도(자산가치가 부채를 밑도는 사건) 발생 확률을 계산하고 채권과 주식의 이론적 가치까지 평가.
- ☞ 기하 브라운 운동 (Geometric Brownian Motion): 자산 가격이 일정 비율의 드리프트(μ)와 변동성(σ)를 갖는 확률적 로그정규 분포를 따르도록 하는 연속 확률 과정. 미래 가격의 분포를 닫힌 형태로 얻을 수 있어 옵션 가격·위험 측정 등에 널리 쓰임.
- ☞ 블랙-숄즈 모형 (Black-Scholes Model): 기하 브라운 운동을 가정한 기초자산 S 의 확률적 움직임과 무위험이자율 r , 변동성 σ 를 입력으로 사용해 유럽형 옵션의 이론적 공정가격을 구함.

하이퍼파라미터 설정

- **하이퍼파라미터 (Hyperparameter)**

모델 학습 전에 사용자가 미리 정하는 설정값(예: 학습률, 은닉층 크기, 배치 크기)으로, 성능과 학습 속도를 크게 좌우함.

- **MSE (Mean Squared Error, 평균제곱오차)**

예측값과 실제값 차이의 제곱을 평균한 손실 함수. 오차가 클수록 값이 급격히 커져 회귀 문제에서 널리 사용됨.

- **Adam 최적화 함수**

모멘텀과 RMSProp 아이디어를 결합해 1) 이동평균으로 기울기 방향을, 2) 제곱 기울기로 학습률을 자동 조정해 빠르고 안정적으로 수렴하는 경사하강법 변형 알고리즘. 즉, 기울기의 '움직이는 평균(모멘텀)'을 기억해 최근 방향을 따라 관성처럼 학습하고, 기울기 제곱의 '움직이는 평균(RMSProp)'을 이용해 변화가 심한 파라미터에는 학습률을 낮추고, 안정적인 파라미터에는 학습률을 높여요. 이 두 가지를 결합해, 초반에는 빠르게 달리다가도(모멘텀) 뒤로 갈수록 지나치게 흔들리지 않고(분산 기반 학습률 조정) 안정적으로 최적점에 수렴하도록 돕는 알고리즘.

- **에포크 (Epoch)**

전체 학습 데이터를 한 번씩 모두 신경망에 투입해 학습을 완료하는 주기. 1에포크=1주기
보통 여러 에포크를 반복해 모델 성능을 향상시킨다

통계적 유의성 검증

- **MAE (Mean Absolute Error, 평균절대오차)**

실제값과 예측값 차이의 절댓값을 평균한 것. 오차를 모두 양수로 취급해서 직관적이며, 이상치(outlier)에 덜 민감

- **MSE (Mean Squared Error, 평균제곱오차)**

예측값과 실제값 차이의 제곱을 평균한 손실 함수. 오차가 클수록 값이 급격히 커져 회귀 문제에서 널리 사용됨. 즉 큰 오차를 제공해서 더 크게 벌점을 주므로 이상치에 민감하고 수학적으로 다루기 쉬움(미분 등).

- **RMSE (Root Mean Squared Error, 평균제곱근오차)**

MSE의 제곱근으로, 오차의 단위를 원래 값 단위로 다시 줄여서 맞춰 직관적 해석이 가능함. 그러면서도 MSE의 민감도를 유지

- **서로 다른 지표를 쓰는 이유**

민감도 조절: MAE는 극단치에 덜 민감, MSE/RMSE는 큰 오차를 더 강조

해석 편의: MAE는 실제 평균 오차 크기를 바로 알기 쉽고, RMSE는 단위가 동일해 해석이 편리

최적화 특성: MSE는 제곱 미분이 연속적이어서 경사하강법 등 최적화 알고리즘에 유리

문제 특성 반영: 이상치가 많거나 적은 데이터, 모델 튜닝 목적 등에 따라

적절한 지표를 골라서 쓰면 평가와 비교에 더 좋음

통계적 유의성 검증

• 큐큐플롯(Q-Q Plot, Quantile-Quantile Plot)

데이터의 분포가 특정 이론 분포(예: 정규분포)와 얼마만큼 비슷한지 시각적으로 점들을 찍어서 비교하는 그래프. 분포 형태를 직관적으로 파악할 때 유용하며, 이론 분포와 어긋나는 구간(꼬리, 중앙 등)을 눈으로 확인할 수 있음.

• 샤피로-윌크 검정(Shapiro-Wilk Test)

주어진 표본이 정규분포에서 뽑힌 것인지 통계적으로 검정하는 방법. W 통계량을 계산해 p -값이 작으면(예: $p < 0.05$) “정규성이 아니다”라고 결론. 데이터가 정규분포 가정을 만족하는지 수치적으로 판단해야 할 때 쓰며, Q-Q Plot보다 정량적(정확한 p -값)인 근거를 제공.

• p -값 (p -value)

통계 가설 검정에서 “귀무가설(H_0)이 참일 때, 관측된 데이터(또는 더 극단적인 결과)가 나올 확률”을 뜻함. p -값이 작을수록(일반적으로 < 0.05) “귀무가설을 기각”하고 대립가설을 채택할 근거가 강해짐. (즉, p -값이 작을 경우, 두 변수 사이에는 관련이 있다고 본다).

• 윌콕슨 순위합 검정(Wilcoxon Rank Sum Test[Mann-Whitney U Test])

두 독립된 집단 사이에 중앙값 차이가 있는지 검정하는 비모수 방법. 데이터가 정규분포를 따르지 않아도 순위(rank)만으로 그룹 간 차이를 평가. 정규분포 가정이 깨졌을 때(Shapiro-Wilk에서 정규성 기각)에도 두 집단을 비교할 수 있는 강건한(alternative) 대안임. 방법은 두 그룹의 데이터를 모두 모아 크기 순으로 줄 세움. 각각의 값에 순위를 매기고(같으면 평균 순위) 각 그룹의 순위 합을 구함. 순위 합이 “생각보다 많이 다르면” 두 그룹의 분포나 중앙값이 다르다고 판단.

• 왜 서로 다른 방법을 쓰나?

시각 vs. 정량: Q-Q Plot은 분포 모양을 눈으로 보기에 좋고, Shapiro-Wilk은 객관적 p -값을 제공.

모수 vs. 비모수: Shapiro-Wilk은 “정규분포”라는 가정 기반(모수 검정), Wilcoxon은 분포 형태에 구애받지 않는 비모수 검정.

목적 차이: 분포의 형태를 확인(Q-Q Plot), 정규성 여부 판단(Shapiro-Wilk), 두 그룹 차이 검정(Wilcoxon),

한계 및 향후 연구

• 메타-서브(meta-sub

여러 개의 1차 모델(base learner)을 학습시킨 뒤, 이들의 예측값을 다시 입력으로 받아 최종 예측을 수행하는 ‘메타 학습(meta-learning)’ 혹은 ‘스태킹(stackings)’ 방식의 앙상블 기법을 의미. 1차 모델들이 갖는 편향(bias)과 분산(variance)을 상호 보완하며, 모델 간 다양성(diversity)이 클수록 효과가 좋음. Kaggle 등 대회에서 자주 쓰이는 고성능 앙상블 전략

• 그레디언트 부스팅 트리(Gradient Boosting Tree, GBT)

여러 개의 결정 트리(Decision Tree)를 순차적으로 학습시키고 이들의 예측을 더해 최종 모델을 만드는 앙상블 기법. 핵심 아이디어는 ‘오류(잔차, residual)를 보완하면서 모델을 점진적으로 개선’하는 것.

• XGBoost (Extreme Gradient Boosting)

그레디언트 부스팅 트리(Gradient Boosted Trees)를 고속·고성능·과적합 제어 기능까지 갖춘 형태로 구현한 라이브러리. 트리 추가 시 2차 미분 정보(hessian)까지 활용해 수렴 속도 및 예측 성능 향상. 정규화(regularization)를 통한 과적합 방지(L1/L2 페널티). 병렬 학습, 희소 데이터 처리, 트리 프루닝(pruning) 등 풍부한 최적화 기법 탑재. 분류·회귀·순위 예측 등 범용 적용. 대규모 데이터셋에서도 빠른 학습 속도.

• LightGBM (Light Gradient Boosting Machine)

Microsoft에서 개발한 그레디언트 부스팅 프레임워크로, 특히 대용량 데이터와 높은 차원(피쳐 수)에 최적화되어 있음. Leaf-wise 트리 분할 전략(“현재 트리에서 손실(loss)이 가장 많이 감소할 수 있는 리프(leaf) 노드”를 계속해서 분할)으로 동일 깊이(depth-wise)보다 손실 감소 효과 큼. Histogram 기반 이산화(binning) 기법으로 메모리·학습 속도 절감. GPU 지원, 다중 분산 학습 등 확장성 우수. XGBoost 대비 빠른 학습·추론 속도가 필요한 환경이나 메모리 제약이 있는 대규모 피쳐셋에 사용.

• SVM (Support Vector Machine)

데이터를 최적의 초평면(hyperplane)으로 분리하여 분류(Classification) 혹은 회귀(Regression) 문제를 푸는 지도학습 알고리즘. 마진(margin)을 최대화하는 결정 경계를 설계하며 일반화 성능 우수. 커널 트릭(kernel trick)으로 비선형 문제도 효율적 처리 (RBF, 다항 커널 등). 그러나 데이터 수나 피쳐 수가 매우 커지면 학습·추론 속도가 느려질 수 있음. 하이퍼파라미터(C, γ 등) 튜닝 필요. 각 기법은 데이터의 특성과 문제의 복잡도에 따라 적합한 기법을 선택하여 사용하는 것이 중요하다.

감사합니다



머신러닝 기반 기업 부도 위험 예측 모델 검증

스태킹 앙상블 모델을 통한 개선을 중심으로