

설명 가능한 인공지능 (XAI) 기반

기업부도 예측 연구

어떤 요소가 기업 부도를 예측하는가?

논문 출처 디지털콘텐츠학회논문지 Vol.24, No.9 (2023)

연구 대상 KOSPI·KOSDAQ 상장기업 2,540개

연구 방법 DNN · CNN · LSTM + Integrated Gradients

목 차

01

연구 배경 및 목적

왜 xAI가 필요한가?

02

기업부도 예측 선행연구

전통적 기법 → 머신러닝 → 딥러닝

03

데이터 구성

32개 특성 (재무 / 기업특성 / 거시경제)

04

딥러닝 모델

DNN · CNN · LSTM

05

설명 가능한 AI: Integrated Gradients

Feature Attribution 원리

06

실험 결과 (예측 성능)

F1 Score & Accuracy 비교

07

Feature Attribution 분석

어떤 변수가 중요한가?

08

핵심 발견 & 결론

연구 요약 및 한계

01 연구 배경 및 목적

! 문제점

ML/DL 모델은 예측 성능은 뛰어나지만,
왜 그런 예측을 했는지 설명하기 어렵다.

- 복잡한 파라미터 간 상관관계 학습
- 딥러닝 = '블랙박스(Black-Box)'
- 금융 의사결정에서 신뢰성·투명성 필수

기업부도는 정상기업 대비 희소 → 데이터 불균형
문제도 존재

✓ 연구 목적

Explainable AI(XAI)를 활용해
기업부도 예측 모델의 신뢰도와 투명성 향상

- Integrated Gradients로 Feature Attribution 분석
- 어떤 변수가 부도에 영향? → 시각화
- DNN · CNN · LSTM 3가지 모델 비교 검증

의사결정자·신용평가기관이 활용 가능한
설명력 있는 부도 예측 모델 제시

02 기업부도 예측 선행연구

1966~1980

통계적 방법

- Beaver(1966): 단일변량분석, 정확도 78%
- Altman(1968): 다변량 판별분석, 정확도 95%
- Ohlson(1980): 로짓분석, 정확도 96%

1990s~2000s

시장정보 활용

- KMV 모형(McQuown): 옵션가격 평가
- EDF(Expected Default Frequency) 측정
- 거시경제 변수 통합 모형 연구

2010s~

머신러닝·딥러닝

- Random Forest, SVM 등 ML 기법
- Deep Belief Networks(DBN) 도입
- RNN·LSTM 시계열 모델 등장

★ 최근: AI 활용 모델이 전통 기법 대비 우수한 예측 성능을 보이지만, '설명 가능성(Explainability)' 부족 문제가 대두됨

03 데이터 구성 (총 32개 특성)

📊 분석 대상: KOSPI + KOSDAQ 총 2,540개 기업 (2001~2021) | KOSPI: 정상 711 / 부도 118 KOSDAQ: 정상 1,300 / 부도 411

🏠 건전성

- 부채비율 (TL/TA)
- 시장부채비율 (TL/MV)
- 금융부채비율 (FL/TA)
- 유동비율 (CA/CL)
- 고정자산비율

💰 수익성

- 총자산영업이익률 (OI/TA)
- ROE
- 이익잉여금비율 (RE/TA)
- 시장자산이익률 (NI/MV)

📈 성장성 / 유동성

- 총자산증가율 (AGR)
- 매출액증가율 (SGR)
- 현금자산비율 (Cash/TA)
- 영업현금흐름 (OCF/TA)

🏢 규모 / 기업특성

- 총자산규모 $\ln(TA)$
- 총매출규모 $\ln(Sales)$
- 최대주주지분율
- 직원수·임금 증감

🌐 거시경제

- GDP
- 원/달러 환율 (FX)
- KOSPI·KOSDAQ 지수
- CPI·PPI·국고채금리·CD

04 딥러닝 모델 소개

❓ DNN

Deep Neural Network

입력층·은닉층·출력층으로 구성된 기본 신경망. 비선형 관계를 학습하며, 범주형 변수에도 유연하게 적용 가능. 본 연구에서 Dense Layer 2개 사용.

장점

- ✓ 비선형 복잡 패턴 학습
- ✓ 범주형 변수 처리 용이

주의

△ 가중치 해석 어려움 (블랙박스)

❓ CNN

Convolutional Neural Network

이미지 패턴 인식에 강점. 본 연구에서는 기업 데이터를 이미지화하여 Convolutional Layer로 공간적 패턴을 추출하고 DNN에 입력.

장점

- ✓ 공간적(패턴) 특성 추출
- ✓ 2D 데이터 분석에 적합

주의

△ 정형 데이터 적용 시 추가 처리 필요

❓❓ LSTM

Long Short-Term Memory

RNN의 장기 의존성 문제를 해결. Forget-Input-Output Gate로 시간적 패턴을 기억. 재무 시계열 데이터에 특히 효과적.

장점

- ✓ 시계열 패턴 학습 최적화
- ✓ 장기 의존성 처리 가능

주의

△ 학습 시간 상대적으로 김

05 설명 가능한 AI: Integrated Gradients

🔍 XAI란?

복잡한 AI 모델이 결론에 도달하는 과정을 사람이 이해할 수 있게 설명하는 방법론

Feature Attribution(특성기여도)

각 입력 변수가 AI의 예측 결과에 얼마나 기여했는지를 수치로 표현

기여도가 클수록 → 해당 변수의 영향 큼

양수(+) → 부도 예측에 기여

음수(-) → 비부도 방향으로 기여

📐 Integrated Gradients

Sensitivity + Implementation Invariance

두 가지 공리(Axioms)를 동시에 만족하는 Feature Attribution 방법론

Baseline(기준점)에서 실제 Input까지의 모든 경로의 기울기(Gradient)를 적분하여 각 특성의 기여도를 계산

🔑 핵심 장점

- 이미지·텍스트·정형 데이터 모두 적용 가능
- 특정 지점에서 기울기 = 0인 문제 해결
- DNN·CNN·LSTM 등 다양한 딥러닝 모델 지원

훈련 데이터셋 구성 & 모델 검증 방법

Set 1

재무비율만

- 건전성 (부채비율 등)
- 수익성 (ROE 등)
- 성장성 (자산증가율 등)
- 유동성 (현금비율 등)
- 활동성 (자산회전율 등)
- 규모 (총자산·매출 log)

Set 2

재무비율 + 기업특성

- Set 1 전체 포함
- + 직원수 증감
- + 직원 평균임금 증감
- + 최대주주지분율
- + 최대주주지분율 증감

Set 3

재무비율 + 기업특성
+ 거시경제

- Set 2 전체 포함
- + GDP
- + 원/달러 환율
- + KOSPI·KOSDAQ 지수
- + CPI·PPI·국고채·CD

5-Fold Cross Validation (교차 검증)

전체 데이터를 5등분 → 1/5는 검증, 4/5는 학습 → 5회 반복하여 모델 안정성 확보. 부도 데이터 희소 문제를 완화하고 다양한 특성 학습 가능.

06 실험 결과 — 예측 성능 (F1 Score & Accuracy)

모델	Set1 F1	Set1 Acc	Set2 F1	Set2 Acc	Set3 F1	Set3 Acc
DNN	92.90	92.57	90.99	90.47	99.56	99.56
CNN	90.05	89.48	91.34	90.87	99.64	99.64
LSTM	93.12	92.97	93.09	92.85	99.72	99.72

Set 1 (재무비율)

DNN·CNN·LSTM 모두 F1 90% 이상의
준수한 성능.
LSTM이 시계열 특성 반영으로 소폭
우세.

Set 2 (+ 기업특성)


기업특성 추가 시 성능이 Set1과 비슷
하거나 소폭 하락.
기업특성 자체의 Feature Attribution
이 낮음을 시사.

Set 3 (+ 거시경제)

모든 모델에서 F1 99% 이상으로 대폭
향상!
거시경제지표가 기업부도 예측에 핵
심 역할.

07 Feature Attribution 분석 — Set 1 (재무비율)

DNN·LSTM 공통 상위 Feature (Set 1)



💡 해석

● 부도 예측에 기여 (양수)

건전성 지표(부채비율) 악화
→ 부채 높을수록 부도 위험 ↑

● 비부도 예측에 기여 (음수)

기업 규모 지표 $\ln(TA)$, $\ln(Sales)$
→ 대형·활성 기업일수록 부도 ↓

결론

재무 건전성 악화 + 규모 소형
= 부도 위험 최고조

07 Feature Attribution — Set 3 (거시경제 포함)

기업 규모·활동성

$\ln(TA)$, $\ln(Sales)$, $Sales/AR$, $Sales/TA$



-

비부도 방향 (음수)

재무 건전성

TL/TA , TL/MV , FL/TL , CA/CL



+

부도 방향 (양수)

최대주주지분율

$MajorOwn(\%)$



+

부도 방향 (양수)

수익성·유동성

ROE , OCF/TA , $Cash/TA$



-

비부도 방향 (음수)

거시경제지표

CPI , PPI 증감, 국고채, GDP , FX



+

부도 방향 (양수)

기업특성 (성장률)

$\Delta Employee$, $\Delta Salary$, $\Delta MajorOwn$



≈ 0

영향 미미

상위 10개 특성으로 재예측한 결과 비교

전체 32개 특성 사용

모델	Set3 F1	Set3 Acc
DNN	99.56	99.56
CNN	99.64	99.64
LSTM	99.72	99.72

✓ 핵심 인사이트

32개 전체 특성을 모두 사용한 결과
Set 3에서 99% 이상의 압도적 성능 달성.

상위 10개 특성만 사용

모델	Set3 F1	Set3 Acc
DNN	88.88	88.09
CNN	99.64	99.64
LSTM	99.68	99.68

⚠ 주목할 점

CNN·LSTM: 상위 10개만으로도 동등한 성능!
DNN만 Set 3에서 소폭 하락.

→ Feature Attribution 기반 변수 선택이
효율적 모델 구축에 유효함을 검증!

✦ XAI 기반 Feature Selection을 활용하면 특성 수를 줄이면서도 높은 예측 성능을 유지할 수 있다!

거시경제 변수의 역할 — 핵심 발견

📊 실제 역사적 사례: 거시경제 충격 → 기업 부도 급증

2008~2011

글로벌 금융위기

세계적 경기침체로 2009~2011년 사이 상장기업 부도 집중 발생

2020

코로나19 팬데믹

주요 거시경제지표 급락 → 기업 유동성 위기 심화

🔍 흥미로운 연구 결과 — '거시경제 역설'

거시경제지표의 Feature Attribution(기여도)은 상대적으로 낮게 측정되었으나,
거시경제를 추가한 Set 3에서 예측 정확도가 99%로 대폭 향상 → 이것이 의미하는 바:

- ① 개별 거시경제 변수의 직접적 기여도는 낮아도, 다른 재무 변수들과의 상호작용 효과가 매우 큼
- ② 기업 부도 예측 시 거시경제 맥락을 반드시 고려해야 함

08 핵심 발견 요약

1

재무 건전성이 부도 예측의 핵심

부채비율, 시장부채비율 등 건전성 지표가 악화될수록 부도 예측에 가장 강하게 기여

2

기업 규모·활동성은 부도를 억제

총자산 규모·매출액 규모가 클수록, 자산회전율이 높을수록 비부도 방향으로 기여

3

거시경제 변수의 간접적 역할

개별 기여도는 낮지만 거시경제 포함 시 전체 예측력이 99% 이상으로 대폭 향상

4

최대주주지분율의 예상외 영향

지분 집중도가 높을수록 오히려 부도 위험 신호 — 지배 구조 리스크 반영

5

LSTM이 시계열 데이터에 최적

3가지 딥러닝 모델 중 LSTM이 재무 시계열 특성을 가장 잘 반영하여 우수한 성능

6

XAI로 블랙박스 문제 해결 가능성

Integrated Gradients로 딥러닝 예측 근거를 시각화 — 신뢰성·투명성 확보에 기여

결론 & 시사점

연구 기여

XAI(Integrated Gradients)로 딥러닝 기업부도 예측 모델의 블랙박스 문제를 해결하고, 각 변수의 기여도를 최초로 시각화하여 신뢰성·투명성 향상

실무 활용

금융기관과 신용평가기관이 부도 위험 기업을 식별하고 선제적 조치를 취하는 데 활용 가능한 설명력 있는 예측 모델 제공

연구 한계

Integrated Gradients는 딥러닝 전용 → 머신러닝(SVM, RF)에는 적용 불가. 다양한 XAI 기법(SHAP, LIME 등) 결합 시 설명력 추가 향상 기대