

딥러닝 시계열 알고리즘 적용한

기업부도예측모형 유용성 검증

RNN & LSTM으로 금융위기를 넘는 안정적 예측모형 구축

논문 출처 J Intell Inform Syst, Vol.24, No.4 (2018)

연구자 차성재 · 강정석 (㈜에이젠글로벌)

분석 기간 2000~2009년 (KOSPI·KOSDAQ 연간 데이터)

목 차

01

연구 배경 & 목적

정적 모형의 한계, 동적 시계열 모형의 필요성

02

연구 데이터 구성

10년 데이터, 3기간 분할 (학습/검증/테스트)

03

변수 선정 방법론

MDA · Logit · Lasso 회귀분석

04

부도 예측 모델 비교

9가지 알고리즘 (통계모형 ~ 딥러닝)

05

RNN & LSTM 시계열 모형

가변적 데이터 생성법과 구조 설명

06

모형 평가 지표

ROC AUC · PR AUC · F1 Score

07

실험 결과 분석

3가지 변수군 × 9가지 모델 결과 비교

08

핵심 결론 & 시사점

RNN·LSTM의 유용성 검증 및 한계

01 연구 배경 & 목적

! 기존 연구의 한계

① 정적(Static) 모형 위주

시간에 따라 변화하는 부도 위험 요인을 반영하지 못함

② 특정 변수에만 집중

부채비율 등 단일 지표로만 구조조정 진행 → 2008년 리만 브라더스 사태처럼 시스템 붕괴 위험

③ 데이터 3가지 한계

- 비선형 변수
- 다중공선성 문제
- 데이터 수 부족 (부도기업 희소)

✓ 연구 목적

3가지 문제를 각각 해결하는 방법론 조합:

비선형성 → Logit(로짓) 모형

다중공선성 → Lasso 회귀분석

데이터 부족 → 딥러닝 시계열 알고리즘(가변적 데이터 생성)

최종 목표:

금융위기 전후를 포괄하는 일관되고 안정적인 (Consistent & Robust) 기업부도 예측모형 구축

02 연구 데이터 구성

 KOSPI + KOSDAQ | 2000~2009년 연간 데이터 | 총 890개 기업 (부도 134개) | 원천: FnGuide DataGuide

Train Set 학습 데이터

2000~2006
(7년)

금융위기 이전
정상 데이터 학습

5,766개 → 14,649개
(시계열 생성 후)

Validation Set 검증 데이터

2007~2008
(2년)

금융위기 포함!
Parameter Tuning

1,530개
(시계열 생성 안함)

Test Set 테스트 데이터

2009년
(1년)

금융위기 이후
최종 성능 검증

722개
(표본 외 검증)

🔑 연구 설계의 핵심 포인트

학습 데이터가 금융위기 이전 → 검증 데이터가 금융위기 포함 → 이 상태에서도 일관된 성능을 보이는 모델을 Parameter Tuning으로 선정 → 이후 학습+검증 통합 후 2009년 데이터로 최종 검증

03 변수 선정 방법론 (3가지)

MDA

다중판별분석
(Multiple Discriminant Analysis)

해결 문제: 다중공선성 해결

방법

F-test(등분산 검정) → T-test(집단 간 차이 검정) → 상관분석으로 공선성 높은 변수 제거

결과

13개 최적 변수 선정

ROA, ROE, 총부채회전율, 자기자본비율, 총자산 증가율 등 수익성·건전성 중심

Logit

로지스틱 회귀분석
(Logit Model)

해결 문제: 비선형성 해결

방법

Backward Stepwise Selection 방법으로 변수를 하나씩 제거하며 유의미한 변수 선별

결과

11개 최적 변수 선정

총자산증가율(1위), 지배주주지분(2위), 총부채회전율(3위), 총부채증가율(4위) 등

Lasso

Lasso 회귀분석
(Lasso Regression)

해결 문제: 다중공선성 + 차원 축소

방법

L1-norm 기반 정규화로 불필요한 변수의 계수를 정확히 0으로 만들어 변수 선택

결과

11개 최적 변수 선정

ROA(영업이익)(1위), ROE(세전사업이익)(2위), 총부채회전율(3위), 이자비용(3위) 등

3가지 방법에서 공통 선정된 핵심 변수

총부채회전율

Total Debt Turnover

매출액 ÷ 총부채 평균 → 높을수록 부도 확률 ↓

3회 공통

자기자본비율

Equity Capital Ratio

자기자본 ÷ 총자본 → 높을수록 재무 건전 → 부도 ↓

3회 공통

ROA (영업이익)

ROA(Operating Profit)

영업이익 ÷ 총자산 → 높을수록 수익성 → 부도 ↓

3회 공통

총자산증가율

Total Asset Growth Rate

자산 증가 = 부도 ↓ / 부채 증가로 인한 자산 증가 = 부도 ↑

3회 공통

ROE (세전사업이익)

ROE(Earnings before tax)

순이익 ÷ 자기자본 → 높을수록 주주수익 → 부도 ↓

3회 공통

타인자본비율

Borrowed Capital Ratio

차입금 의존도 → 높을수록 부도 위험 ↑

2회 공통

영업수익/영업비용

Operating Revenue/Expense

수익률 → 높을수록 기업 운영 효율 → 부도 ↓

2회 공통

총부채증가율

Total Debt Growth Rate

부채 증가 = 부도 위험 ↑

2회 공통

04 비교 대상 9가지 알고리즘

통계 기반 (Score 모형)

LDA

다중판별분석. Altman Z-score의 근간. 정규분포 가정 필요.

LR

로지스틱 회귀. Ohlson O-score의 근간. 비선형 처리 가능.

비시계열 기계학습

DT

의사결정나무. 해석력 우수, 학습 오류 누적 문제.

RF

랜덤 포레스트. 앙상블 기법, 일반적으로 가장 안정적.

KNN

k-최근접 이웃. 비모수 알고리즘, k값 설정이 핵심.

SVM

지지벡터머신. 최대 마진 경계 분류, Soft Margin 개념.

MLP

다층 퍼셉트론. 딥러닝의 기본, 정적 모형에 해당.

딥러닝 시계열

RNN

순환신경망. 이전 Hidden State 기록을 현재 학습에 활용. Vanishing Gradient 문제 있음.

LSTM

장단기기억. Cell State로 RNN의 Vanishing Gradient 해결. 장기 패턴 기억 가능.

05 RNN & LSTM — 시계열 모형의 핵심

🔄 RNN (Recurrent Neural Network)

핵심 원리:

이전 시점의 Hidden State를 현재 학습에 함께 사용
→ 과거 정보 반영

수식: $o(t) = \sigma(U \cdot x(t) + W \cdot h(t-1))$

⚠️ 한계:

시점 간격이 멀어질수록 Back-Propagation Through Time에서 기울기가 0에 수렴

→ Vanishing Gradient 문제 발생

💡 LSTM (Long Short-Term Memory)

RNN 개선:

Cell State를 추가해 어떤 정보를 기억/삭제할지 결정

4단계 구조:

- ① Forget Gate: Cell State에서 버릴 정보 결정
- ② Input Gate: 새 정보 중 저장할 것 결정
- ③ Cell State 업데이트
- ④ Output Gate: 최종 출력값 결정

✓ 해결:

Cell State로 Vanishing Gradient 문제 해결
→ 장기 시계열 패턴 학습 가능

가변적 데이터 생성법 & 모형 평가지표

가변적 데이터 생성법 (시계열의 핵심 기술)

데이터 부족 문제 해결 전략:

5개 시점의 데이터 → 3기간 연속 슬라이딩으로 샘플 생성

예시 (3기간 슬라이딩 윈도우):

- ① [1,2,3] → 학습 샘플 1
- ② [2,3,4] → 학습 샘플 2
- ③ [3,4,5] → 학습 샘플 3

Padding 기법:

앞 기간 데이터 없을 때 → 직후값(forward fill)으로 채움

효과:

5,766개 → 14,649개로 데이터 약 2.5배 확대
(부도 샘플: 92개 → 227개)

모형 평가 지표

ROC AUC

FPR-TPR 그래프 아래 넓이
→ 1에 가까울수록 우수
→ 기본 성능 평가 지표

PR AUC

Recall-Precision 그래프 아래 넓이
→ 불균형 데이터에서 더 엄격
→ 최우수 모형 선정 기준

F1 Score

왜 Accuracy만으로는 부족한가?
부도기업 비율 ~2% → 전부 정상 예측해도 Accuracy 98%!!

07 실험 결과 — MDA 변수 기반 (Test Set 2009)

알고리즘	Accuracy	ROC AUC	PR AUC	평가
LDA	0.979	0.804	0.306	보통
LR	0.982	0.702	0.373	보통
DT	0.975	0.645	0.101	낮음
RF	0.975	0.861	0.381	우수 ★
KNN	0.977	0.832	0.242	보통
MLP	0.981	0.756	0.396	우수
RNN	0.978	0.875	0.330	우수 ★

ROC AUC 순위 (MDA 변수)

- 1위: RNN (0.875)
- 2위: RF (0.861)
- 3위: LSTM (0.844)

PR AUC 순위 (MDA 변수)

- 1위: MLP (0.396)
- 2위: RF (0.381)
- 3위: RNN (0.330)

종합 판단

- RF·RNN: 가장 균형 잡힌 성능
- DT: ROC AUC 0.645 → Over-fitting 심각
- KNN: 학습 우수, 테스트에서 과적합

Logit & Lasso 변수 기반 테스트 결과 비교

● Logit 변수 기반 — Test Set ROC/PR AUC

알고리즘	Accuracy	ROC AUC	PR AUC	평가
RF	0.981	0.899	0.390	우수 ★
RNN	0.981	0.862	0.512	최우수 ★★
LSTM	0.978	0.830	0.233	보통
KNN	0.979	0.881	0.414	우수


🔍 Lasso 변수 기반 — Test Set ROC/PR AUC

알고리즘	Accuracy	ROC AUC	PR AUC	평가
RF	0.977	0.917	0.382	우수 ★
LSTM	0.979	0.873	0.418	최우수 ★★
RNN	0.978	0.869	0.314	우수
KNN	0.975	0.844	0.375	우수

🌟 종합: Logit 변수 + RNN 조합이 PR AUC 0.512로 전체 최고. Lasso 변수 + LSTM 조합이 0.418로 2위.

전체 변수군 × 알고리즘 최종 순위

ROC AUC 비교 (Test Set 2009)



PR AUC 상위 순위

1위 Logit + RNN 0.512

2위 Lasso + LSTM 0.418

3위 Logit + MLP 0.426

4위 Lasso + MLP 0.401

5위 MDA + MLP 0.396

6위 Logit + KNN 0.414

08 핵심 결론 & 시사점

🏆 RNN-LSTM의 유용성 입증

딥러닝 시계열 알고리즘이 기존 통계 모형(LDA, LR)과 비시계열 ML 모형(DT, KNN, SVM)보다 전반적으로 우수하거나 동등한 성능. 앙상블 기반 RF와 비교해도 경쟁력 있음.

🔑 Lasso 변수 선정의 효과

기존 MDA·Logit에 Lasso 회귀분석을 추가함으로써 다중공선성 제거된 변수군으로 더욱 Robust한 모형 구축 가능. 금융 실무에서 차원 축소에 바로 활용 가능.

📈 가변적 데이터 생성법의 중요성

시계열 알고리즘에서 슬라이딩 윈도우 + Padding(직후값 채우기) 방식이 핵심. 다른 방식으로 생성 시 예측력이 크게 하락함을 실험으로 확인. 데이터 전처리가 성능을 좌우.

⚠️ 한계 & 향후 연구 방향

- 금융 데이터의 비선형성·희소성으로 인해 결과 일반화에 주의 필요
- 딥러닝 시계열에도 랜덤 포레스트처럼 앙상블 기법 적용 시 추가 성능 향상 기대
- SHAP, Attention 등 해석 기법 결합 연구 필요

두 논문 비교 요약 (학습 포인트)

비교 항목	2018 논문 (차·강)	2023 논문 (박 외)
연구 연도	2018년 (차성재·강정석)	2023년 (박중현 외)
모델 종류	RNN, LSTM + ML 비교 (9가지)	DNN, CNN, LSTM (3가지 딥러닝)
변수 수	11~13개 (선정 후)	32개 (재무+기업특성+거시경제)
평가 지표	ROC AUC, PR AUC 중심	F1 Score, Accuracy 중심
XAI 활용	없음 (블랙박스 그대로)	Integrated Gradients 적용 ✓
데이터 기간	2000~2009년 (금융위기 포함)	2001~2021년 (코로나 포함)
핵심 기여	시계열 알고리즘 최초 적용 검증	딥러닝 예측의 설명력(XAI) 확보
최우수 모형	Logit변수 + RNN (PR AUC 0.512)	LSTM + 거시경제 (F1 99.72%)

결론 & 시사점

?? 왜 시계열인가?

기업 부도를 결정하는 변수는 시간에 따라 변한다. 정적 모형은 특정 시점에 편향 → 딥러닝 시계열이 동적 변화를 반영해 일관성 유지

∞ 3가지 문제, 3가지 해법

비선형성(Logit) + 다중공선성(Lasso) + 데이터 부족(시계열 가변 생성) → 세 가지를 동시에 해결하는 파이프라인 구성이 핵심

💡 실무 활용 포인트

금융기관에서 기업신용평가·조기경보 시스템 구축 시 RNN/LSTM + Lasso 변수군 조합 권장. 특히 경기침체 국면에 서 안정적 성능