

금융 데이터 및 텍스트 데이터를 활용한 금융 기업 조기 정보 모형 개발 : 부실은행 예측을 중심으로

송서하 · 김준홍 · 김형석 · 박재선 · 강필성[†]

고려대학교 산업경영공학부

Development of Early Warning Model for Financial Firms Using Financial and Text Data : A Case Study on Insolvent Bank Prediction

Seoha Song · Junhong Kim · Hyungseok Kim · Jaeseon Park · Pilsung Kang

Department of Industrial Management Engineering, Korea University

The early warning model, one of the risk management models for financial companies, was introduced to detect in advance the capital adequacy crisis of financial institutions. The existing early warning models have mainly used predictive models with structured data-based variables such as various macroeconomic indicators and enterprise internal indicators. The purpose of this study is to further improve the performance of the early warning models by applying customer complaints data and news articles related to individual financial institutions to machine learning-based model. As a result of applying this technique to actual data over the period of 2001 to 2017, the methodology proposed in this study has demonstrated a performance improvement up to 20%p compared to the existing methodology in certain evaluation metrics.

Keywords: Early Warning Model, Unstructured Text Data, Text Mining, Machine Learning

1. 서 론

금융 산업의 구조가 복잡해지면서 수익, 위험 관리 등을 목적으로 하는 금융 모델들도 과거보다 고도화될 필요성이 요구되고 있다. 인터넷 은행 및 홈트레이딩 시스템(home trading system; HTS) 등 기술과 제도의 발달로 발생한 사건들은 연쇄적으로 금융 산업에 영향을 준다(Malecki, 1997). 한 가지 예시로 인터넷 은행이 실제 시장의 이자율에 영향을 미친다는 연구 결과가 보고된 사례가 있다(Luo *et al.*, 2018). 경험적으로 기술 발달의 속도는 시간에 따라 일정하지 않고 폭발적으로 증가하며(Chalmers, 2010) 증가하는 변화 속도와 함께 금융 기업에도 기존의 분석 체제만으로 대응

하기 힘든 잠재 위험의 요소들이 증가할 것이다(Holton, 2004).

잠재 위험은 취약성(vulnerability)을 가질 수 있으며 취약성은 그에 대응하는 위기를 촉발하는 사건(trigger event)과 결합해 금융위기를 발생시킨다(Lee, 2015). 금융 기업의 위기는 그 피해가 고객에서 시작해 사회 전반으로 퍼지는 막대한 파급효과를 가진다. 대표적인 금융위기의 예로 국내에서는 1997년과 2003년에 발생한 외환위기 및 카드 사태 등이 있으며 국외에서는 2008년 미국에서 발발하여 전 세계에 막대한 피해를 준 서브프라임 모기지 사태(subprime mortgage crisis)가 있다. 위험 관리 주체들은 위기로 인한 기대 비용을 최소화하기 위해 금융기관에 대한 효과적인 위험 관리 모형을 연구개발 중이다.

이 논문은 2018년도 정부(미래창조과학부 및 교육부)의 재원으로 한국연구재단의 지원을 받아 수행된 기초연구사업임(NRF-2016R1D1A1B03930729). 또한 이 논문은 한국전력공사의 2018년 착수 에너지 거점대학 클러스터 사업에 의해 지원되었음(과제번호 R18XA05).

[†] 연락저자 : 강필성 교수, 02841 서울시 성북구 안암로 145 고려대학교 산업경영공학부, Tel : 02-3290-3383, Fax : 02-929-5888,

E-mail : pilsung_kang@korea.ac.kr

2018년 12월 7일 접수; 2019년 3월 5일 수정본 접수; 2019년 3월 6일 게재 확정.

조기 경보 모형은 금융 기업의 위험을 사전에 파악하고 대응하기 위한 모형이다. 위험 관리 주체는 조기 경보 모형을 통해 금융 기업의 자본 적정성 비율(capital adequacy ratio)을 평가한다. 자본 적정성 비율은 자기 자본 비율이라고도 불리며, 국제결제은행(bank for international settlements, BIS)이 은행의 건전성을 측정하기 위해 고안한 대표적인 위험 측정 지표이다(Lee, 2015). 자본이 충분할 경우 은행의 파산 확률이 낮아지기 때문에 자본 적정성 비율은 은행의 재무 건전성을 나타내는 중요한 척도이다. 은행은 감독 당국에 의해 최소한의 자본을 유지하도록 요구되며 수치가 일정 수준 이하일 경우 부실은행으로 지정된다. 이 비율을 충족하지 못하는 것은 해당 기업이 최소한의 요구를 만족할 수 없는 위기 상태라는 것을 암시한다. 이에 따라 본 연구에서는 은행의 자본 적정성 비율이 향후 2분기 이후 6% 이하로 하락할 것인지 예측하는 조기 경보 모형을 개발하였다.

기존의 조기 경보 모형은 거시경제 및 기업 내부 지표 같은 정량적인 변수를 사용한 예측 모형이 주를 이루었다. 모형이 주요 변수로 사용하는 기업 내부 지표들은 그 데이터가 금융기관에서 직접 수집된다는 특징이 있다. 이러한 재무 지표들은 해당 기관과 가장 밀접한 설명 변수지만 역으로 단점 또한 존재한다. 첫 번째로, 특정 주체가 기록하는 기업 내부 지표나 거시경제 변수들은 도덕적 해이(moral hazard)나 관리 감독 체계의 미흡함 등 중립성을 보장하기 힘든 요인에 의해 훼손될 수 있다(Dowd, 2009). 두 번째로, 기존의 데이터들은 기업 간 사전에 정해진 방법으로 수집되기 때문에 수집 대상과 단위, 기간 등을 유동성 있게 분석 모형에 맞춰 변경하는 것이 어렵다.

본 연구에서는 개별 금융기관과 관련된 고객의 민원 데이터와 뉴스 기사 데이터들을 조기 경보 모형에 적용하고자 한다. 이해관계 기관 외부에서 수집되는 비정형(unstructured) 텍스트 데이터들은 기업 내부 지표와 같은 기존 데이터의 약점을 보완할 수 있다. 첫째, 정보기술의 발달과 함께 비정형 텍스트 데이터의 양은 그 생성 속도가 폭발적으로 증가하고 있고(Zhu et al., 2009) 상대적으로 누구나 확보하기 쉽다는 장점이 있다. 둘째, 이러한 비정형 텍스트 데이터는 금융기관 당사 간에 기록하는 데이터가 아니며 상대적으로 금융사 간 이해관계에 의해 훼손될 위험이 적다. 그 예시로 민원 데이터의 경우는 소비자의 입장에서 바라보는 금융사에 대한 관점을 반영할 수 있으며, 뉴스 기사 데이터의 경우는 검색엔진의 중립성이 내용의 중립성을 보장한다는 장점이 있다. 수집된 비정형 텍스트 데이터들은 기계학습(machine learning) 기법을 통해 현재의 경향을 반영하거나 미래의 사건을 예측하는 등 금융 산업에서 객체 간의 연관성을 규명하는 작업에 적용될 수 있다. 실제로 다양한 분야에서 텍스트 정보를 이용한 기계학습을 시도하고 있다. 최근 Cho et al.(2017)의 연구는 여행 사이트 리뷰 정보를 이용해 관광지의 만족도 요인을 분석했으며, Jeong et al.(2018)의 연구는 이동통신 단말기 리뷰 정보를 이용해 비지도 학습 기반 주제 범주화를 시도하고 그 성능을 검증했다.

본 연구에서 사용된 비정형 데이터는 각 은행에 대한 민원 데이터와 뉴스 기사 데이터이다. 본 연구에서 사용된 정형 데이터는 기존 조기 경보 모형에서 이용하는 재무 데이터 및 거시경제 데이터이다. 비정형 데이터는 (1) Doc2Vec, (2) 잠재 디리클레 할당 모형(latent Dirichlet allocation, LDA)을 이용한 토픽 모형(topic modeling), 두 가지 텍스트 마이닝 기법을 통해 정형 데이터와 결합된다. 두 기법은 동시에 사용되어 서로 다른 두 모형의 장점을 함께 이용할 수 있도록 하였다. 결합된 데이터는 기존에 사용하던 모형인 (1) 로지스틱 회귀(logistic regression)와 새롭게 적용하는 (2) 랜덤 포레스트(random forest), (3) 순환 신경망(recurrent neural network, RNN)의 확장된 형태인 LSTM(long short-term memory), 각 세 종류의 기계학습 알고리즘에 적용되었으며 세 가지의 평가지표에서 어떤 모델이 유리한지 실증적인 비교 실험을 수행했다.

본 연구는 다음과 같이 구성되어 있다. 제 2장에서는 조기 경보 모형의 발전과 관련된 선행 연구와 예측 모형에 텍스트 정보 적용을 시도한 선행 연구들을 소개한다. 제 3장에서는 본 연구에서 사용한 방법론을 서술한다. 제 4장에서는 데이터의 수집 방법과 전처리 과정을 묘사하고 결합된 데이터들이 기계학습 기반의 모형에 적용되는 방식을 논한다. 제 5장에서는 실험 결과를 다양한 지표에서 해석한다. 제 6장에서는 본 논문의 결론과 후속 연구 계획을 제시했다.

2. 선행 연구

금융위기 이후 많은 기업이 도산하면서 개별 금융기관의 위험 관리를 위한 통계적 분석 방법 연구가 활발해지기 시작했다. 전통적으로 통계적 분석 모형은 판별분석모형(discriminant analysis model)과 로지스틱 회귀 모형이 이용된다. 판별분석모형은 Altman(1968)의 연구 이후 1970년대부터 금융 기업의 부실 예측 모형을 위해 사용되었지만, 모델에서 이용하는 설명 변수가 정규분포를 따른다는 가정이 필요해 그 범용성이 부족하다고 평가된다. 로지스틱 회귀 모형은 설명 변수의 확률 분포가 정규분포를 따르지 않아도 적용 가능하며(Ohlson, 1980) 현재 가장 범용적으로 이용되는 알고리즘이다.

재무 정보만 이용하던 기존의 예측 모형은 모델에서 사용하는 설명 변수를 다양화하는 방향으로 고도화가 이루어졌다. McQuown(1993)과 Jarrow and Turnbull(1995)는 재무 정보 외에도 주식시장과 채권시장의 정보처럼 해당 기업과 직접적인 관련 지표를 이용한 예상 부도확률(expected default frequency, EDF) 모형과 내재 부도율(implied default rate, IDR) 모형에 관한 연구를 진행했다. 이후 재무 정보와 시장정보를 통합하고 더 많은 정보량을 이용한 모형들이 더 성능이 좋다는 것을 실증적으로 확인하는 연구들이 진행되었으며(Shumway, 2001; Campbell et al., 2008), 개별 기업과 직접적인 관련이 없어도 영향력을 가질 수 있는 거시경제 변수의 유효성도 확인되었다.

(Tinoco and wilson, 2013). 다양한 설명 변수와 동시에 조기경보 모형의 목적 변수는 자본 적정성 비율이 자주 이용된다. 관련 연구(Choi and Oh, 2010)에서는 실제로 파산 은행일수록 일반 은행과 비교해 자산 건전성이 떨어지고, 자기자본비율은 낮으며, 자산 대비 대출 비율이 낮은 경향이 있음을 확인했다.

모형에 사용되는 데이터의 다양화 외에 모형 자체를 다양화하는 연구도 진행되었다. Christofides *et al.*(2016)의 연구 결과는 기존의 조기 경보 모형들이 개별적으로는 2008년의 금융위기를 예측하지 못했지만, 각각 작은 범위의 다른 위기를 예측할 수 있음을 시사한다. 미국은 부실은행을 발생시킬 요인을 감지하는 미래 지향적(forward-looking models) 모형과 은행이 직면하는 위험에 초점을 맞춘 모형(risk-focused models)들을 복수로 운영해 오고 있다(Kim and Baek, 2012).

본 연구는 텍스트 데이터를 활용해 조기경보 모형의 성능향상을 시도한다. 조기경보 모형의 성능향상을 위해 텍스트 정보를 활용한 연구는 아직 국내에서 활발하지 않다. 하지만 대중의 관심을 받는 투자 자산 분야에서는 텍스트 정보의 도입이 꾸준히 시도되었다. 대표적으로 Mittermayer(2004)의 연구는 NewsCATS(news categorization and trading system) 시스템을 구축해 특정 기사가 노출되는 즉시 주식 가격에 미치는 영향을 연구했다. 이 연구는 term frequency-inversed document frequency(TF-IDF)와 support vector machine(SVM) 알고리즘을 이용한 자동 텍스트 분류(automatic text categorization, ACT)를 통해 주가 예측 모형의 성능향상을 시도했으며, 정확한 분류작업을 위한 특징(feature) 추출의 중요성을 강조한다.

최근 새롭게 등장해 큰 가격 변동성을 보여주는 암호 화폐(crypto currency) 시장에서도 텍스트를 활용한 예측 모형 연구가 이루어졌다. Kim *et al.*(2017)의 연구는 2013년부터 2016년 간의 온라인 암호 화폐 관련 커뮤니티에 기록된 텍스트들을 이용해 암호 화폐의 가격 예측을 시도했다. 이 연구는 비음수 행렬 분해(non-negative matrix factorization, NMF) 기법을 이용해 문서-용어 행렬을 용어-요소 행렬과 요소-문서 행렬로 분해하고, 이때 만들어지는 요소-문서를 벡터값처럼 문서의 특징로 사용했다. 또한, 문서의 본문과 이에 대한 댓글을 함께 분석

에 도입하였으며, 댓글을 함께 이용했을 때 본문만 사용한 경우보다 예측 성능이 개선됨을 확인했다.

3. 방법론

본 연구에서는 정형 데이터와 비정형 텍스트 데이터를 함께 활용하는 기계학습 기반 조기 경보 모형을 제안한다. 본 연구의 방법론은 크게 두 부분으로 나눌 수 있다. 제 3.1절에서는 텍스트 데이터를 모델에 활용하기 위한 문서 범주화 기법을 설명한다. 제 3.2절에서는 추출된 비정형 데이터의 분석 결과를 활용하는 모형들을 제시했다.

3.1 문서 범주화

비정형 데이터를 기계학습 알고리즘에 적용하기 위해 텍스트는 문자 형태에서 모델에 적용 가능한 연속형 실수 벡터로 변환되어야 한다. 이를 위해 본 연구는 Doc2Vec 알고리즘과 LDA 기반 토픽 모형화를 이용했다.

(1) Doc2Vec

텍스트 데이터는 분산 표상(distributed representation) 기법을 통해 미리 정의된 고차원 공간으로 표현될 수 있다. Word2Vec은 연산량이 적으면서 분산 표상을 가능하게 하는 모형이다(Mikolov *et al.*, 2013). Word2Vec의 단어 단위 분산 표상을 문장 단위로 확장한 것이 Doc2Vec 모형이다. Doc2Vec은 간단한 인공신경망을 활용해 대량의 텍스트로 이루어진 문서를 효과적으로 고차원 공간에 표현할 수 있다(Le and Mikolov, 2014). Doc2Vec 모형은 해당 문서 아이디와 문서의 단어들로부터 문서에 속한 다른 단어를 예측하는 DM(distributed memory) 방식과 해당 문서에 포함된 단어들로부터 해당 문서를 예측하는 DBOW(distributed bag of words) 방식으로 나누어진다. <Figure 1>은 두 모형을 도식화한 것이다. 본 연구에서는 Doc2Vec의 두 가지 방식 중 구조상 역전파로 인한 학습량이 더 많은 DM 방식을 통해 은행별 민원 문서와 뉴스 기사 문서를 50차원의 공간에 표현하였다.




Figure 1. The Architecture of DM & DBOW(reprinted from(Le and Mikolov, 2014))

(2) 토픽 모형: 잠재 디리클레 할당(LDA)

텍스트 문서데이터는 해당 문서가 어떤 주제일지에 대한 확률 분포로 표현될 수 있다. LDA는 디리클레 분포(Dirichlet distribution)를 가정해 토픽별 단어분포와 문서의 주제 분포의 결합확률이 최대가 되도록 깁스 샘플링(Gibbs sampling)을 통해 추론하는 기법이다(Blei, 2012). 이 모형은 결과적으로 주제별 단어의 분포와 문서별 토픽의 분포를 할당한다. 본 연구에서는 K-1의 자유도를 가지는 K개의 잠재 토픽에 대한 확률 분포를 벡터로 활용해 조기 경보 모형에 이용하였다. 적절한 K값을 찾기 위해 뉴스 기사와 민원 데이터 각각에 대해 30, 50, 100의 K값을 적용해 보았다. 문서의 수가 많은 뉴스 기사의 경우 50개의 토픽을, 문서의 수가 적은 민원의 경우 30개의 토픽을 적용했을 때 성능 하락이 적으면서 계산에 부담이 없는 낮은 차원 수를 유지할 수 있었다.

3.2 기계학습 기반 조기 경보 모형

현재 당국 감독기관에서는 조기 경보 모형으로 로지스틱 회귀 모형을 사용하고 있다. 본 연구는 이 외에도 랜덤 포레스트와 LSTM 두 가지 기계학습 모형을 이용해 금융기관의 미래 자본 적정성을 예측했다.

(1) 랜덤 포레스트

분류 모형 중 뛰어난 성능을 보이는 것으로 알려진 랜덤 포레스트는 여러 개의 독립적인 의사 결정 나무들을 배깅(bagging, bootstrap aggregation) 기법을 통해 무작위로 학습한 후 이를 앙상블 하는 방법이다(Breiman, 2001). 앙상블 기법으로 인해 특별한 변수의 소거 없이도 이상 치에 강건한 일반화된 성능의 모형을 구축할 수 있다는 장점이 있다. 랜덤 포레스트의 성능은 초 모수(hyper-parameter)에 따라 달라질 수 있다. 개별 모형을 결합하는 과정에서 개별 모형의 개수와 각 모형의 구체적인 형태를 초 모수를 이용해 정할 수 있다. 본 연구에서는 일정 범위에서 모든 경우의 실험을 통해 가장 좋은 성능을 보이는 초 모수를 탐색하는 그리드 탐색(grid search) 방식을 사용하여 최종적으로 <Table 1>과 같은 초 모수를 결정하였다.

Table 1. Hyper-Parameters for Random Forest

The number of trees in the forest = 100
The function to measure the quality of a split = Gini
The number of features to consider = Total number of variables
The minimum number of samples required to be at a leaf node = 1

(2) 순환 신경망

인공신경망은 경사 하강법(gradient descent) 기반의 오차 역전파(backpropagation) 기법을 사용하여 최적의 가중치들(weights)을 찾아내는 기계학습 알고리즘이며, 이러한 인공신경망이 순차적인 입력 정보를 처리할 수 있도록 설계된 특수한 구조가

순환 신경망이다. 순환 신경망은 음성과 문장 등 순서를 두고 등장하는 데이터 처리에 적합한 모델로 알려져 있으며(Lipton et al., 2015) 데이터가 순서를 두고 등장할 때 이전 시점의 상태를 기억해 현재의 데이터와 정보를 종합할 수 있다는 장점이 있다. 순환 신경망의 확장된 형태인 LSTM은 기존 순환 신경망의 망이 깊어질수록 역전파의 강도가 약해지는 그라디언트 소멸(vanishing gradient) 문제를 해결하고 있어야 할 정보와 기억해야 할 정보를 구분해 처리할 수 있도록 고안된 모형이다(Hochreiter and Schmidhuber, 1997). 본 연구에서는 연속된 시점의 설명 변수들을 LSTM에 적용하고 예측 오차의 오차 제곱항과 L1 정규화(norm)를 추가한 비용 함수를 사용하였다. 랜덤 포레스트와 같이 그리드 탐색을 통해 선택된 초 모수들은 <Table 2>와 같다.

Table 2. Hyper-Parameters for Recurrent Neural Networks

The number of epoch = 200(Ensemble 151~200)
Learning rate = 0.005
Regularization term = L1-Norm
Regularization term weight = 0.001

4. 실험 설계

본 연구에서 사용한 예측 모형을 구축하는 단계는 <Figure 2>에서 나타난 바와 같다.




Figure 2. Research Framework

4.1 정형 데이터

금융 기업을 감독하는 금융기관에서는 실제로 자본 적정성(자기자본비율)을 목적 변수로 사용하고 35개의 재무제표 항목을 설명 변수로 사용하는 로지스틱 회귀 모델을 조기 경보 모델로 이용하고 있다. 본 연구에서는 실제 모델에 사용되는 데이터를 정형 데이터로 이용해 모델을 구축하였다. 2001년부터 2017년까지 분기별로 금융회사들에 대한 35개의 재무제표 항목을 수집하였으며(총 901건), 결측치가 많은 특정 재무변수를 제외하고 중요한 재무변수가 누락된 관측치를 제외해 최종적으로 <Table 3>에 표시된 27개의 재무제표 값을 모두 확인할 수

Table 3. Input Variables from Structured Data

Variable Name(English)	Variable Name(Korean)
BIS Capital Adequacy Ratio	BIS자기자본비율
BIS Capital Ratio	BIS기본자본비율
Ratio of Foreign Currency Loans to Total Loans	총여신대비외화대출비율
Net Interest Margin	순이자마진율
Quarterly Net Interest Margin	분기별순이자마진율
Capital Adequacy Ratio	단순자기자본비율
Substandard & ' Below Ratio 1	고정이하여신비율 1
Substandard & ' Below Ratio 2	고정이하여신비율 2
Net Precautionary & ' Below Ratio	순요주의이하여신비율
Coverage Ratio	커버리지비율
Liquidity Coverage Ratio	유동성커버리지비율
Ratio of Short-term Loans	단기대출비율
Loan-Deposit Ratio	예대율
Net Income Ratio to Total Assets 1	총자산순이익율 1
Net Income Ratio to Total Assets 2	총자산순이익율 2
Difference in Interest Rates on Deposits and Loans	원화에대금리차
Difference in Interest Rates on Deposits and Loans for Foreign Currency	외화에대금리차
Expense Ratio to Total Assets	총자산경비율
Total Liabilities	부채총계
Total Assets	자산총계
Total Amount of Capital	자본총계
Operating Efficiency	수지비율
Return on Equity	자기자본이익율
Foreign Debt Ratio to Total Liabilities	부채총계대비외화부채비율
Customers Deposit against Total Loans	총여신대비고객예수금
Delinquency Ratio	연체대출채권비율
Ratio of Allowances for Credit Losses	대손충당금비율

있는 773건의 관측치를 예측 모형 구축 및 검증에 사용하였다. <Table 3>에서 한국어는 실제 금융당국에서 쓰는 용어이며 영어는 금융위원회의 온라인 홈페이지에서 제공하는 용어 사전을 참조해 번역하였다. 또한, 773개의 관측치는 2002년 4분기부터 2017년 2분기까지 <Table 4>에 나타난 바와 같이 분기별로 최소 12건, 최대 14건이 분포되어 있다. 2002년 4분기 이전 데이터의 경우 중요한 결측치가 많아 제외되었으며 2017년 2분기 이후 데이터는 2018년의 데이터가 없는 관계로 목적 변수만 이용하고 설명 변수는 이용하지 않았다.

Table 4. Number of Observations in Each Quarter

Periods	No. of observations	No. of quarters	Total number of observations
2002. 4 th quarter~ 2006. 1 st quarter	14	14	196
2006. 2 nd quarter~ 2015. 2 nd quarter	13	37	481
2015. 3 rd quarter~ 2017. 2 nd quarter	12	8	96

4.2 비정형 데이터

비정형 텍스트 데이터는 민원과 뉴스 기사 두 종류의 문서로 이루어진다. 민원 데이터는 금융당국의 보안 정책을 준용하여 전처리가 수행된 데이터를 전달받아 사용하였으며, 뉴스 기사는 HTTP(HyperText Transfer Protocol)통신을 통해 텍스트를 수집하는 웹 스크래핑(web scraping) 기법을 통해 수집되었다. 수집된 데이터에는 효과적인 분석을 위해 전처리와 텍스트마이닝 기법이 적용되었다.

(1) 문서데이터 수집

금융 기업의 이용자는 특정 사건이 발생했을 때 해당 기업에 대한 민원을 국내 감독 당국에서 제공하는 온라인 홈페이지를 통해 작성할 수 있다. 본 연구에서는 정형 데이터를 확보한 기간인 2001년부터 2017년에 맞추어 이에 해당하는 기간의 민원 문서를 금융감독원으로부터 제공받아 사용하였다. 민원 데이터의 경우, 개인정보에 대한 부분이 포함될 수 있으므로 해당 기관의 보안 정책을 준용하여 민감한 정보는 모두 제외한 상태로 뉴스 기사는 국내의 검색 포털 네이버(Naver)의 뉴스 검색 기능을 통해 수집되었다. 검색 포털은 여러 언론사의 뉴스 기사를 모아서 나열하는 기능을 제공하고 있으며 이점을 이용해 본 연구에서는 적절한 검색 질의(query)를 통해 금융 기업의 이름이 제목에 포함된 기사를 모두 수집했다. 기사 제목에 해당 금융 기업의 이름이 포함될 경우 기사가 해당 기업과 관련이 있는 기사라고 간주하였다. 민원 데이터와 마찬가지로 2001년부터 2017년 기간 동안 총 296,174개 뉴스 기사가 수집되었으며 기사들에 사용된 단어 수는 총 141,921개로 집계되었다.




Figure 3. Concatenating the structured and unstructured data

(2) 문서데이터 전처리

수집된 문서데이터는 금액 및 숫자와 알파벳의 나열, 전화번호, 도메인 주소, 메일 주소, 이모티콘 등 의미가 불분명한 단어들이 제거되었다. 민원 데이터와 뉴스 기사 데이터는 명확한 정보 전달이 중요한 문서이다. 따라서 다른 도메인(domain)의 문서데이터와 비교해 띄어쓰기나 비속어의 비율이 낮은 편에 속한다는 장점이 있다. 원시 형태의 문서데이터는 형태소 분석기를 통해 단어의 품사를 확률적으로 결정하는 작업(part-of-speech tagging, POS Tagging)이 수행되었다. 품사 결정 이후에는 노이즈(noise)가 될 수 있는 의미 없는 어미와 조사 등을 제거하였다. 마지막으로 은행 이름만으로 파산 가능성을 예측하는 경우를 방지하고 고유명사가 아닌 보편적인 단어들로 예측을 수행하기 위해 은행명과 전체 문서에서 등장 횟수가 5회 이하의 단어들이 문서데이터에서 제외되었다.

4.3 데이터 결합

비정형 데이터는 모델에 사용 가능한 변수로 변환되기 이전에 773개의 정형 데이터 관측치와 대응될 수 있어야 한다. 이를 위해 각 문서가 다루는 금융기관과 문서가 수집된 시점의 연도와 분기를 추적하였다. 최종적으로 모든 문서는 정형 데이터 관측치 하나와 대응되는 복수의 문서들로 그룹화가 진행되었다. <Figure 3>과 같이 문서 그룹은 그룹에 속한 모든 단어를 가지는 거대한 하나의 문서로 취급되어 텍스트 마이닝에 적용되었다. 그룹화로 인해 분기마다 노이즈가 될 문서 혹은 이상 치에 해당하는 문서의 영향력이 상쇄되는 효과를 기대할 수 있다.

Doc2Vec과 LDA 두 종류의 텍스트마이닝 방법을 민원 문서와 뉴스 기사 문서에 각각 적용해 총 182개의 연속형 변수를 생성했다. 결과적으로 민원과 뉴스 기사에 대해 50차원 문서 벡터와 분기별 출현 빈도를 추출하고, 민원 데이터에 대한 30차원 토픽, 뉴스 기사 데이터에 대한 50차원 토픽을 추출했다. 이렇게 생성된 182개의 변수는 27개의 정형 변수와 결합해 총 209개의 변수가 조기 경보 모형의 입력변수로 사용되었다. <Table 5>는 다수의 토픽 중 10개를 선정해 토픽 당 빈도수가 높은 주요 단어들을 나타낸 것이며 토픽별로 어느 정도 주제의 차이가 드러나는 것을 볼 수 있다.

Table 5. Representative Words for Each of 10 Topics

Topic	Keywords
Topic 1	소송, 분양, 상의, 답변서, 빠른
Topic 2	어음, 부도, 당사, 발행, 할인
Topic 3	계좌, 보안, 이체, 피해, बैंकिंग
Topic 4	주주, 주식, 소액, 소프트, 기술
Topic 5	전화, 정보, 팩스, 유출, 영업
Topic 6	민원, 내용, 적법, 조치, 불법
Topic 7	금리, 금감원, 가산, 징계, 집단
Topic 8	펀드, 상품, 손실, 가입, 설명
Topic 9	이자, 분양, 중도, 소송, 아파트
Topic 10	통장, 전화, 지점, 직원, 본인

4.4 모형 적용

정형 데이터에서 목적 변수는 자기 자본 비율이 6% 이하 부실기업 상태인 경우와 그 외의 경우로 정해지는 이진 분류 변수이다. 해당 목적 변수는 정상과 부실의 비율이 745:28의 비율로 존재하는 범주 불균형(imbalanced) 데이터이다. 본 연구에서는 범주의 불균형이 학습에 영향을 미치지 않도록 오버샘플링(over sampling)을 수행하고 학습데이터와 검증 데이터의 비율은 5:5로 나누었다. 부실은행 경우의 수가 상대적으로 작아 엄밀한 성능 검증을 위해 랜덤한 샘플링을 100회 수행해 평균 성능을 측정했다. 결과적으로 본 연구에서는 <Figure 4>와 같이 현재 시점으로부터 과거 1분기와 2, 3, 4분기까지의 데이터를 사용하는 4개의 실험을 구성했다.




Figure 4. Framework of Proposed Method(Input data)




Figure 5. Data Preprocessing Example for Random Forest and Logistic Regression




Figure 6. Structure of Recurrent Neural Network-based Prediction Model

Table 6. Variable Group Description for Recurrent Neural Networks

Variable Group Name	Description
D^X	27 dimensions, financial structured data
D^C	2 dimensions, number of documents per quarter (news, complaints)
D^{ND}	50 dimensions, document vector(news)
D^{NT}	50 dimensions, probability distribution by topic (news)
D^{MD}	50 dimensions, document vector(complaints)
D^{MT}	30 dimensions, probability distribution by topic (complaints)

최종적으로 모형에 사용되는 데이터들은 <Table 6>에서 자세히 설명하고 있다. 수집된 데이터들은 각 예측 모형에 적합한 형태로 조정된다. 로지스틱 회귀와 랜덤 포레스트 모형에 대해서는 <Figure 5>와 같은 전처리가 수행되었다. 예측 분기로부터 직전 2분기 데이터만 사용하는 경우는 기존의 전처리된 209차원의 변수를 사용한다. 1분기와는 다르게 2, 3, 4분기에 대해서는 각 과거 시점마다 변수들을 한꺼번에 결합한다. 결과적으로 실험마다 209의 2, 3, 4배의 변수가 사용된다.

순환 신경망의 경우는 다른 두 모형과 다르게 분기별 변수들을 합치지 않고 각각 순서대로 모형에 입력한다. 경사 하강법과 역전파를 통해 최적화를 진행하는 신경망 모형은 경험적으로 높은 성능을 달성하기 위해 적용 분야마다 모형의 세부 조정이

필요하다(Andrychowicz *et al.*, 2016). 본 연구에서는 정형 데이터와 비정형 데이터 모두를 사용하며 서로 다른 성질을 가지는 데이터로부터 효과적으로 패턴을 인식하기 위해 <Figure 6>과 같이 신경망을 구축했다. 순환 신경망 모형에 적용되는 데이터는 <Table 6>처럼 6가지 그룹으로 분류된 후 각각 별개의 입력 차원을 보존하는 LSTM 층에서 학습된다. LSTM 층에서 출력된 값은 모든 뉴런이 연결된(fully connected) 신경망을 두 번 거친 후 마지막에 종합되어 최종 분류 값을 계산한다.

<Table 2>에 기술된 바와 같이 순환 신경망의 학습은 200세 대까지 진행되었다. 신경망을 어느 시점까지 학습할지는 실제 데이터에 적용하는 관점에서 매우 중요한 사안이다. 훈련 데이터에 과하게 학습된 모형은 검증 데이터에서 낮은 성능을 보일 위험이 있다. 반대로 학습이 부족할 경우 모형이 훈련 데이터의 패턴을 제대로 인식할 수 없는 위험이 있다. 일반적으로 이를 방지하기 위해 정규화 항을 목적함수에 추가하며 본 연구에서는 정규화 항으로 L1-norm을 이용했다. 본 연구에서는 정규화 항에 추가로, 151회부터 200회 동안의 학습된 각각의 모형을 단순 앙상블 해 최종 예측값을 계산했다. 이 방법으로 인해 모형이 일정 수준 이상 패턴을 인식할 수 있는 단계가 되면, 앙상블을 통해 과적합을 피하고 높은 확률로 최적 학습 구간의 예측력을 이용할 수 있다.

4.5 성능 평가지표

본 연구에서는 조기 경보 모형의 성능을 <Table 7>의 정오 행렬(confusion matrix) 기반 3개 지표를 사용해 측정한다. 3개 지표는 실제 부실은행 중 모형에 의해 부실로 예측된 비율인 (1) 재현율(recall), 모형에 의해 부실기업으로 예측된 경우 중 실제로도 부실은행인 경우의 비율인 (2) 민감도(precision), 재현율과 민감도의 조화평균인 (3) F1-지표(F1-score)를 이용했다.

조기경보 모형은 도메인의 특성상 실제 부실은행을 놓치지 않고 정확히 부실은행으로 판별해 내는 것이 중요하며 예측

실패 시 비용도 가장 크다. 따라서 단순 정확도 보다는 F1-지표가 현실에서 더 유용하게 사용될 수 있는 지표이며, 제 5장의 실험 결과 해석은 F1-지표를 중심으로 서술하였다.

Table 7. Confusion Matrix of Prediction Model

Confusion Matrix		Predicted	
		Normal Bank	Insolvent Bank
Actual	Normal Bank	A	B
	Insolvent Bank	C	D

$$Recall = \frac{D}{C+D} \quad (1)$$

$$Precision = \frac{D}{B+D} \quad (2)$$

$$F1-Score = \frac{2 \times (Recall \times Precision)}{Recall + Precision} \quad (3)$$

5. 실험 결과

본 연구의 목적 변수는 정상과 부실의 비율이 745:28의 비율로 존재하는 범주 불균형(imbalanced) 데이터이다. 이에 대응하는 명확한 성능 검증을 위해 전체 데이터로부터 학습데이터와 평가 데이터를 랜덤하게 추출하는 과정을 100번 수행하고 각 표본에 대해서 반복적으로 실험을 진행했다. 학습데이터의 경우는 범주의 불균형으로 인한 문제를 해결하기 위해 오버샘플링(over sampling)을 수행했다. 성능의 비교는 같은 샘플 안에서 서로 다른 두 환경의 대응표본 t 검정(paired t-test)을 이용해 성능을 비교했다.

과거 1분기부터 4분기까지의 데이터를 사용하여 부실 예측을 수행한 각 모형의 F1-지표의 값과 대응표본 t 검정의 결과는 <Table 8>과 같다. 괄호 안의 숫자는 100회 반복실험에 대한 표

Table 8. Model Performance Evaluation with Paired t-Test Results

		F1-Score (Structured)	F1-Score (Structured & Unstructured)	P-Value (n = 100)
Recent 1 quarter	LR	0.7320 (0.1115)	0.7726 (0.1555)	0.0046
	RF	0.8937 (0.1121)	0.9259 (0.0799)	0.0000
	RNN	0.7332 (0.1430)	0.6455 (0.2297)	0.0002
Recent 2 quarters	LR	0.7981 (0.1083)	0.7908 (0.1591)	0.6502
	RF	0.9239 (0.0821)	0.9235 (0.0868)	0.8962
	RNN	0.8067 (0.0873)	0.7966 (0.0903)	0.2118
Recent 3 quarters	LR	0.8498 (0.1044)	0.7558 (0.1854)	0.0000
	RF	0.9152 (0.0923)	0.9127 (0.1095)	0.6409
	RNN	0.8877 (0.1067)	0.9344 (0.0770)	0.0000
Recent 4 quarters	LR	0.8774 (0.0951)	0.7679 (0.1930)	0.0000
	RF	0.9042 (0.1249)	0.8971 (0.1380)	0.3239
	RNN	0.8885 (0.0937)	0.9061 (0.0829)	0.0003

준편차이다. 기존의 정형 데이터만을 사용한 방법과 비정형 데이터도 함께 사용한 방법 두 가지를 비교해 더 높은 수치를 나타내면서 유의확률(p-value)이 0.05 이하로 신뢰할 만한 경우 굵은 글씨로 강조했다. 전체 경우의 수 중에서 가장 높은 성능을 기록하는 경우는 굵은 글씨와 밑줄로 강조하였다. 최근 3분기까지의 정형 및 비정형 데이터를 모두 사용해 순환 신경망 알고리즘을 적용한 예측 모형이 가장 높은 F1-지표 값을 나타냈으며 그 차이는 통계적으로 유의미한 수준으로 나타났다.

로지스틱 회귀, 랜덤 포레스트, 순환 신경망 세 가지 알고리즘을 정형 데이터 단독 및 정형 데이터+비정형 데이터를 이용하여 구축된 조기경보 모형의 성능은 <Table 9>와 같다. 또한, 비교를 위하여 비정형 데이터만을 단독으로 사용한 조기경보 모형의 성능은 <Table 10>에 제시하였다. <Table 10>을 통해 비정형 데이터만을 단독으로 사용하는 경우에도 어느 정도 유의미한 예측 성능을 나타내는 것도 확인할 수 있다. 그러나 정형 데이터와 비정형 데이터를 단독으로 사용한 경우에는 일반적으로 정형 데이터만을 사용한 조기경보 모형의 예측력이 우수한 것으로 나타났다. 또한, 정형 데이터에 비정형 데이터를 결합할 경우 정형 데이터만을 단독으로 사용하는 경우보다 우수한 성능을 나타내는 경우가 다수 존재하며, 특히 복잡도가 높은 순환 신경망에 대해 장기간의 과거 데이터를 사용할 때 유의미한 성능의 향상을 나타내는 것을 확인하였다. 이 결과는 적절한 알고리즘이 이용될 경우 정형 데이터와 비정형 데이터의 결합이 모형의 성능을 개선시킬 수 있음을 뒷받침한다고 할 수 있다.

5.1 모형 알고리즘과 예측 성능의 관계

<Table 9>에서는 데이터의 기간과 비정형 데이터의 유무에 따른 각 환경에서 모형들의 성능 지표들을 보여주고 있으며 지표 아래에 괄호 안에 있는 숫자는 100회 실험 결과에 대한

표준편차이다. 굵은 글씨로 강조된 부분은 같은 기간의 데이터를 활용하는 6종류의 실험 중 가장 높은 F1-지표이다.

실험 결과는 각 모형이 강점을 가지는 영역이 다르다는 점을 시사한다. 로지스틱 회귀 모형은 비교적 변수의 개수가 적고 데이터의 시의성이 보장되는 환경에서 높은 성능을 보여주고 있다. 다만 두 분기 이상의 텍스트 데이터가 추가될 경우 낮은 성능을 보이며, 이는 모형의 복잡도가 비교적 낮은 이유로 많은 양의 변수를 선택적으로 고려하지 못하기 때문이다. 랜덤 포레스트는 <Table 8>에서도 보이는 것처럼 텍스트 정보를 활용할 경우와 활용하지 않는 경우가 통계적으로 유의미한 차이가 보이지 않는다. 다만 시의성이 떨어지더라도 크게 성능이 하락하지 않는다. 랜덤 포레스트 모형은 앙상블을 통해 만들어졌기 때문에 변수의 개수와 노이즈에 강건한 예측 성능을 보일 수 있다. 다만 앙상블 과정이 무작위적이기 때문에 비정형 데이터와 정형 데이터의 장점을 선택적으로 고려하지는 못한다. 순환 신경망의 경우 긴 기간의 데이터를 이용할 경우 가장 좋은 성능을 보이는 경향이 있다. 이는 알고리즘의 특성상 모형 자체에서 데이터의 시간 정보를 고려하는 것이 가능하기 때문이다. 순환 신경망은 역전파를 통해 필요 이상의 과거 정보는 고려하는 비중을 줄이고 필요 없는 정보에 대한 과적합을 방지한다는 점을 확인할 수 있다.

<Table 10>에서는 로지스틱 회귀 모형의 경우 2분기까지는 예측 성능이 상승하지만 2분기 이후부터 변수의 차원이 너무 커져서 올바르게 학습되지 않는 현상을 볼 수 있다. 랜덤 포레스트의 경우 <Table 9>의 실험 결과와 마찬가지로 모든 기간에서 텍스트 데이터로부터 다른 모형에 비해 나은 성능을 보여주지 못하고 있다. 순환 신경망의 경우는 흥미롭게도 사용하는 데이터의 기간이 늘어남에 따라 성능이 꾸준히 증가한다. 가장 긴 4분기 기간 동안 데이터를 사용할 경우 순환 신경망은 정형 데이터만을 썼을 때와 비슷한 수준으로 유의미하게 부실은행을 예측할 수 있었다.

Table 9. Model Performance Evaluation

		Structured			Structured & Unstructured		
		Precision	Recall	F1	Precision	Recall	F1
Recent 1 quarter	LR	0.6889 (0.1744)	0.8540 (0.1517)	0.7320 (0.1115)	0.7548 (0.1735)	0.8400 (0.2078)	0.7726 (0.1555)
	RF	0.8709 (0.1418)	0.9480 (0.1375)	0.8937 (0.1121)	0.8987 (0.1038)	0.9720 (0.1021)	0.9259 (0.0799)
	RNN	0.6643 (0.1784)	0.8560 (0.1745)	0.7332 (0.1430)	0.6208 (0.2545)	0.7180 (0.2758)	0.6455 (0.2297)
Recent 2 quarters	LR	0.7654 (0.1644)	0.8760 (0.1517)	0.7981 (0.1083)	0.8010 (0.1896)	0.8160 (0.1994)	0.7908 (0.1591)
	RF	0.8843 (0.1216)	0.9820 (0.0805)	0.9239 (0.0821)	0.8876 (0.1195)	0.9760 (0.0907)	0.9235 (0.0868)
	RNN	0.7687 (0.1495)	0.8860 (0.1273)	0.8067 (0.0873)	0.7602 (0.1597)	0.8760 (0.1226)	0.7966 (0.0903)
Recent 3 quarters	LR	0.8384 (0.1548)	0.8860 (0.1241)	0.8498 (0.1044)	0.8050 (0.1908)	0.7640 (0.2390)	0.7558 (0.1854)
	RF	0.8722 (0.1382)	0.9800 (0.0775)	0.9152 (0.0923)	0.8761 (0.1367)	0.9760 (0.1106)	0.9127 (0.1095)
	RNN	0.8456 (0.1542)	0.9540 (0.0974)	0.8877 (0.1067)	0.8863 (0.1304)	1.0000 (0.0000)	0.9344 (0.0770)
Recent 4 quarters	LR	0.8378 (0.1309)	0.9420 (0.1142)	0.8774 (0.0951)	0.8152 (0.1840)	0.7820 (0.2515)	0.7679 (0.1930)
	RF	0.8729 (0.1434)	0.9660 (0.1358)	0.9042 (0.1249)	0.8733 (0.1404)	0.9600 (0.1575)	0.8971 (0.1380)
	RNN	0.8150 (0.1384)	0.9940 (0.0597)	0.8885 (0.0937)	0.8412 (0.1355)	0.9960 (0.0280)	0.9061 (0.0829)

Table 10. Model Performance Evaluation(Unstructured Only)

		Unstructured Only		
		Precision	Recall	F1
Recent 1 quarter	LR	0.6319 (0.2016)	0.6820 (0.2655)	0.6296 (0.1981)
	RF	0.4324 (0.3091)	0.2920 (0.2008)	0.3263 (0.2140)
	RNN	0.4586 (0.2210)	0.5620 (0.2824)	0.4849 (0.2133)
Recent 2 quarters	LR	0.7092 (0.2102)	0.6300 (0.2504)	0.6383 (0.1913)
	RF	0.5325 (0.3037)	0.3600 (0.2191)	0.3958 (0.2022)
	RNN	0.6072 (0.2295)	0.6520 (0.2343)	0.6039 (0.1934)
Recent 3 quarters	LR	0.6941 (0.2438)	0.5720 (0.2400)	0.5995 (0.2008)
	RF	0.6023 (0.3314)	0.3540 (0.2076)	0.4102 (0.2091)
	RNN	0.6538 (0.2201)	0.7680 (0.2222)	0.6821 (0.1809)
Recent 4 quarters	LR	0.7270 (0.2468)	0.5480 (0.2238)	0.5952 (0.1906)
	RF	0.5857 (0.3515)	0.3340 (0.2041)	0.3832 (0.2006)
	RNN	0.6786 (0.1793)	0.8480 (0.1792)	0.7360 (0.1416)

5.2 텍스트 데이터와 예측 성능의 관계

<Table 11>은 가장 좋은 성능을 보여준 환경(순환 신경망에서 이전 3분기까지의 정형 데이터와 비정형 데이터를 쓴 환경)에 대한 자세한 결과물이다. 본 연구에서는 100개의 샘플을 통해 실험 결과를 도출했으며 <Table 11>은 그중 무작위로 20개의 샘플을 뽑아 정형, 비정형, 정형+비정형 데이터를 이용한

세 경우에 대한 성능을 기록한 것이다. 모든 경우에서 비정형 데이터를 함께 사용한 경우가 정형 데이터만 사용한 경우보다 성능이 더 높거나 같다. 성능이 더 높은 경우 굵은 글씨로 강조했으며 이례적으로 94번 실험의 경우는 정형 데이터만을 이용해서 가장 높은 성능을 보여주고 있다. 해당 실험의 결과물은 정형 데이터와 비정형 데이터 각각의 이점을 잘 조합할 수 있는 알고리즘의 필요성을 시사하고 있다.

Table 11. Model Performance Evaluation(RNN, Recent 3 Quarters)

Index(1~100) (Randomly Selected)	F1-Score		
	Structured Only	Unstructured Only	Structured & Unstructured
27	0.9091	0.9091	0.9091
87	0.8333	0.8000	0.9091
3	0.7143	0.6154	0.7143
56	1.0000	0.9091	1.0000
76	1.0000	0.4615	1.0000
94	0.8000	1.0000	0.9091
17	0.7273	0.6000	0.8333
74	0.7273	0.6667	0.8333
55	0.8333	0.6667	0.8333
96	0.8333	0.2500	0.9091
54	1.0000	0.9091	1.0000
93	0.7273	0.6667	0.9091
79	1.0000	0.5000	1.0000
14	0.9091	0.6250	1.0000
8	0.9091	0.8000	1.0000
31	0.8889	0.6667	1.0000
23	1.0000	1.0000	1.0000
25	1.0000	0.5000	1.0000
34	1.0000	0.8333	1.0000
9	0.8889	0.8889	1.0000

5.3 학습 기간과 예측 성능의 관계

모든 모형은 공통적으로 일정 수준까지 과거의 정보가 더해질수록 성능향상을 보이며, 특정 시점 이상부터 그 양상이 역전된다. 이는 분석에 이용되는 정보가 과거의 것일수록 그 시의성이 하락한다는 점을 시사한다. 설명 변수의 수집 시점이 예측 시점과 관련성이 없을 정도로 과거일 경우 모형은 과거 변수에 과적합(over-fitting) 될 확률이 높아지고 검증 데이터에 대한 성능이 하락했다.

대체로 정형 데이터보다 비정형 텍스트 데이터의 시의성이 더 빨리 감소하는 것으로 보인다. 정형 데이터의 경우 대체로 직전 4분기부터 과거 정보가 추가될 때 모델 성능이 하락하지만 비정형 데이터를 함께 사용한 경우는 이보다 앞선 3분기부터 모형의 성능이 하락하기도 한다. 조기 경보 모형에서 예측 대상이 되는 목적 변수는 현재로부터 2분기 이후이기 때문에 현재의 직전 3분기 데이터는 5분기, 즉 1년이 넘는 과거의 정보이며 이를 통해 1년 정도의 과거 텍스트 데이터는 미래 예측에 유용하지 않다는 사실을 알 수 있다. 외적으로 <Table 9>에서 순환 신경망 모형을 사용할 경우 모형이 고려하는 기간이 길어질수록 성능이 향상되는 현상을 관찰할 수 있다. 이는 순환 신경망 특성상 비정형 데이터의 문맥 정보를 더 파악할 수 있고 필요 없는 정보를 최적화 과정에서 무시할 수 있기 때문이다.

6. 결론 및 활용방안

본 연구는 실제 감독기관에서 부실은행 예측에 이용하는 설명 변수와 은행 관련 텍스트 데이터를 이용해 예측 모형의 성능 향상을 시도했다. 수집된 데이터는 2001년부터 2017년까지 35 종류의 재무 정보로 이루어진 901개의 관측치와 실제 은행과 매칭되는 민원 문서, 그리고 296,174개의 뉴스 기사이다.

비정형 텍스트 데이터들은 두 가지 텍스트 마이닝 기법을 통해 시점당 160차원의 벡터값으로 차원 축소가 진행되었다. 이후 다른 장단점을 가지는 세 가지 알고리즘의 조기 경보 모형을 구축하고 세 개의 평가지표를 통해 실험 결과를 해석하였다. 연구 결과 텍스트 정보는 적절한 시의성과 알고리즘을 충족하는 경우 부실은행 예측에 유의미한 설명 변수가 될 수 있음을 확인했다. 이는 주식시장 등 다른 도메인에서 텍스트 정보를 적용한 연구와 비슷한 결과이다.

본 연구의 적용 분야는 다른 도메인과 비교해 정형 데이터의 양이 부족하다. 은행 및 금융 기업들의 위험 정도를 평가하기 위한 주요 재무 데이터는 감독기관과 기업 간의 복잡한 관계로 인해 그 종류와 수집량을 늘리는 것이 쉽지 않다. 이에 더해 과거 부실은행이 발생한 경우가 한국의 주요 금융위기 외에는 거의 없어 데이터의 기록 양이 많더라도 범주 불균형으로 인한 문제가 존재한다. 금융 기업의 위기에측은 그 여건상 다양한 어려움이 존재하지만 본 연구는 기존의 약점을 극복하는 새로운 변수의 도입이 예측의 성능을 개선할 수 있음을 시사하고 있다.

조기 경보 모형은 이후로도 많은 고도화가 필요하다. 본 연구에서는 은행과 직접 관련이 있는 텍스트 정보만을 이용했으나 컴퓨팅 자원이 풍부하다면 경제 분야의 모든 기사를 수집하고 더 고도화된 텍스트 마이닝을 적용해 데이터의 질을 높일 수 있다. 조기경보 모형의 알고리즘도 데이터 성질에 따라 유연하게 발전할 수 있다. 본 연구는 실험을 통해 알고리즘마다 서로 다른 강점을 가진다는 사실을 확인했다. 따라서 관측 시점과 변수의 종류가 상대적으로 적은 정형 데이터에 대해 복잡도가 낮은 모델을 적용하며, 압도적으로 관측치와 차원 수가 많은 텍스트 데이터에 대해서 복잡도가 높은 모형을 적용 후, 두 결과를 취합하는 모형의 결합을 고려할 수도 있다.

참고문헌

- Altman, E. I. (1968), Financial ratios, discriminant analysis and the prediction of corporate bankruptcy, *The Journal of Finance*, **23**(4), 589-609.
- Andrychowicz, M., Denil, M., Gomez, S., Hoffman, M. W., Pfau, D., Schaul, T., Shillingford, B., and De Freitas, N. (2016), Learning to learn by gradient descent by gradient descent, *In Advances in Neural Information Processing Systems*, 3981-3989.
- Blei, D. M. (2012), Probabilistic topic models, *Communications of the ACM*, **55**(4), 77-84.
- Breiman, L. (2001), Random forests, *Machine Learning*, **45**(1), 5-32.
- Campbell, J. Y., Hilscher, J., and Szilagyi, J. (2008), In search of distress risk, *The Journal of Finance*, **63**(6), 2899-2939.
- Chalmers, D. (2010), The singularity : A philosophical analysis, *Journal of Consciousness Studies*, **17**(9-10), 7-65.
- Cho, S., Kim, B., Park, M., Lee, G., and Kang, P. (2017), Extraction of Satisfaction Factors and Evaluation of Tourist Attractions based on Travel Site Review Comments, *Journal of the Korean Institute of Industrial Engineers*, **43**(1), 62-71.
- Choi, S. and Oh, H. (2010), An analysis on the bank conditions and fundamentals that explain bank failures during financial crisis in East Asia, *Journal of Industrial Economics and Business*, **23**(1), 547-561.
- Christofides, C., Eicher, T. S., and Papageorgiou, C. (2016), Did established Early Warning Signals predict the 2008 crises?, *European Economic Review*, **81**, 103-114.
- Dowd, K. (2009), Moral hazard and the financial crisis, *Cato Journal*, **29**, 141.
- Hochreiter, S. and Schmidhuber, J. (1997), Long short-term memory, *Neural Computation*, **9**(8), 1735-1780.
- Holton, G. A. (2004), Defining risk, *Financial Analysts Journal*, **60**(6), 19-25.
- Jarrow, R. A. and Turnbull, S. M. (1995), Pricing derivatives on financial securities subject to credit risk, *The Journal of Finance*, **50**(1), 53-85.
- Jeong, J., Mo, K., Seo, S., Kim, C., Kim, H., and Kang, P. (2018), Un-supervised Document Multi-Category Weight Extraction based on Word Embedding and Word Network Analysis : A Case Study on Mobile Phone Reviews, *Journal of the Korean Institute of Industrial Engineers*, **44**(6), 442-451.
- Kim, H. and Baek, J. (2012), Performance evaluation and forecasting model for financial institution : A study on credit union institutions in Korea, *Korean Journal of Financial Studies*, **41**(1), 41-91.
- Kim, Y. B., Lee, J., Park, N., Choo, J., Kim, J. H., and Kim, C. H. (2017), When Bitcoin encounters information in an online forum : Using text mining to analyse user opinions and predict value fluctuation, *PLoS One*, **12**(5), e0177630.
- Le, Q. and Mikolov, T. (2014), Distributed representations of sentences and documents, *In Proceedings of the International Conference on Machine Learning*, 1188-1196.
- Lee, H. (2015), Early warning system for financial crisis, Collection of research papers and materials on development issues.
- Lipton, Z. C., Berkowitz, J., and Elkan, C. (2015), A critical review of recurrent neural networks for sequence learning, *arXiv preprint*, arXiv:1506.00019.
- Luo, C., Li, M., Peng, P., and Fan, S. (2018), How does Internet finance influence the interest rate? Evidence from Chinese financial markets, *Dutch Journal of Finance and Management*, **2**(1), 01.
- Malecki, E. J. (1997), Technology and economic development : the dynamics of local, regional, and national change.
- McQuown, J. A. (1993), A comment on market vs. accounting based measures of default risk, mimeo, KMV Corporation.
- Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., and Dean, J. (2013), Distributed representations of words and phrases and their compositionality, *In Advances in neural information processing systems*, 3111-3119.
- Mittermayer, M. A. (2004), Forecasting intraday stock price trends with text mining techniques, *In Proceedings of the 37th annual hawaii international conference on System Science*.
- Ohlson, J. (1980), Financial ratios and probabilistic prediction of bankruptcy,

- Journal of Accounting Research*, **18**(1), 109-131.
- Shumway, T. (2001), Forecasting bankruptcy more accurately : A simple hazard model, *The Journal of Business*, **74**(1), 101-124.
- Tinoco, M. H. and Wilson, N. (2013), Financial distress and bankruptcy prediction among listed companies using accounting, market and macroeconomic variables, *International Review of Financial Analysis*, **30**, 394-419.
- Zhu, Y., Zhong, N., and Xiong, Y. (2009), Data explosion, data nature and dataology, In *Proceedings of the International Conference on Brain Informatics*, 147-158.

저자소개

송서하 : 고려대학교 산업경영공학부에서 2017년 학사학위를 취득하였다. 현재는 고려대학교 산업경영공학부에서 석사과정으로 재학 중이다. 연구 분야는 자연어 처리 및 심층신경망이다.

김준홍 : 서울과학기술대학교 글로벌융합산업공학과에서 2014년 학사학위를 취득하고, 서울과학기술대학교 데이터 사이언스 학과에서 2016년 석사학위를 취득하였다. 현재는 고려대학교

산업경영공학부에서 박사과정으로 재학 중이다. 연구 분야는 정형 및 비정형 데이터를 활용한 기계학습 알고리즘 개발 및 응용이다.

김형석 : 단국대학교 통계학과에서 2015년 학사학위를 취득했다. 현재는 고려대학교 산업경영공학부에서 박사과정으로 재학 중이다. 연구 분야는 자연어 처리 및 데이터 마이닝이다.

박재선 : 고려대학교 수학과에서 2016년 학사학위를 취득하고, 고려대학교 산업경영공학부에서 2018년 석사학위를 취득하였다. 연구 분야는 Multimodal 심층신경망이다.

강필성 : 서울대학교 산업공학과에서 2003년 학사, 2010년 박사학위를 취득하였다. 이후 현대카드 과장, 서울과학기술대학교 조교수로 근무하였으며, 현재는 고려대학교 산업경영공학부 부교수로 재직 중이다. 연구 분야는 정형 및 비정형 데이터를 활용한 데이터마이닝 및 기계학습 알고리즘 개발 및 제조/IT/공공분야 응용이다.