

이 논문은 기업부실예측을 위한 조기경보가 아님.

금융위기 예측을 위한 조기경보임.

그러나 한국은행에서 발행한 논문이기에, 어떤 흐름대로 조기경보시스템을 만드는지 참고할 수 있어서 이 논문을 읽는 것을 추천함.

제 2024-11호

BANK OF KOREA

BOK 이슈노트

데이터 기반 금융 · 외환 조기경보모형



김태완

한국은행 금융결제국
디지털화폐기술1팀 차장
Tel. 02-750-6606
kimtwan@bok.or.kr

박정희

한국은행 디지털혁신실
디지털신기술팀 과장
Tel. 02-759-4674
positive@bok.or.kr

이현창

한국은행 디지털혁신실
디지털신기술팀 팀장
Tel. 02-759-4869
hyunchang.yi@bok.or.kr

2024년 4월 24일

금융 · 외환위기는 가계 · 기업 부문의 과도한 레버리지, 단기 · 외화부채 비중 상승 등 금융시스템내 취약성이 누적된 가운데, 경제 여건 변화나 특정 이벤트로 촉발(트리거)된 시장불안이 경제 전반의 자산가격 하락 및 디레버리징으로 확산되면서 발생한다. 이러한 위기가 발생하면 금융시스템의 가격발견 및 자원배분 기능이 정상적으로 수행되지 못하고, 실물 경제는 장기간 극심한 침체를 겪게 될 수 있다. 1990년대 이후 이러한 위기 발생을 조기에 경보하는 다양한 모형이 제안되었으나, 위기 발생 메커니즘(취약성 · 트리거 변수 간 상호작용)의 복잡성, 데이터 부족 등은 신뢰할 수 있는 조기경보 모형 개발을 제약하는 요인이 되어왔다.

본 연구는 우리나라 금융 · 외환위기 또는 시장불안을 조기경보하는 신뢰할 수 있는 모형을 개발하고자 하였다. 먼저, 은행, 채권 · 주식, 외환 등 부문별 시장불안을 반영할 수 있는 복합금융압력지수(CFPI, Composite Financial Pressure Index)를 정의하고 1997년 7월 이후 발생한 위기 및 시장불안 이벤트를 식별하였다. 또한, 위기 발생 메커니즘을 포착할 수 있는 AI/ML 알고리즘을 활용하고, 조기경보모형에 적합한 모형 검증 기법을 적용하여 모형의 표본외 예측력을 엄밀히 평가하였다.

테스트 결과, 대표적 ML 알고리즘인 ET (Extremely randomized

Trees)를 적용한 조기경보모형이 가장 높은 예측력(0.95, ROC-AUC 기준)을 나타냈다. 이는 1990년대 이후 조기경보모형으로 널리 활용되어온 신호추출법의 예측력(0.84)에 비해 개선된 것으로 평가된다. 그리고, 과거 위기 및 시장불안 이벤트를 대상으로 조기경보 모형의 유효성을 점검한 결과, 이벤트 발생 3~6개월 전까지는 위기 발생 가능성을 경보하는 지수(경보 지수)가 0.1 이하로 낮은 수준을 보이다가 점차 높아져 이벤트 발생 직전 0.4~0.6을 상회하는 모습을 보였다. 아울러, 동 조기경보모형을 통해, 취약성 · 트리거 변수와 위기 발생 가능성 간 비선형, 상호의존적 관계도 확인할 수 있었다.

조기경보모형은 주기적으로 입수되는 경제 · 금융지표를 이용하여 향후 위기 발생 가능성을 정량적으로 나타내지만, 구체적으로 어느 부문에서 취약성이 축적되고 어떤 트리거 이벤트가 시장불안을 촉발하는지에 대한 정보는 제공하지 못한다. 이를 위해서는 IMF의 EWE (Early Warning Exercise)와 같이 조기경보모형뿐만 아니라 전문가 서베이를 통한 금융 · 실물경제 리스크 요인 식별, 부문별 취약성 평가 등을 포괄하는 조기경보체계(EWS, Early Warning System)로 발전시켜 나갈 필요가 있다. 본 연구에서 제안한 조기경보모형은 아직 여러 측면에서 개선할 점이 많으나, 향후 보다 종합적인 조기경보체계 개발로 이어지는 계기가 되기를 기대한다.

- 본 자료의 내용은 한국은행의 공식견해가 아니라 집필자 개인의 견해라는 점을 밝힙니다.

따라서 본 자료의 내용을 보도하거나 인용할 경우에는 집필자명을 반드시 명시하여 주시기 바랍니다.

- 본고의 작성 과정에서 큰 도움을 주신 홍원석 디지털혁신실장, 임광구 금융안정국 안정총괄팀장, 박병걸 국제국 국제금융연구팀장, 김권식 국제금융센터 조기모형부장, 행내 세미나에 참석하여 귀중한 의견을 주신 세미나 참석자분들께 감사드립니다. 그리고 원고 심사 과정에서 유익한 의견을 주신 금융안정국 시스템리스크팀 김민수 차장, 국제국 국제총괄팀 조유정 과장께 감사드립니다.



한국은행

1. 머리말

일반적으로 금융·외환위기는 자산가격 상승과 함께 나타나는 기업·가계 부문의 과도한 레버리지, 금융기관의 외화 및 단기성 자금 조달 비중 상승 등으로 금융시스템의 취약성(vulnerability)이 높아진 가운데, 경제 불확실성 확대나 긴축적 금융여건으로 촉발(트리거)된 시장불안(market stress)이 경제 전반의 자산가격 하락 및 디레버리징으로 확산되면서 발생한다. 이러한 위기가 발생하면, 금융시스템의 가격발견 및 자원배분 기능이 정상적으로 수행되지 못하고, 실물 경제도 장기간 극심한 침체를 겪게 될 수 있다.

이러한 위기 발생을 조기경보하는 모형은 정책 대응의 적시성을 높이고, 금융시스템의 취약 부문을 파악함으로써 위기 발생 가능성을 완화하는 데 활용될 수 있다. 이러한 역할을 조기경보모형이 효과적으로 수행하기 위해서는 모형에 대한 정책결정자의 신뢰를 확보함과 동시에, 위기 발생 가능성에 대한 평가 결과를 요인별로 설명할 수 있어야 한다. 예를 들어, 모형의 정보가 외환시장이나 주식시장의 변동성 확대에 인한 것인지, 기업 부문의 부채 누증에 의한 것인지 등에 대한 판단에 따라 요구되는 정책 수단도 달라지게 된다.

조기경보모형 관련 연구는 1990년대 남미와 동아시아에 발생한 신흥국 금융·외환위기, 2000년대 글로벌 금융위기, 2010년대 유럽 재정위기 등을 거치며 발전해왔다. 초기 조기경보모형으로는 1990년대말 제안된 신호추출법(signal extraction)이 대표적이다. 신호추출법에서는 주요 경제·금융 지표를 10개 내외로 선별한 다음, 사전 설정한 임계점

(threshold)을 상회하는 지표 개수가 많을수록 위기 발생 가능성이 높은 것으로 평가하는 다소 단순한 방법이다. 또한, 로짓(logit)·프로빗(probit) 모형도 조기경보모형으로 초기부터 활용되었다. 로짓·프로빗 모형은 선형회귀모형과 같이 경제·금융 지표를 선형결합하여 위기 발생 가능성을 평가하며, 0과 1 사이의 결과값을 위기 발생 확률로 해석할 수 있다는 장점이 있다. 이 외에 금융시스템의 취약성 수준이 높을수록 위기 발생 가능성이 높다는 사실을 명시적으로 고려한 모형도 제안되었다. 마코프 전환(Markov switching) 모형은 취약성 수준을 경기·금융 사이클 국면으로 구분하고, 동 국면을 위기 발생 가능성 평가에 활용한다.

그러나, 위기 조기경보모형은 예측 대상 이벤트의 발생 빈도가 낮아 여타 경제·금융 변수에 비해 예측력을 엄밀하게 평가하기 어렵다. 이는 모형에 대한 정책결정자의 신뢰를 확보하는 데도 제약으로 작용한다. 또한, 경제 내 여러 취약성 및 트리거 변수 간 상호작용(위기 발생 메커니즘)을 고려할 때, 변수 간 비선형·상호의존적 관계를 고려하지 않는 모형은 데이터에 내재한 위기 관련 정보를 제대로 평가하는 데 한계가 있다.

본 연구는 앞서 언급한 이슈를 고려하여 예측 결과를 신뢰할 수 있고, 정책 대응에도 활용할 수 있는 조기경보모형을 구축하는 데 필요한 여러 방법론을 제시하고자 하였다. 먼저, 은행, 채권·주식, 외환 등 부문별 시장불안을 반영할 수 있는 복합금융압력지수(CFPI, Composite Financial Pressure Index)를 정의하고 1997년 7월 이후 발생한 위기 및 시장불안 이벤트를 식별하였다. 다음으로, 기계

학습(ML, Machine Learning) 모형 개발에서 주로 활용되는 검증 기법을 적용하여, 조기정보모형의 표본외 예측력을 엄밀하게 평가함으로써 예측 결과에 대한 신뢰성을 높이도록 하였다. 또한, 복합적인 위기 발생 메커니즘을 반영할 수 있도록 다양한 ML 알고리즘을 테스트하였다. 마지막으로, 조기정보모형에 의한 위기 발생 가능성을 부문별 취약성 및 트리거 요인으로 분해하였다. 이를 통해, 현재 경제·금융 상황을 파악하고, 효과적인 정책 대응에 활용할 수 있도록 하였다.

한편, 하나의 조기정보모형만으로는 위기 발생 또는 시장불안을 방지하고, 거시경제·금융 안정을 달성하는 데 충분하지 않다. 글로벌 금융위기 이후 IMF와 금융안정위원회(FSB, Financial Stability Board)는 EWE(Early Warning Exercise)를 통해 금융·실물경제 각 부문의 리스크 요인을 식별하는 전문가 서베이, 위기 발생 가능성에 대한 정량(quantitative) 및 정성(qualitative) 평가, 국가별 리스크 평가 등을 순차적으로 수행하는 체계를 마련하였다. 본 연구에서 제안하는 조기정보모형도 위기와 관련한 다양한 유형·원천의 정보와 평가가 유기적으로 결합되는 EWS(Early Warning System)의 한 구성요소로 포함될 때 제 역할을 다 할 수 있을 것이다.

본고의 구성은 다음과 같다. II절은 금융·외환위기 및 조기정보모형 관련 기존 연구를 살펴보고, III절은 본 연구의 조기정보모형 개발 방향에 대해 설명한다. IV절은 조기정보모형에 활용되는 데이터와 모형을 소개하고, 조기정보모형의 표본외 예측력 검증 방법을 설명

한다. 마지막으로 V절에서 조기정보모형 개발 결과를 평가하고, VI절에서 본 연구의 시사점을 정리한다.

II. 기존 연구

1994년 남미, 1997~98년 동아시아 등 신흥국에서 금융·외환위기가 연이어 발생하면서 금융 불안정성이 실물경제 위축으로 확산되고 경제 전반에 막대한 손실을 초래할 수 있다는 인식이 확산되었다. 이에 개별 경제·금융 지표를 모니터링하는 단계에서 나아가 위기 발생을 사전 경보할 수 있는 조기정보모형에 대한 관심이 높아졌으며, 이들 연구는 주로 신호추출법, 로짓·프로빗, 마코프 국면전환 등의 모형으로 전개되었다.

신호추출법은 변수의 확률 분포에 대한 특별한 가정 없이 위기 발생과 관련성이 높은 경제·금융 변수가 사전 설정한 임계치를 넘는지 여부에서 위기 정보를 추출하는 비모수적(non-parametric) 방법이다. 각 변수에 대해 과거 데이터를 기반으로 예측력¹⁾을 극대화하는 최적의 임계치를 찾고, 변수별 예측력에 따라 가중평균하여 최종 결과를 산출한다. 신호추출법을 이용한 초기 연구로는 Kaminsky et al. (1998), Kaminsky and Reinhart (1999), Goldstein et al. (2000) 등이 대표적이다. Kaminsky et al. (1998)은 여러 국가의 통화위기(currency crisis)를, Kaminsky and Reinhart (1999)는 은행위기(banking crisis)와 국제수지위기

1) 각 변수의 예측력은 NSR(Noise-to-Signal Ratio)의 역수로 계산되며, NSR은 신호(1-1종 오류) 대비 노이즈(2종 오류) 비율을 의미한다. 1종 오류 및 2종 오류에 대한 자세한 정의는 IV절(데이터와 모형)의 예측력 평가 방법을 참고하기 바란다.

(balance of payments crisis)가 동시에 발생하는 쌍둥이위기(twin crises)를 분석하고 위기 발생 전 나타나는 선행지표를 식별하였다. Goldstein et al. (2000)은 신흥국의 금융취약성을 평가하고 위기 발생 가능성을 평가하는 조기경보시스템을 제안하였다.²⁾

위기 발생 가능성에 대한 확률적 평가를 통해 조기경보모형의 예측력을 개선하기 위한 노력도 이어졌다.³⁾ 로짓 모형과 프로빗 모형은 각각 예측변수의 선형결합에 로지스틱 함수와 정규분포의 누적분포함수를 적용하여 위기 발생 가능성을 0과 1 사이의 값으로 평가한다. 보다 구체적으로는 한 국가의 외환보유액, 금리·환율, 경제성장률 등(예측변수)이 금융위기 발생 여부(0 또는 1의 값을 가지는 종속변수)에 미치는 영향을 추정하는 모수적(parametric) 방법론이라고 할 수 있다. 대표적인 연구로는 프로빗 모형을 이용하여 신흥국의 통화위기 발생 확률을 분석한 Frankel and Rose (1996)와 Berg and Pattillo (1999), 로짓 모형을 이용하여 신흥국의 은행위기 발생 확률을 분석한 Demirgüç-Kunt and Detragiache (1998) 등이 있다.

그러나, 신호추출법과 로짓·프로빗 모형에서는 각 변수 값이 개별적으로 위기 발생 가능성을 나타내므로, 변수 간 상호작용으로 위기가 발생하는 메커니즘을 고려할 수 없다. 이에 대안으로 제안된 마코프 전환 모형은 시간

에 따라 전환되는 국면(regime)에 따라 변수 간 관계가 달라지는 것으로 가정한다.⁴⁾ Abiad (2003)는 아시아 국가를 대상으로 전체 시계열을 정상과 위기 국면으로 구분하고 통화위기 발생 가능성을 평가함으로써 기존 방법론보다 예측력 높은 조기경보모형을 개발하였다고 주장하였다.

한편, 2000년대 들어 위기 예측보다 금융시스템 전반 또는 시스템 각 부문의 취약성을 판단할 수 있는 지수에 대한 관심이 높아졌다. Babihuga (2007)는 1998년에서 2005년까지 96개 국가의 패널 데이터를 사용하여 금융안정지수(FSI, Financial Stability Indicator)를 개발하였으며, Hawkins and Klau (2000)는 환율, 대출규모, 금융기관 신용등급 등 지표를 활용하여 은행 부문 및 대외 취약성을 평가하는 지수를 개발하였다. 이러한 연구는 다양한 경제·금융 지표를 함께 고려하여 각 부문별 위기를 복합적으로 판단할 수 있게 하였다. 또한 위기 정도를 계량화함으로써 리스크 상황에서 정책 당국이 효율적이고 정확한 의사 결정을 내리는 데 기여할 수 있는 것으로 평가된다.

이제까지 살펴본 조기경보모형들은 위기 발생 가능성이 높아지는 경우 경보를 울리는 목적으로 개발되었으나, 모형의 예측력을 어느 정도 신뢰할 수 있는지, 부문별 취약성·트리거 이벤트가 위기 발생 가능성에 미치는 영향이 어느 정도인지에 대한 정보는 제공하지

2) 신호추출법은 특정 확률 분포에 의존하지 않고 다양한 데이터를 활용할 수 있다는 장점으로 인해, 금융·외환위기 조기경보뿐만 아니라, 과도한 시장 변동성이나 시장불안과 같은 비정상 상황을 탐지하는 도구로 널리 활용되고 있다. 김명직 외(2011), 박원암(2011, 2017) 등이 신호추출법을 이용하여 우리나라 금융위기를 예측하는 연구를 수행하였으며, IMF (2021), 캐나다 중앙은행의 Christensen and Li (2014)는 금융시스템 취약성 분석에 신호추출법을 활용했다.

3) Furman and Stiglitz (1998), Berg and Pattillo (1999) 등은 Kaminsky et al. (1998)의 신호추출법이 아시아 위기 예측에 잘 작동하지 않는다고 지적하였다.

4) Hamilton (1989)은 경기 침체와 성장 국면의 전이(transition) 패턴을 마코프 프로세스로 모형화하였으며, 국민총생산(GNP) 성장률을 대상으로 실증 분석하였다.

못한다는 한계가 있다. 이러한 한계는 크게 두 가지 요인으로 설명할 수 있다. 첫째는 변수 간 선형관계를 가정한 기존 계량경제모형은 위기 발생 메커니즘을 반영하기 어렵다는 것이고, 둘째는 개별 국가 단위에서 과거 위기 발생 사례가 많지 않아 모형의 예측력을 엄밀히 평가하기 어렵다는 것이다.

영란은행의 Bluwstein et al. (2023)은 17개국 패널 데이터에 ML 알고리즘을 적용하여 금융위기 발생 메커니즘을 반영할 수 있는 조기경보모형을 개발하였다. 또한, 위기정보에 적합한 모형 검증 기법을 적용하여 모형의 표본외 예측력을 엄밀히 평가할 수 있도록 하였다.⁵⁾ 그러나, 위 연구는 데이터 부족 문제를 해결하기 위해 연간(annual) 단위로 수집된 국가 패널 데이터를 사용함에 따라 개별 국가 경제의 위기 발생 가능성을 상시 모니터링하는데 사용할 수 없다는 한계가 있다.⁶⁾ 이 외에 금융시스템 취약성 분석에 ML 알고리즘을 활용한 연구로 Suss and Treitel (2019), IMF (2021) 등이 있다. 특히, IMF (2021)는 1년 이내 시계에서 국가별 거시경제 위험을 식별하기 위해 국가 패널 데이터에 ML 알고리즘을 적용하였으며, 동 결과는 IMF의 EWE 체계내에서 국가별 취약성 평가(VE, Vulnerability Exercise)에 활용되고 있다.

2008년 글로벌 금융위기는 기존 신흥국이 경험한 위기와 다른 새로운 양상을 드러냈다. 글로벌 금융시장과 각 국가 간 연결을 통해 모든 국가가 금융위기 전이 가능성에 노출되어

있다는 자각하에 금융시스템의 취약성을 관리하기 위한 국제적인 노력이 강화되었다. 특히, G20은 IMF·FSB에 글로벌 금융위기와 같이 발생 가능성은 낮지만 글로벌 경제에 미치는 영향은 큰 리스크와 취약성을 평가할 수 있는 EWE를 함께 개발할 것을 요청했다. 반기단위로 수행되는 EWE는 위기 예측보다 특정 국가나 취약 부문에 대한 경고를 제공하는 것을 주요 목표로 삼고 있으며, 다양한 실증 분석과 전문가 서베이를 결합하여 취약점에 대한 분석, 정책 조언, 글로벌 정책 조율 등을 제공한다(IMF, 2010).⁷⁾

한편, 글로벌 금융위기는 위기 발생 메커니즘에 대한 관심을 촉발했다. Ghosh et al. (2009)은 다양한 취약 요인과 위험 촉발 사건(트리거)을 분석하여, 이 두 요소의 결합이 금융위기를 유발하는 메커니즘임을 강조하였다. Bernanke (2010)는 금융위기가 단순히 특정 사건에 의해서가 아니라, 금융시스템 및 규제, 감독의 구조적 약점 등 근본적인 취약점과 결합될 때 발생한다고 주장했다. 구체적으로는 글로벌 금융위기 당시, 주택가격 하락 후 드러난 서브프라임 모기지 부문 대규모 손실이 주요 트리거였지만, 금융시스템 취약성과 정부의 위기 대응 도구 부재가 글로벌 금융위기 발생의 결정적 배경임을 지적하였다. 국내에서는 이항용(2015)이 자산가격 과대평가, 금융기관 및 기업의 재무구조상 불일치, 자본 부족 등 경제내 취약성과, 교역조건 급변, 해외의 긴축 통화정책, 정치적 불안정성, 금융위기의 국제적

5) 조기경보모형 검증에 대한 보다 자세한 내용은 다음 III절(개발 방향)의 표본외 예측력 부문을 참고하기 바란다.

6) 국가별 연간 패널 데이터를 분석한 다른 연구로 Laeven and Valencia (2018), Jordà et al. (2019) 등이 있다.

7) EWE 수행 과정에서 IMF는 거시경제 및 거시금융 취약점을 분석하고, FSB는 금융 부문 취약점과 규제를 분석하여 국제통화금융위원회(IMFC)에 제출한다. 제출되는 보고서 중 조기경보목록(EWL, Early Warning List)에는 금융위기로 이어질 수 있는 주요 취약점들이 나열되고, 이에 대한 해결책과 정책 권장 사항이 포함된다.

전염 등 위기 촉발 사건이 어떻게 결합하여 금융위기를 일으키는지 분석하였다. 또한, 정영식 외(2023)는 과거 금융위기 사례를 통해 금융위기 발생 및 전개 양상을 분석하였다.⁸⁾

보모형을 개발하는 하나의 방안을 제시한 데 있다고 할 수 있다.

1. 조기경보 대상 이벤트 식별


여기서부터 읽기

III. 개발 방향

본 연구의 목적은 매월 입수되는 경제·금융지표를 활용하여 6개월 이내 시계에서 우리나라 위기 발생 가능성을 평가하고, 취약성·트리거 변수별 영향을 분해함으로써 선제적 정책 대응을 지원할 수 있는 조기경보모형을 구축하는 데 있다.⁹⁾ 이를 위해서는, 첫째 월 단위로 조기경보 대상 이벤트를 식별하고, 둘째 위기 발생 메커니즘을 반영할 수 있는 모형을 활용하고, 셋째 모형의 표본의 예측력을 엄밀히 평가하는 것이 필수적이다. 본 연구의 기여는 이들 요소를 적절히 결합하여 신뢰할 수 있는 조기경

보모형을 구축하기 위해서는 경보 대상 이벤트가 명확히 정의되어야 한다. 그러나 금융·외환위기는 경제내 취약 부문 및 트리거 유형에 따라 서로 다른 양상을 나타낸다. 또한, 조기경보 대상 이벤트가 실제 위기로 이어진 것인지 아니면 시장불안에 불과한지에 대한 컨센서스가 형성되기 어렵고, 그 위기가 언제 시작되었는지 특정하기도 어렵다. 이에 본 연구는 Cardarelli et al. (2009)을 참고하여 은행, 채권·주식, 외환 등 부문별 압력지수로 구성된 복합금융압력지수(CFPI, Composite Financial Pressure Index)를 정의하고 조기경보 대상 이벤트를 식별하였다(아래 <식 1>).¹⁰⁾ 구체적으로, CFPI의

<그림 1> 복합금융압력지수(CFPI) 추이



주: 가로 점선은 CFPI의 1표준편차, 음영은 CFPI가 1표준편차를 상회한 시장불안(market stress) 기간을 표시한다. 세로 점선은 GDP 성장률(전기 대비)이 지난 4분기 평균보다 1표준편차 이상 하락한 시점을 나타낸다.

8) 나성오 외(2020)는 우리나라 데이터를 이용하여 중장기 시계에서 경제·금융 취약성이 실물경제에 미친 영향을 분석하였다. 주요 금융·외환위기 발생시 경제·금융시스템 취약성과 트리거 요인에 대해서는 <부록 1>을 참고하기 바란다. 참고로, 우리나라의 주요 시장별 위기경보 기관은 아래와 같다(Lee and Lee, 2014).

부문	외환	금융	석유	원자재	노동	부동산
기관	국제금융센터	금융위원회·금융감독원	한국석유공사	산업연구원	노동연구원	국토연구원

9) 3개월, 6개월, 9개월, 12개월 이내 시계에서 위기 발생 가능성을 평가하는 모형을 각각 테스트한 결과, 6개월 및 9개월 시계에서 위기 발생을 사전경보하는 모형이 가장 높은 예측력을 보였다. 본고는 6개월 시계를 중심으로 조기경보모형 개발 결과를 소개한다.

10) 본 연구는 비은행금융중개(non-bank financial intermediation)를 포함하지 않고 있다. 금융시스템내 비은행 부문 비중이 점차 높아지는 점을 고려할 때, 향후 CFPI 구성 및 취약성·트리거 변수로서 비은행 부문을 포함할 경우 조기경보모형의 유효성이 보다 제고될 것으로 기대한다.

1 표준편차를 임계값으로 하고 지수가 임계값을 상회하는 기간을 조기경보모형에서 예측 대상으로 식별하였다(아래 <그림 1>).

<식 1> 복합금융압력지수(CFPI)

○ 은행부문압력지수

= KRX 은행지수 변동성
+ CD스프레드 (CD수익률 - 통안증권 수익률)

○ 채권·주식부문압력지수

= KOSPI 지수 변동성
- KOSPI 지수 수익률(12개월 최대 하락폭)
- 기간프리미엄 (국채3년물 - 통안증권1년물)
+ 회사채 스프레드 (회사채AA - 국채3년)

○ 외환부문압력지수

= USD/KRW 환율 변동성


주: 각 부문별 변수를 표준화한 후 합산하여 CFPI를 산출했다.

CFPI로 식별된 기간은 1998년 외환위기, 2008년 글로벌 금융위기와 함께 2001년(IT 버블)과 2003년(카드사태), 2020년(코로나 팬데믹), 2022년(레고랜드 사태) 등 시장불안 이벤트를 포함한다. 1998년과 2008년 이외 기간들은 시장불안 정도나 거시경제적 영향을 고려할 때 조기경보 대상 이벤트로 포함하는 것이 적절한 지에 대해 이견이 있을 수 있다. 그러나, 시장불안이 금융시스템의 정상적인 기능이 저하된 상태를 의미하며, 이어지는 경제·금융 여건 변화에 따라 금융위기로 이어질 수도 있다는 점을 고려하여, 본 연구는 CFPI로 식별된 기간들을 모두 조기경보 대상으로 포함하였다.

2. 위기 발생 메커니즘

앞서 기존 연구에서 살펴본 것과 같이 금융위기는 금융시스템 취약성과 트리거 이벤트의 상호작용에 의해 발생한다. 취약성이 높은 경우 작은 충격도 위기로 확산될 수 있으며, 금융시스템 전반에 걸쳐 취약성이 높은 경우 위기가 확산되는 규모와 속도는 더욱 확대될 수 있다(아래 <그림 2> Type 1). 이와 달리, 시스템내 취약성이 크지 않은 경우에도 트리거가 되는 충격의 유형이나 강도에 따라 위기 발생 가능성은 크게 상승할 수 있다(<그림 2> Type 2).

<그림 2> 위기 발생 가능성 상승 유형



이는 위기 발생 가능성을 정확히 평가하기 위해서는 조기경보모형이 취약성 및 트리거 변수 간 상호의존적 관계를 반영할 수 있어야 함을 시사한다. 그러나, 신호추출법이나 로짓·프로빗 모형을 이용한 조기경보모형은 각 예측 변수에서 얻는 정보가 서로 독립적이라는 점에서 한계가 있다. 변수 간 관계가 국면에 따라 변화하는 마코프 전환 모형은 간접적이거나 어느 정도 변수 간 상호관계를 포착할 수 있다. 그러나, 마코프 전환 모형은 연구자가 사전에 가정한 방식으로만 각 변수들 간 관계를 포착하게 된다.

ML 알고리즘은 데이터에 내재한 패턴, 또는 변수 간 관계를 모형의 자체 알고리즘에 따라 포착한다. 대표적인 ML 알고리즘으로 정규화 회귀(regularized regression), SVM(Support Vector Machine), 트리 앙상블(tree-based ensemble), 인공신경망(ANN, Artificial Neural Network) 등이 있으며, 하이퍼파라미터 튜닝(hyperparameter tuning)을 통해 모형이 학습 데이터에 과소적합(underfitting)하거나 과적합(overfitting)하지 않도록 하여 표본외 예측력을 높이게 된다.¹¹⁾ ML 알고리즘 가운데, 정규화 회귀는 일반적인 선형회귀모형에 변수 선택이나 계수 축소를 위한 정규화(regularization 또는 penalization)가 적용된 것으로 변수 간 상호의존성을 반영하기 어렵지만, 트리 앙상블, 인공신경망 등은 의사결정나무(decision tree)나 다층적인(multi-layer) 변수 간 관계식과 비선형 함수 등을 통해 변수 간 상호관계를 포착하게 된다.

3. 표본외 예측력

모형의 표본외(out-of-sample) 예측력은 모형 개발에 활용된 표본 데이터가 아닌 앞으로 관찰될 새로운 데이터에서의 예측력을 의미한다. 다시 말해, 표본외 예측력은 개발이 완료된 예측모형의 실제 예측 성능을 의미한다. 그러나, 과거 관찰된 데이터를 이용하여 예측모형을 개발할 때 모형의 실제 표본외 예

측력을 계산할 수 없으므로, 다양한 모형 검증(model validation) 기법을 이용하여 간접적인 방식으로 모형의 표본외 예측력을 평가하게 된다. 이때 모형의 표본외 예측력을 엄밀히 평가하기 위해서는 모형 및 데이터 특성에 적합한 모형 검증 기법을 적용해야 한다.

표본외 예측력을 평가하는 간단한 방법은 전체 데이터를 A와 B 데이터셋으로 나눈 다음, A 데이터셋을 이용하여 모형을 학습하고 B 데이터셋을 대상으로 예측오차를 계산하여 평가하는 홀드아웃(hold-out) 검증이다.¹²⁾ 그러나, 이러한 방법은 전체 데이터의 일부만 모형 학습에 활용한다는 단점이 있다. 전체 데이터를 모두 활용하는 방법으로 K-fold 교차검증(cross-validation)이 있다. K-fold 교차검증에서는 전체 데이터 D 를 $D_1, D_2, \dots, D_K$ 와 같이 서로 크기가 같은 K 개 데이터셋(fold)으로 나눈 다음, hold-out 검증을 K 회 수행한다. 다시 말해, 각 k 에 대해 $D \setminus D_k$ (D 에서 D_k 를 제외한 데이터)를 학습 데이터로, D_k 를 평가 데이터로 하여 예측오차를 계산한 다음, K 개 예측오차를 평균하여 표본외 예측력을 평가하는 것이다. 이와 달리, 데이터 간 전후 순서가 중요한 시계열 데이터의 경우에는 walk-forward 검증이 보다 일반적이다. t 시점까지 입수된 데이터셋을 D_t 라고 할 때, walk-forward 검증에서는 각 시점 $\tau = t, t+1, \dots, T$ 에 대해 D_τ 를 이용하여 모형을 학습한 다음 $\tau+1$ 이후 시점을 대상으로 예측오차를 계산하고, 전체 예측오차를 평균하여 표본외

11) 일반적으로 ML 알고리즘의 하이퍼파라미터는 ML 모형의 자유도를 결정한다. 자유도가 높은 모형은 데이터에 내재한 크고 작은 패턴을 모두 학습하게 되는 반면, 자유도가 낮은 모형은 데이터에서 가장 두드러진 패턴만을 학습하게 된다. 샘플 데이터에는 관찰 시점에 관계없이 유효한 변수 간 관계(신호)와 샘플 데이터내에서만 고유한 관계(노이즈)가 서로 섞여 있다. 하이퍼파라미터 튜닝은 적절한 모형 자유도를 선택하여 샘플 데이터에서 신호에 해당하는 변수 간 관계만을 최대한 포착하도록 조정하는 과정을 의미한다. 하이퍼파라미터에 대한 보다 자세한 설명은 이창훈 외(2023)의 II절을 참고하기 바란다.

12) hold-out 검증은 각 관측치가 서로 독립적인 경우에 주로 적용된다. 일반적으로 전체 데이터중 20%에서 30% 정도를 평가 데이터로 활용한다.

예측력을 평가한다.

그러나, 조기경보모형의 경우 표본외 예측력 평가 방법을 결정할 때 2가지 요인을 추가적으로 고려해야 한다. 첫째는 동일한 금융·외환위기 기간에 속한 데이터 간 유사성이다. 예를 들어, 글로벌 금융위기 발생을 몇 개월 앞둔 2008년 3월과 4월의 취약성 및 트리거 변수는 서로 유사한 모습을 보일 것이다. 만약, 조기경보모형이 2008년 3월말 기준으로 6개월 이내 금융위기가 발생한다는 사실을 학습한다면, 2008년 4월말 기준으로 6개월 이내 금융위기 발생 가능성이 상당히 높은 것으로 예측하게 되며, 이는 모형의 표본외 예측력을 과대평가하게 된다.


둘째는 정상·위기 데이터 간 불균형이다. 조기경보모형이 신뢰를 얻기 위해서는 위기 발생 가능성이 낮을 때 높다고 예측하거나(1종 오류, false positive), 위기 발생 가능성이 높을 때 낮다고 예측하는(2종 오류, false negative) 오류가 적어야 한다. 이러한 2가지 오류를 줄이기 위해서는 학습 데이터와 평가 데이터가 정상 및 위기 기간을 고르게 포함하여 모형이 각 기간중 데이터 패턴을 충분히 학습하고 그 결과가 예측력 평가에 반영되어야 한다.

이러한 데이터 특성을 고려하여, 본 연구는 stratified group K-fold 교차검증 기법을 적용하여 조기경보모형의 표본외 예측력을 평가하였다.¹³⁾ 동 기법은 K-fold 교차검증을 수행하되, 정상·위기 데이터가 전체 fold에 최

대한 균등하게 배분되며(stratified), 동일한 위기 이벤트에 속한 데이터는 하나의 그룹으로 지정되어(group) 동일한 fold에 포함된다.

아래 <그림 3>은 stratified group K-fold 교차검증 과정에서 각 데이터가 어떻게 그룹으로 지정되는지 나타낸다. 그림을 보면 실선으로 표시된 CFPI가 임계점(가로 점선)을 2차례 상회한다(그룹 1의 3·4번 구간, 그룹 2의 3·4번 구간). 조기경보모형은 시장 불안 또는 위기를 일정 기간 앞서 정보하는 것이 목적이므로, 각 그룹의 3·4번 구간과 2번 구간도 조기경보모형의 예측 대상으로 식별된다. 또한, 각 그룹의 2번 구간 직전 기간과 4번 구간 직후 기간(각 그룹의 1·5번 구간)은 해당 그룹과 유사한 데이터 특성을 가질 수 있으므로 같은 그룹으로 지정한다. 이와 같이 구성된 각 그룹 데이터는 모형 검증 과정에서 항상 같은 fold에 속한다.¹⁴⁾

<그림 3> CFPI 식별 이벤트 그룹 지정 예시



주: 실선은 CFPI, 가로 점선은 CFPI의 1표준편차를 나타낸다.

13) 시계열 변수 전망모형의 표본외 예측력을 평가하는 경우 walk-forward 검증 기법을 적용하는 것이 일반적이다. 그러나, 조기경보모형의 경우 앞서 설명한 데이터 특성으로 인해 walk-forward 검증 기법을 적용할 경우 학습에 사용할 수 있는 데이터 규모가 극단적으로 축소되는 문제가 있다. 한편, 금융·외환위기는 각 이벤트마다 주요 취약성 부문 및 트리거 이벤트가 서로 다른 양상을 나타내므로 K-fold 교차검증을 하더라도 일반적인 시계열 데이터에 비해 표본외 예측력 과대 평가 문제가 작을 것으로 기대할 수 있다. Bluwstein et al. (2023)도 본 연구와 유사한 이유를 들어 group K-Fold 교차검증 기법을 적용하였다.

14) 조기경보모형은 위기 발생 가능성이 확대되는 기간을 정확히 식별하는 것이 중요하다. 이를 고려하여, 본 연구는 각 그룹의 4번 구간을 학습 및 평가 과정에서 제외하였다.

IV. 데이터와 모형

다음으로 조기경보모형에 활용된 우리나라 취약성 및 트리거 변수, ML 알고리즘, 예측력 평가 기준을 설명한다.

1. 데이터


우리나라의 취약성 및 트리거 변수는 1997년 7월부터 2024년 1월까지 기간을 대상으로 한국은행 금융안정보고서에 수록된 금융불안지수(FSI, Financial Stress Index)와 금융취약성지수(FVI, Financial Vulnerability Index), 국내외 관련 연구를 참고하여 구성하였다(〈부록 2〉 참고).¹⁵⁾

취약성 변수는 크게 레버리지, 자금조달, 자산가격 등 3개 부문으로 분류할 수 있다. 레버리지는 GDP 대비 기업·가계부채 비율과 은행 레버리지, 자금조달은 단기외채 비율과 은행 예대율, 자산가격은 주택매매가격지수로 구성된다(〈부록 1〉 부문별 변수 목록 참고). 아래 〈그림 4〉는 1999년 이후 부문별 취약성 변수 추이를 나타낸다. 취약성 변수는 시기에 따라 다르지만, 대체로 위기 또는 시장불안 이벤트에 앞서 지속적으로 상승하다가 이후 하락하는 모습을 보인다.

가계 및 기업 부문 레버리지를 보면, 가계 부문은 2003년(카드사태)과 2020년(팬데믹), 기업 부문은 2008년(글로벌 금융위기)과 2022년(레고랜드)을 지나면서 흐름이 바뀌

는 모습을 보였다. 은행 레버리지는 2001년(IT버블)과 2008년, 2022년, 은행 예대율은 2003년과 2008년, 단기외채 비율은 2003년과 2008년, 그리고 2022년을 전후하여 지속적인 상승세를 보이다 하락하였다.

〈그림 4〉 주요 취약성 변수 추이



주: 음영은 CFPI가 1표준편차를 상회한 시장불안(market stress) 기간을 표시하며, 세로 점선은 GDP 성장률(전기 대비)이 지난 4분기 평균보다 1표준편차 이상 하락한 시점을 나타낸다.


시장불안을 촉발하는 트리거 변수는 주요국의 긴축적 통화정책, 무역분쟁, 감염병 유행 등 이벤트에 의한 불확실성 확대 및 위험회피(risk off) 행태 등 다양한 이벤트와 밀접하게 연관되어 있다. 그러나, 이러한 이벤트는 계량하기 어렵고 매번 새로운 양상으로 나타나므로 조기경보모형의 예측변수로 포함하기 어렵다. 본 연구는 이러한 이벤트를 빠르게 반영하는 국내외 금융·외환시장의 가격변수를 트리거 변수로 활용하였다. 이들 변수로는 VIX, 원/

15) 한국은행 금융안정보고서에 수록된 두 지수 가운데 FVI는 취약성, FSI는 트리거 변수를 중심으로 구성되어 있다. 먼저 FVI는 금융불균형과 금융기관 복원력 두 부문으로 나누어 평가된다. 금융불균형은 다시 자산가격 부문 8개, 신용축적 부문 14개의 평가요소로 구성되어 있다. 자산가격은 부동산 부문 PIR (Price Income Ratio), 주식 부문 PER (Price Earning Ratio), 채권 부문 신용 스프레드 등으로, 신용축적은 가계 부문 DSR (Debt Service Ratio), 기업 부문 기업신용 증감률, 대외부채 증감률 등으로 구성된다. 금융기관 복원력은 은행 예대율, 증권 레버리지, 카드 레버리지, 생명보험회사 RBC (Risk Based Capital), 금융부문 총부채 증감률 등으로 구성된다. FSI는 금융시장, 대외, 실물, 은행, 비은행 부문의 세부 지표로 평가되며, KOSPI 변동성, 원/달러 변동성, 주택가격 변동성, 은행채 스프레드, 저축은행 연체율 등으로 구성된다.

달러 환율 변동성, 금리 스프레드 등이 있다
(〈부록 1〉 부문별 변수 목록 참고).

〈그림 5〉는 1999년 이후 트리거 변수 추이를 나타낸다. Bernanke (2010)가 지적한 바와 같이 트리거 변수는 단기내 빠르게 상승하며 사전에 예측하기 어려운 모습을 보인다.

〈그림 5〉 주요 트리거 변수 추이



주: 음영은 CFPI가 1표준편차를 상회한 시장불안(market stress) 기간을 표시하며, 세로 점선은 GDP 성장률(전기 대비)이 지난 4분기 평균보다 1표준편차 이상 하락한 시점을 나타낸다.

조기경보모형은 이러한 취약성 및 트리거 변수를 예측변수로 하여, 6개월 이내 시계에서 금융·외환위기 또는 시장불안 이벤트가 발생하는지 예측한다. 또한, 데이터의 공표시차를 고려하여 매월 말일을 기준으로 입수가 가능한 예측변수를 사용한다. 이를 위한 조기경보모형 학습 데이터는 다음과 같이 구성한다. 먼저, 매월 말일을 기준으로 각 취약성 및 트리거 변수의 가장 최근값을 예측변수로 한다. 예를 들어, VIX와 같이 매일 입수되는 값은 기준월 평

균값을 이용하고, GDP 성장률과 같이 공표주기가 분기이고 공표시차가 있는 경우에는 속보치를 기준으로 가장 최근 공표된 값을 이용한다.¹⁶⁾ 조기경보모형의 예측 대상이 되는 타겟 변수(종속변수)는 예측시점을 기준으로 6개월 이내에 CFPI 식별 이벤트가 포함된 경우 1의 값을, 그렇지 않은 경우 0의 값을 갖는다.

2. 예측력 평가 방법

조기경보모형은 현재 예측변수에 근거하여 타겟변수가 0과 1 가운데 어떤 값을 갖는지 예측하는 2진(binary) 분류모형이라고 할 수 있다.¹⁷⁾ 조기경보모형의 결과값은 0과 1 사이 임의의 실수값을 가진다. 결과값이 클수록 향후 6개월 이내 시계에서 위기 또는 시장불안 이벤트가 발생할 가능성이 높으므로, 동 값을 위기 발생 가능성 지수, 또는 ‘경보 지수’라고 한다.¹⁸⁾ 0과 1 사이의 경보 지수를 타겟변수에 매칭하기 위해, 지수가 특정 임계값보다 크거나 같으면 타겟변수를 1로 분류하고, 낮으면 0으로 분류한다.

이러한 2진 분류모형의 예측력을 평가하는 가장 간단한 방법은 전체 예측 중 정확한 예측의 비중을 나타내는 정확도(accuracy)를 계산하는 것이다. 예를 들어, 2018년 1월부터 2022년 12월까지 60번 예측하였는데, 그 가운데 실제 결과를 정확히 예측한 것이 50번이라면 정확도는 83.3%(50/60)이다.

그러나, 타겟변수 값이 불균등하게 분포된 경우, 정확도는 분류모형의 실제 예측성능을


16) 조기경보모형 학습시 각 예측변수는 평균이 0, 표준편차가 1의 값을 갖도록 표준화한다.

17) 타겟변수가 1의 값을 가지면 6개월내 시장불안 또는 위기 이벤트가 발생(CFPI가 임계점을 상회)하는 것을 의미한다.

18) 경보 지수를 향후 6개월 이내 위기 또는 시장불안 발생 확률로 해석할 수도 있겠으나, 엄밀한 의미의 확률을 나타내는 것은 아니다. 예를 들어, 조기경보모형의 결과값이 0.5라고 해서, 향후 6개월 이내 위기 또는 시장불안이 발생할 확률이 0.5를 의미하는 것은 아니다.

과대평가할 수 있다. 예를 들어, 60개월중 타겟변수 값이 1인 경우가 5개월에 불과하다면 매월 타겟변수 값을 0으로 예측하는 조기정보모형의 정확도는 91.6%(55/60)에 달하게 된다. 이 경우, 예측모형의 1종 오류(false positive)와 2종 오류(false negative) 빈도를 모두 고려하여 예측력을 평가하는 것이 모형의 활용 목적에 보다 부합할 수 있다.¹⁹⁾ 또한, 2진 분류모형의 임계값을 어떻게 설정하느냐에 따라서도 모형의 예측력이 다르게 평가된다. 조기정보모형과 같은 분류모형의 예측력은 1종 오류와 2종 오류를 함께 고려하는 한편, 특정 임계값 수준에 영향을 받지 않은 기준을 적용하여 평가할 필요가 있다.

ROC-AUC (Receiver Operating Characteristic - Area Under the Curve)는 임계값을 지정하지 않고 예측모형의 1종 및 2종 오류 발생 가능성을 하나의 값으로 나타낸다. 아래 <그림 6>은 어느 예측모형의 ROC 곡선과 AUC를 나타낸다.



ROC는 임계값 수준에 따라 예측모형의 TPR (True Positive Rate)과 FPR (False Positive Rate)이 어떻게 변화하는지를 나타내며, AUC는 ROC 곡선의 아래 영역을 의미한다. FPR이 작을수록(TPR이 높을수록) 1종(2종) 오류 발생 빈도가 낮으므로, AUC의 면적이 1에 가까울수록 모형의 예측력이 높다고 할 수 있다.

3. ML 알고리즘

본 연구는 조기정보모형을 개발하기 위해 벤치마크 모형인 신호추출법과 함께 정규화 회귀, SVM, 트리 앙상블, 인공신경망 등 다양한 ML 알고리즘을 테스트하였다. 아래에서는 주요 ML 알고리즘에 대해 간략히 설명한다.²⁰⁾

정규화 회귀에 속하는 알고리즘으로는 Lasso (Tibshirani, 1996), Ridge (Hoerl and Kennard, 1970), Elastic Net (Zou and Hastie, 2005) 등이 대표적이다. 이들 모형은 일반적인 선형회귀모형과 유사하게 예측변수를 선형결합하여 종속변수를 예측하지만 변수 선택이나 계수 축소를 통해 모형의 자유도를 낮춤으로써 과적합을 최소화한다. Lasso는 변수 선택, Ridge는 계수 축소, Elastic Net은 변수 선택과 계수 축소를 모두 적용한다. SVM (Cortes and Vapnik, 1995)은 고차원 공간에서 서로 다른 범주의 데이터간 거리를 최대화하는 경계(hyperplane)를 찾아 데이터를 분류하는 모형이다.

19) 이러한 예측력 평가 방법으로 정밀도(precision) 민감도(sensitivity), F1 score 등이 있다.

20) ML 알고리즘은 예측변수와 타겟변수 간 관계에 대한 가정없이 적절한 모형 검증 기법을 이용하여 변수 간 관계를 포착한다. 다시 말해, 특정 ML 알고리즘이 어떤 특징으로 인해 다른 알고리즘에 비해 더 나은 예측력을 보이는지 설명하기 어렵다. 이러한 점을 고려하여 본고는 각 ML 알고리즘에 대한 자세한 설명없이 주요 특징만을 나열하였다. 정규화 회귀, SVM, 트리 앙상블에 대한 보다 자세한 내용은 James et al. (2017), 딥러닝에 대한 내용은 Chollet (2022)를 참고하기 바란다. 참고로, 경제·금융 통계와 같은 정형 데이터 대상 예측모형의 경우 트리 앙상블 모형이 대체로 높은 예측력을 보이는 것으로 평가되고 있다.

앙상블(ensemble) 모형, 특히 랜덤 포레스트(RF, Random Forest)와 익스트림 랜덤 트리(ET, Extra-Trees 또는 Extremely randomized Trees)²¹⁾는 여러 개의 의사결정트리(decision trees)를 결합(앙상블)하여 강건한(robust) 예측 모형을 구성한다. RF (Breiman, 2001)는 의사결정트리를 생성할 때마다 데이터 일부와 예측변수 일부를 임의추출하여 예측 성능은 약하지만 서로 다른(decorrelated) 모형을 많이 만들고, 이들 의사결정나무의 예측을 평균하여 최종 예측값을 결정한다.²²⁾ 이 방법은 개별 트리의 과적합 문제를 완화하고 전반적인 예측 성능을 향상시키는 장점이 있다. ET (Geurts et al., 2006)는 RF와 유사하지만 의사결정트리 생성 과정에 보다 강한 임의성을 부여하여 과적합을 억제하는 효과가 있다.

인공신경망(ANN)은 인간 뇌의 신경망 구조를 모방하여 설계된 ML 모형이다. 이 모형은 입력층(input layer), 은닉층(hidden layer), 그리고 출력층(output layer)으로 구성되어 있으며, 각 층은 다수의 노드로 이루어져 있다. 각 층의 노드는 이전 층의 노드들을 선형결합한 다음 비선형 활성화(activation) 함수를 거쳐 변환된 값을 저장한다. 특히, 여러 개의 은닉층으로 구성된 인공신경망을 딥러닝(deep learning)이라고 한다. 인공신경망은 데이터에 내재된 복잡하고 추상적인 패턴을

학습할 수 있어, 정형 데이터 예측뿐만 아니라 이미지, 음성, 자연어 등 다양한 비정형 데이터 인식·생성 등에 널리 활용되고 있다.

앞서 설명한 것과 같이 ML 알고리즘은 하이퍼파라미터 튜닝을 통해 모형의 자유도를 적절한 수준으로 조정함으로써 표본외 예측력을 높이게 된다. 하이퍼파라미터 튜닝은 의사결정트리 크기, 은닉층 개수 등 각 알고리즘의 하이퍼파라미터 값을 조금씩 바꾸어가면서 표본외 예측력이 가장 커지는 하이퍼파라미터를 탐색하는 것을 의미한다. 이때 각 하이퍼파라미터 수준에서의 표본외 예측력은 앞서 설명한 stratified group K-fold 교차검증 방식으로 평가한다.

V. 조기경보모형

1997년 7월부터 2023년 6월까지 기간을 대상으로 표본외 예측력을 평가한 결과, 트리 앙상블 기법을 적용한 조기경보모형의 예측력이 가장 우수한 것으로 나타났다. 또한, 과거 시장불안 기간을 대상으로 시뮬레이션한 결과, 조기경보모형이 시장불안 또는 위기 발생을 수 개월 앞서 경보하며, 취약성 및 트리거 요인별로 위기 발생 가능성 상승에 어느 정도 기여하였는지 파악할 수 있는 것으로 나타났다.

21) 익스트림 랜덤 트리는 문헌에 따라 ET, EXT 또는 ERT로 부르기도 한다.

22) 트리 앙상블 모형은 일반적인 예측모형뿐 아니라 본 연구의 조기경보모형으로서도 높은 예측력을 나타내었다. 트리 앙상블 모형의 핵심 요소인 의사결정트리 생성 과정은 다음과 같다. 예를 들어, 데이터가 100개의 관측치와 10개의 예측변수로 구성되어 있으며, 타겟변수는 0과 1의 값을 갖는다고 하자. 먼저, 복원추출 방식으로 전체 데이터와 같은 크기의 학습 데이터를 생성한다. 다음으로, 10개 예측변수 중 N 개($x_1, \dots, x_N$)를 임의추출하고, 이 중 한 변수(x_n) 값을 기준으로 데이터를 두 노드(그룹)로 나눈다. 이때, 노드를 나누는 변수 및 그 임계값(t_n)은 각 노드에 속한 데이터의 타겟변수 값을 최대한 서로 동일하게 만드는 것으로 정한다. 그리고, 이렇게 나누어진 각 노드에 대해 다시 예측변수 N 개를 임의추출하고 그 중 최적의 변수 및 임계값을 찾아서 노드를 나눈다. 이러한 과정을 더 이상 노드를 나눌 수 없을 때까지 반복하면, 하나의 의사결정트리(T)가 생성된다. 의사결정트리의 예측값은 최종 노드에 속한 관측치 가운데 타겟변수 값이 1인 관측치의 비중이다. 한편, 예측오차 평균이 0이고, 분산이 σ^2 인 서로 독립인 예측모형 n 개를 평균(앙상블)하여 예측오차 평균이 0이고 분산이 σ^2/n 인 예측모형을 만들 수 있다. 트리 앙상블 모형은 서로 관련성이 낮은 많은 수의 의사결정트리를 앙상블하여 예측의 분산을 축소하고 예측력을 높이게 된다.

1. ROC-AUC

아래 <표 1>은 각 조기경보모형의 ROC-AUC를 나타낸다. 트리 앙상블 모형인 ET의 예측력이 0.95로 가장 높았으며, 벤치마크 모형인 신호추출법(SE)은 0.84를 기록했다. RF (0.93), XGB (0.91) 등 다른 트리 앙상블 모형은 SVM (0.92)에 비해 낮은 예측력을 나타냈다. 로지스틱, 정규화 회귀 등은 그보다도 낮은 예측력을 보였다.


<표 1> 모델별 ROC-AUC

	신호 추출법 (BM)	트리 앙상블			SVM	로지 스틱
		ET	RF	XGB		LR
평균	0.84	0.95	0.93	0.91	0.92	0.76

주: stratified group K-fold 교차검증을 5회 반복하여 계산된 AUC의 평균값

아래 <그림 7>은 모형별 ROC를 나타낸다. 앞서 설명한 것과 같이 커브가 왼쪽 상단에 위치할수록 각 FPR 수준에서 TPR이 높아지므로, 예측력이 개선되는 것을 의미한다. 그림을 보면, ET가 다른 모든 모형에 비해 예측력이 높다는 것을 확인할 수 있다. 특징적인 것은, 신호추출법이 간단한 모형 구조에도 불구하고, ET, RF, XGB 등 트리 앙상블과 SVM을 제외한 모형 중 양호한 예측력을 보인다는 것이다.

<그림 7> 모델별 ROC



2. 조기경보모형 시뮬레이션


조기경보모형을 실제 운영할 경우 어떤 정보를 제공하는지, 예측 결과를 얼마나 신뢰할 수 있는지 파악하기 위해 2008년(글로벌 금융위기), 2020년(코로나), 2022년(레고랜드) 기간을 대상으로 시뮬레이션을 수행하였다.²³⁾

아래 <그림 8>은 2007년 1월부터 2009년 1월까지 기간 중 각 시점의 빈티지 데이터를 이용하여 경보 지수를 계산하고, 동 지수 변동성을 취약성 및 트리거 변수별로 분해한 것이다. 또한, 벤치마크 모형인 신호추출법에 의한 경보 지수를 함께 표시하여 비교할 수 있도록 하였다. 그림을 보면 경보 지수(검은 실선)가 2007년초 0에서 시작하여 완만하게 상승하다가 CFPI가 임계값을 상회한 2008년 9월 이후 보다 가파르게 상승하였다(08.9월 0.2 → '09.1월 0.6). 그림 아래 요인 분해를 보면, 동 기간 지수 상승은 트리거 변수(주식·환율 변동성, 경기)가 주도하였으며, 취약성 변수

23) 앞서 모형 검증 과정에서 최적화된 하이퍼파라미터를 이용하여 walk-forward 방식으로 조기경보모형을 학습한 다음 각 시점별 빈티지 데이터를 이용하여 경보 지수를 계산하였다. 각 금융·외환위기 또는 시장불안 기간에 대해 해당 기간을 제외한 전체 데이터를 이용하여 학습한 후 계산(stratified group K-fold)한 경보지수는 <부록 3>을 참고하라.

중에서는 자금조달 변수가 지수 상승에 기여한 것으로 분석된다.


〈그림 8〉 2007-08년 경보 지수



주: 위쪽 그림에서 검은 실선과 점선은 각각 조기경보모형(ET)과 신호추출법(SE)을 이용하여 walk-forward 방식으로 계산한 경보 지수를 나타내고, 음영은 CFPPI가 임계값을 상회하고 정점을 기록하기까지 기간을 표시한다. 가로 회색 점선은 조기경보모형(ET)을 이용하여 산출한 1999년 이후 경보 지수의 70th, 90th percentile 값을 나타낸다. 아래쪽 그림은 조기경보모형(ET)의 경보 지수 변동을 각 예측변수별로 분해한 것이다.

아래 〈그림 9〉는 2018년 6월부터 2020년 6월까지 기간을 나타낸다. 경보 지수는 2019년 9월 이후 소폭 하락하였다가, 2020년 3월 이후 가파르게 상승하는 모습을 보였다. 이는 당시 시장불안이 감염병 유행으로 촉발됨에 따라 조기경보모형이 사전 경보할 수 없었던 것으로 판단된다. 요인 분해를 보면 2008년과 마찬가지로 변동성 관련 트리거 변수가 지수 상승을 주도한 것을 확인할 수 있다(〈그림 2〉 Type 2 참고).


〈그림 9〉 2019-20년 경보 지수



주: 위쪽 그림에서 검은 실선과 점선은 각각 조기경보모형(ET)과 신호추출법(SE)을 이용하여 walk-forward 방식으로 계산한 경보 지수를 나타내고, 음영은 CFPPI가 임계값을 상회하고 정점을 기록하기까지 기간을 표시한다. 가로 회색 점선은 조기경보모형(ET)을 이용하여 산출한 1999년 이후 경보 지수의 70th, 90th percentile 값을 나타낸다. 아래쪽 그림은 조기경보모형(ET)의 경보 지수 변동을 각 예측변수별로 분해한 것이다.

다음 〈그림 10〉은 2021년 8월부터 2023년 2월까지 기간이다. 경보 지수는 2022년 2분기부터 지속적으로 상승하면서 위기 발생 가능성을 경보하였으며 2022년 11월 0.5까지 상승하였다. 요인 분해를 보면, 2008년 및 2020년 사례와 달리 금리 부문 트리거 변수와 함께 자금조달, 레버리지 등 취약성 변수의 기여도가 높게 나타났다(〈그림 2〉 Type 1 참고).

〈그림 10〉 2021-22년 경보 지수



주: 위쪽 그림에서 검은 실선과 점선은 각각 조기경보모형(ET)과 신호추출법(SE)을 이용하여 walk-forward 방식으로 계산한 경보 지수를 나타내고, 음영은 CFP가 임계값을 상회하고 정점을 기록하기까지 기간을 표시한다. 가로 회색 점선은 조기경보모형(ET)을 이용하여 산출한 1999년 이후 경보 지수의 70th, 90th percentile 값을 나타낸다. 아래쪽 그림은 조기경보모형(ET)의 경보 지수 변동을 각 예측변수별로 분해한 것이다.

3. 취약성 및 트리거 변수 간 관계

일반적인 계량경제모형은 사전에 변수 간 관계를 가정하고, 그 가정내에서만 변수 간 관계를 추정한다. 예를 들어, 선형회귀모형은 예측 변수와 종속변수 간 선형관계를 가정하기 때문에, 특정 예측변수와 종속변수 간 관계는 그 선형관계의 기울기를 나타내는 하나의 계수로 설명된다. 이에 반해, ML 알고리즘은 모형의 높은 자유도로 인해 연구자가 사전에 변수 간 특정관계를 가정하지 않고, 데이터에 내재한 변수 간 비선형, 상호의존적 관계를 포착할 수 있게 된다. ML 알고리즘으로 포착한 변수 간 관계는 많은 수의 파라미터에 의해 결정되므로

한 두 개 파라미터로 설명할 수 없으며 다양한 시각화 기법을 통해 나타내게 된다.

ML 모형에 포착된 변수 간 관계를 시각화하는 대표적인 기법으로 PDP (Partial Dependence Plot)가 있다. 직관적으로 설명하면, PDP는 ML 모형에 특정 변수 값을 계속 바꾸어 입력하면서 ML 모형의 결과값(경보 지수)이 어떻게 바뀌는지 추적하여 시각화한다(아래 〈식 2〉 참고). 이때 하나의 예측변수를 대상으로 예측변수 값과 결과값의 관계를 살펴보는 것을 1-way PDP, 두 개 예측변수의 값을 각각 독립적으로 바꾸어가며 두 예측변수와 결과값의 관계를 살펴보는 것을 2-way PDP라고 한다.²⁴⁾

〈식 2〉 ICE와 PDP

$$\text{ICE} : f^{(i)}(t) = f(x_k = t | x^{(i)}), \quad i = 1, \dots, N$$

$$\text{PDP} : f(t) = \frac{1}{N} \sum_{i=1}^N f^{(i)}(t)$$


주: f 는 조기경보모형, $x^{(i)}$ 는 i 번째 관측 데이터(예, 2020년 1월말)의 예측변수값, x_k 는 분석 대상 예측변수, N 은 전체 관측 데이터 크기

아래 〈그림 11〉은 단기외채 비율(단기외채/외환보유액), 은행 레버리지, CP 스프레드, VIX 등 변수에 대한 1-way PDP를 나타낸다. 각 그림에서 가로축은 정규화된 예측변수, 세로축은 경보 지수이다. 왼쪽 상단 단기외채 비율에 대한 1-way PDP를 보면, 비율이 1보다 낮을 때는 기울기가 완만한 수준을 보이지만, 1보다 큰 경우 기울기가 상당히 가팔라

24) 하나의 예측변수 값을 변화시키며 ML 모형의 결과값이 어떻게 바뀌는지 계산할 때, 다른 예측변수들의 값은 과거 특정 시점(예를 들어, 2023년 12월말) 값으로 고정한다. 지난 20년간 240개의 관측치가 있다면, 각 예측변수별로 예측변수-결과값 관계를 240개의 차트로 나타낼 수 있으며, 이를 ICE (Individual Conditional Expectation)이라고 한다. ICE를 모두 평균한 것이 1-way PDP이다. PDP에 대한 보다 자세한 내용은 Goldstein et al. (2015)을 참고하기 바란다.

지는 것을 확인할 수 있다. 단기외채 비율 이외에도 은행 레버리지가 경보 지수와 뚜렷한 비선형 관계를 나타내며, 트리거 변수 중에서는 CP·CD 스프레드, VIX 등 변수와 경보 지수가 비선형 관계를 보인다(부록 4) 참고).


〈그림 11〉 1-way PDP



주: 단기외채 비율, 은행 레버리지, CP 스프레드, VIX 등 예측변수에 대한 ICE(열은 실선)와 PDP(붉은 실선). 각 그림에서 가로축은 정규화된 예측변수 값, 세로축은 경보 지수 수준을 나타낸다.

다음으로 〈그림 12〉는 단기외채 비율과 VIX에 대한 2-way PDP를 나타낸다. 가로축은 정규화된 단기외채 비율, 세로축은 정규화된 VIX를 나타내고, 등고선은 경보 지수 수준을 나타내며, 밝을수록 경보 지수가 높은 영역이다. 그림에서 단기외채 비율이 높은 오른쪽 영역에서 등고선 간 간격이 좁은 것을 볼 수 있다. 이는 단기외채 비율이 높을수록 경보 지수가 트리거 및 취약성 변수에 민감하게 반응하는 것을 의미한다. 다시 말해, 취약성 및 트리거 변수가 위기 발생 가능성에 미치는 영향은 각 변수 수준에 의존한다는 것이다(부록 5) 참고).

〈그림 12〉 2-way PDP



주: 가로축은 정규화된 단기외채 비율, 세로축은 정규화된 VIX를 나타내고, 등고선은 경보 지수 수준을 나타내며, 밝을수록 경보 지수가 높은 영역이다.

VI. 요약 및 시사점

본 연구는 금융시스템 취약성과 트리거 변수 간 상호작용에 의해 발생하는 금융·외환위기 발생 및 시장불안을 조기경보하는 신뢰할 수 있는 모형을 개발하고자 하였다. 이를 위해, 먼저 복합금융압력지수(CFPI)를 정의하여 1997년 7월 이후 우리나라 금융·외환위기 및 시장불안 이벤트를 식별하고, 위기 발생 메커니즘을 포착할 수 있는 ML 알고리즘과 위기 조기경보에 적합한 모형 검증 기법을 적용하였다.

다양한 후보 모형을 테스트한 결과 ML 모형 중 트리 앙상블 모형(ET)을 적용한 조기경보 모형이 가장 높은 예측력을 나타냈다. 또한, 과거 위기 및 시장불안 이벤트를 대상으로 조기경보 성능을 점검한 결과, 이벤트 발생 3~6개월 전까지는 위기 발생 가능성을 나타내는 지수(경보 지수)가 0.1 이하로 낮은 수준을 보이다가 이후 지속적으로 높아져 이벤트

발생 직전 0.4~0.6을 상회하는 모습을 보였다. 또한, 동 조기경보모형을 이용하여, 취약성·트리거 변수, 위기 발생 가능성 간 비선형, 상호의존적 관계를 확인할 수 있었다. 이는 금융위기 발생 메커니즘을 고려하지 않는 모형은 위기 발생 가능성을 정확히 평가하는데 한계가 있음을 시사한다.

이번에 개발한 조기경보모형은 엄밀한 예측력 평가를 통해 신뢰성을 높이고, 위기 발생 가능성을 취약성 및 트리거 변수로 나누어 살펴볼 수 있다는 장점이 있다. 그러나, 위기 발생 가능성을 높인 근원 이벤트를 식별하거나, 정책 대응을 위한 구체적 정보를 제공하지 못한다는 한계도 있다. 예를 들어, 본 연구에 포함된 트리거 변수는 미 연준의 긴축적 통화정책이나 미·중 무역분쟁, 감염병 유행과 같은 근원 이벤트에 의해 영향을 받는다. 하지만, 이러한 개별 요인들은 계량화가 어렵고, 관측 데이터가 제한된 상황에서 모든 요인을 모형에 포함할 수 없다는 제약이 있다. 취약성의 경우에도 본 연구에 포함된 레버리지, 자금조달 등 변수는 특정 부문의 취약성 확대를 어느 정도 시차를 두고 반영하게 된다.

금융위기는 여러 해에 걸쳐 축적되는 경제내 취약성과 상대적으로 빠르게 몇 개월에 걸쳐 확산하는 트리거 이벤트의 상호작용으로 촉발된다. 조기경보모형으로 위기 발생 가능성은 평가할 수 있지만, 정확히 어느 부문에서 취약성이 확대되고, 어떤 트리거 이벤트가 확산되고 있는지 파악하는 데 한계가 있다. 이를 위해서는 IMF의 EWE와 같이 조기경보모형뿐만 아니라 전문가 서베이를 통한 리스크 요인 식별, 부문별 취약성 평가 등 종합적인 조기경보체계(EWS, Early Warning System)를

갖출 필요가 있다. 본 연구의 조기경보모형이 향후 정책 수행에 활용할 수 있는 조기경보체계 개발로 이어지는 계기가 되기를 기대한다.

〈부록 1〉

금융위기 취약성(위험요인)과 트리거(위기촉발사건)

위기	취약성(위험요인)	트리거(위기촉발사건)
핀란드(1991) 노르웨이(1988) 스웨덴(1991)	신용 및 주택가격 상승, 경기과열, 은행자본 부족, 은행의 특정대출 집중, 외화표시 국내대출, 건전성 감시·감독이 부족한 상태에서 규제완화, 개별은행의 위험관리 부족	조세개혁, 통화정책 긴축, 교역급감, 환율절하
멕시코(1994)	정부의 (해외통화표시) 단기 대외채무 증가	미국의 통화정책 긴축, 정치적 혼란
아르헨티나(1995)	은행부문의 단기 대외채무 증가	멕시코 위기의 전염효과
일본(1995)	신용 및 부동산가격 상승, 건전성 감시·감독이 부족한 상태에서 규제완화, 기업자배구조 문제	부동산시장 폭락
태국(1997)	금융 및 비금융 기업의 외채 증가, 금융기관의 부동산부문 대출 집중	교역조건 악화, 자산가격 하락
한국(1997)	외채문제(만기불일치), 재벌에 대한 대출집중, 기업부문 부채비율 상승	교역조건 악화, 재벌의 수익성 악화, 태국 위기의 전염효과
인도네시아(1997)	기업부문 외채 증가, 부동산 관련 대출 집중, 기업부문 부채비율 상승	태국 위기의 전염효과
러시아(1998)	정부부문 단기외화조달 필요	재정수지 악화, 교역조건 악화
브라질(1999)	정부부문 단기 외채	재정지출 삭감에 대한 불확실성, 경상수지적자, 러시아 위기 전염효과
터키(2000)	정부부문 단기부채, 은행부문 통화 및 만기불일치	경상수지 악화, 실질환율 절상, 교역조건 악화, 정부의 금융개혁에 대한 불확실성
아르헨티나(2002)	정부 및 민간의 해외통화표시 대외부채	Currency Board와 재정정책의 불일치
우루과이(2002)	은행부문 단기외채	아르헨티나 예금인출 제한에 따라 우루과이에서 대규모 인출 발생
미국(2007)	신용 및 주택가격 상승, 금융기관 규제 악화에 따라 레버리지와 Mispricing 발생	서브프라임 시장 붕괴

자료: Ghosh et al. (2009); 이항용(2015)


〈부록 2〉

취약성 및 트리거 변수 리스트

예측변수			주기	공표시차 (월)	비고
취 약 성	레버리지	가계신용/GDP	Q	3	12개월 차분
		기업신용/GDP	Q	3	12개월 차분
	자금조달	단기외채 비율	Q	3	단기외채/외환보유액
		은행 레버리지	M	1	12개월 차분
		은행 예대율	M	3	12개월 차분
	자산가격	주택가격	M	1	3개월 이동평균 백분율 변화량
트 리 거	금리	CD 스프레드	D	0	12개월 차분
		CP 스프레드	D	0	12개월 차분
		국가 신용 스프레드	D	0	12개월 차분
		기간 프리미엄 스프레드	D	0	12개월 차분
	변동성	KOSPI 변동성	D	0	$X_t = -\frac{p_t}{\max(p_{t-1}, p_{t-2}, \dots, p_{t-24})}$
		은행지수 변동성	D	0	$X_t = \begin{cases} 2.9 \times \text{KOSPI 은행지수} & \text{if } t \leq 2020-06 \\ \text{KRX 은행지수} & \text{if } t > 2020-06 \end{cases}$ 의 이동평균표준편차(6개월)
		VIX	D	0	
		환율 변동성	D	0	이동평균표준편차(6개월)
	경기	GDP 성장률	Q	3	전기 대비

〈부록 3〉


1999-2023년중 경보 지수



주: 위쪽 그림에서 검은 실선과 점선은 각각 조기경보모형(ET)과 신호추출법(SE)을 이용하여 stratified group K-fold 방식으로 계산한 경보 지수를 나타내고, 음영은 CFP가 임계값을 상회한 기간을 표시한다. 세로 점선은 GDP 성장률(전기 대비)이 지난 4분기 평균보다 1표준편차 이상 하락한 시점을 나타낸다. 가로 회색 점선은 조기경보모형(ET)을 이용하여 산출한 1999년 이후 경보 지수의 70th, 90th percentile 값을 나타낸다.


〈부록 4〉

주요 예측 변수별 1-way PDP



〈부록 5〉

주요 취약성-트리거 예측변수 조합별 2-way PDP



〈참고문헌〉

- 김명직, 황태욱(2011), “복합금융위기에 대한 조기경보”, *경제연구*, 32(1), pp. 27-52.
- 나성오, 이현창, 남명훈(2020), “금융·실물 연계를 고려한 금융불균형 수준 평가”, BOK 이슈노트, 2020(2).
- 박원암(2011), “2008년 위기 예측 가능했나?: 신호접근법 분석”, *East Asian Economic Review*, 11(9). 대외경제정책연구원.
- 박원암(2017), “우리나라 위기 예측과 지역모형의 사용—신호접근법 분석”, *금융지식연구* 15(3), pp. 75-98.
- 이창훈, 홍지연, 이현창(2024), “빅데이터와 기계학습 알고리즘을 활용한 실시간 인플레이션 전망(real-time inflation forecasting)”, BOK이슈노트, 2024(5).
- 이항용(2015), “금융위기 조기경보시스템(Early warning system for financial crisis)”, 2015 경제발전경험모듈화사업: 금융위기 조기경보시스템.
- 정영식, 오갑진, 한원태, 백예인, 강은정, 김유리(2022), “금융위기의 전개 과정 및 요인 분석복잡계와 머신러닝 방법론을 중심으로”, 대외경제정책연구원 연구보고서, 22(17).
- Abiad, A. (2003), “Early Warning Systems: A Survey and a Regime-Switching Approach”, IMF Working Paper 03(32).
- Babihuga, R. (2007), “Macroeconomic and Financial Soundness Indicators: An Empirical Investigation”, IMF Working Paper 07(115).
- Berg, A., Pattillo, C. (1999), “Predicting Currency Crises: The Indicators Approach and an Alternative”, *Journal of International Money and Finance* 18(4), pp. 561-586.
- Bernanke, B. S. (2010), “Causes of the recent financial and economic crisis”, Testimony before the Financial Crisis Inquiry Commission, Washington, D.C.
- Bluwstein, K., Buckmann, M., Joseph, A., Kapadia, S., Şimşek, Ö. (2023), “Credit growth, the yield curve and financial crisis prediction: Evidence from a machine learning approach”, *Journal of International Economics* 145(2023).
- Breiman, L. (2001), “Random forests”, *Machine Learning* 45, pp. 5-32.
- Cardarelli, R., Elekdag, S., Lall, S. (2009), “Financial Stress, Downturns, and Recoveries”, IMF Working Paper 09(100).

- Christensen, I., Li, F. (2014), “Predicting Financial Stress Events: A Signal Extraction Approach”, Bank of Canada Working Paper 2014-37.
- Chollet, F. (2022), “Deep Learning with Python”, Manning Publications, Inc.
- Cortes, C., Vapnik, V. (1995), “Support-vector networks”, *Machine Learning*, 20, pp. 273-297.
- Demirgüç-Kunt, A., Detragiache, E. (1998), “The Determinants of Banking Crises in Developing and Developed Countries”, *IMF Staff Papers* 45(1), pp. 81-109.
- Frankel, J. A., Rose, A. K. (1996), “Currency crashes in emerging markets: An empirical treatment”, *Journal of International Economics*, 41, pp. 351-366.
- Furman, J., Stiglitz, J. E. (1998), “Economic crises: Evidence and insights from East Asia”, *Brookings Papers on Economic Activity*, 1998(2), pp. 1-135.
- Geurts, P., Ernst, D., Wehenkel, L. (2006), “Extremely randomized trees”, *Machine Learning*, 63(1), pp. 3-42.
- Ghosh, A. R., Ostry, J. D., Tamirisa, N. (2009), “Anticipating the Next Crisis”, *Finance & Development* 46(3), pp. 35-37.
- Goldstein, M., Kaminsky, G. L., Reinhart, C. (2000), “Assessing Financial Vulnerability, An Early Warning System for Emerging Markets.: Introduction”, In *Assessing Financial Vulnerability: An Early Warning System for Emerging Markets*, pp. 1-56, Washington, DC: Institute for International Economics.
- Goldstein, A., Kapelner, A., Bleich, J., Pitkin, E. (2015), “Peeking Inside the Black Box: Visualizing Statistical Learning With Plots of Individual Conditional Expectation”, *Journal of Computational and Graphical Statistics*, 24(1), pp.44-65.
- Hawkins, J., Klau, M. (2000), “Measuring Potential Vulnerabilities in Emerging Market Economies”, *BIS Working Papers* 91.
- Hoerl, A. E., Kennard, R. W. (1970), “Ridge regression: Biased estimation for nonorthogonal problems”, *Technometrics*, 12(1).
- International Monetary Fund. (2010), “The IMF-FSB Early Warning Exercise: Design and Methodological Toolkit”, *IMF Policy Paper* 2010(078).
- International Monetary Fund. (2021), “How to Assess Country Risk: The Vulnerability Exercise Approach Using Machine Learning”, *IMF Technical Notes and Manuals* 2021(003)

- James, G., Witten, D., Hastie, T., Tibshirani, R. (2017), “An Introduction to Statistical Learning”, Springer.
- James, D. H. (1989), “A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle”, *Econometrica* 57(2), pp. 357-384.
- Jordà, O., Knoll, K., Kuvshinov, D., Schularick, M., Taylor, A. M. (2019), “The rate of return on everything, 1870–2015”, *The Quarterly Journal of Economics*, 134(3), pp. 1225-1298.
- Kaminsky, G. L., Lizondo, S., Reinhart, C. M. (1998), “Leading Indicators of Currency Crises”, *IMF Staff Papers*, 45(1).
- Kaminsky, G., Reinhart, C. (1999), “The Twin Crises: The Causes of Banking and Balance-of-Payments Problems”, *American Economic Review*, 89(3), pp. 473-500.
- Laeven, L., Valencia, F. (2018), “Systemic banking crises revisited”, *IMF Working Paper* 18(206).
- Lee, H., Lee J. (2014), “Establishing Early Warning System in Saudi Arabia”, 2013 Knowledge Sharing Program: Policy Recommendations for Economic Development in Priority Areas of the Kingdom of Saudi Arabia, p. 149.
- Suss, J., Treitel, H. (2019), “Predicting Bank Distress in the UK with Machine Learning”, *Bank of England Staff Working Paper* 831.
- Tibshirani, R. (1996), “Regression shrinkage and selection via the lasso”, *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), pp. 267-288.
- Zou, H., Hastie, T. (2005), “Regularization and variable selection via the elastic net”, *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 67(2), pp. 301-320.

Copyright © BANK OF KOREA. All Rights Reserved

- 본 자료의 내용을 인용하실 때에는 반드시 “BOK 이슈노트 No.2024-11에서 인용”하였다고 표시하여 주시기 바랍니다.
- 자료 내용에 대하여 질문 또는 의견이 있는 분은 커뮤니케이션국 커뮤니케이션기획팀(02-759-4759, 4784)으로 연락하여 주시기 바랍니다.
- 본 자료는 한국은행 홈페이지(<http://www.bok.or.kr>)에서 무료로 다운로드 받으실 수 있습니다.