

머신러닝 기반 기업부도위험 예측모델 검증 및 정책적 제언

스태킹 앙상블 모델을 통한 개선을 중심으로

RiskPulse [고혜원, 이영경, 조윤태]

목차

01	요약	02	선행 연구
03	문제 제기	04	데이터 설명
05	전처리 및 EDA	06	모델링 · 평가 · 결론
07	한계 및 후속 연구	08	Q & A

요약

Merton 모형으로 연속형 부도확률을 산출해 종속변수로 활용하고, **스태킹 앙상블**로 단일 모델의 편향을 제거하여 비상장기업에도 적용 가능한 신뢰성 높은 부도위험 예측 모델을 제안한다.

분석 기업 2,194 개	관측치 10,545 건	변수 160개	분석 기간 2012 – 2018
DEPENDENT Merton 모형 부도확률 주가·시가총액 기반의 연속형 부도확률 (0–1)		METHOD Stacking Ensemble Model RF + MLP + CNN → 메타 MLP가 최종 결합	

선행 연구의 흐름



구분	방법론	주요 연구
통계적 방법	판별분석 · 로짓 / 프로빗	Altman Z-Score (1968), Ohlson (1980), Zmijewski (1984)
시장정보 활용	Merton 구조모형	Byun (2004), Kang (2011, 2014)
ML 단일모델	ANN · SVM · RF · LSTM	Lee (1993), Kim (2009–2014), Cha (2018)
앙상블	Bagging · Voting · SVM 앙상블	Bae (2010), Min (2014) — 본 연구는 Stacking으로 확장

현행 신용평가 체계의 3가지 구조적 문제

갱신 주기가 길다

신용등급은 일정 주기로만 업데이트되어 기업 상황이 급변해도 즉각 반영이 불가능하다.

비상장 · 초기 기업 적용이 어렵다

평가가 상장기업 중심으로 이루어져, 자본 조달이 절실한 중소기업과 스타트업은 평가 체계 밖에 놓여 있다.

후행적이다

부도·채무불이행 같은 신용 사건이 발생한 이후 해야 등급이 조정되어 예측 도구로서 기능이 떨어진다.

후행성 시각화

기업 상황 악화 시작

.....

등급 변화 없음 // LAG

.....

신용 사건 발생

→

등급 하향

기존 ML 연구의 한계와 본 논문의 해결책

	기존 한계	본 논문의 해결책
기존 신용평가 체계의 한계	신용등급의 후행성·긴 갱신 주기	Merton 모형으로 시장가치 기반 부도확률을 적시에 산출
	비상장 기업 적용 불가	상장 기업으로 학습 후, 예측 단계에서는 재무정보만 사용
	회계정보만 반영하는 한계	주가·시가총액 기반 Merton 모형으로 시장의 집단적 판단을 내재화
머신러닝 기반 연구의 한계	부도 사건 희소성 → 데이터 불균형	이진 레이블 대신 연속형 부도확률 (0-1) 사용으로 구조적 우회
	특정 알고리즘의 단일 모델 편향	스태킹 앙상블로 단일 모델의 편향을 보완

데이터 설명 · 160개 변수

기업 수

2,194

관측치

10,545

기간

2012 - 2018

대상

KOSPI · KOSDAQ
상장 기업

KOSPI · KOSDAQ 상장 기업 중 **K-IFRS 도입 이후** 데이터를 사용해 회계 기준의 일관성을 확보. 종속변수는 **Merton 모형으로 산출한 연속형 부도확률**

카테고리	항목 수
재무상태표	38
포괄손익계산서	26
현금흐름표	11
재무비율	76
연도 더미	7
종속변수 (부도확률)	1
합계	160

〈Table 2〉 Input-data descriptions					
Division		Num of Variables	Division		Num of Variables
Balance sheet	Total asset	1	Financial Ratio	Total assets ratio	14
	Current asset	6		total capital ratio	5
	Non-current assets	8		asset liability ratio	5
	Total liabilities	1		Cashflow ratio	4
	Current liabilities	9		Profit-related ratio	3
	non-current liabilities	9		Balance item	3
	capital assets	1		Sales profit item	12
	capital surplus	1		Return on Capital	7
	Comprehensive Income	1		Turnover Related Items	9
	Retained Earnings	1		Period related items	2
State-ment of comprehensive income	Sales	1		EPS	1
	Cost of Goods sold	1		BPS	1
	Gross profit or loss	1		SPS	1
	S&A expenses	8		CFPS	1
	Operating Income/Loss	1		EBITDAPS	1
	Financial income	4		PBR	1
	finance costs	3		PSR	1
	Other Income	1		Beta	1
	Other costs	1		WACC	1
	ILBIT	1		Total Cashflow	1
	Income Taxes	1		CAPEX	1
	Net Income or loss	1		EBITDA	1
	Other income	1	Year dummy variables	2012	1
State-ment of cash flows	Total income	1		2013	1
	Operating activities	6		2014	1
	Investing activities	1		2015	1
	Financing activities	1		2016	1
	Cash & cash equivalents	1		2017	1
	Cash at beginning	1		2018	1
	Cash at end	1	Other	Number of employees	1
Target	Default risk				1
Total	Total number of variables				160

Merton 모형 — 종속변수 산출

종속변수 : 시장은 기업의 부도위험을 어떻게 평가하는가?

→ 주식을 기업 자산에 대한 **콜옵션** 으로 해석하여 부도확률을 도출.

$$\frac{dV}{V} = \mu dt + \sigma_A dW_t$$

(1) 핵심 가정 : 기업의 자산가치가 **기하브라운운동 (GBM)**을 따른다고 가정

$$E = VN(d_1) - e^{-rT}F(d_1)$$

(2) 주식 가치(E)는 블랙-숄즈 옵션가격결정모형을 통해 산출

$$d_1 = \frac{\ln(V/F) + (r + 0.5 \times \sigma_V^2)T}{\sigma_V \sqrt{T}}$$

$$d_2 = d_1 - \sigma_V \sqrt{T}$$

(3) 자산 가치(V)와 자산 가치 변동성은 연립방정식 (3)을 통해 반복적으로 추정

$$\sigma_E = \frac{V}{E} N(d_1) \sigma_V$$

$$\pi = N\left(-\left(\frac{\ln(V/F) + (r - 0.5 \times \sigma_V^2)T}{\sigma_V \sqrt{T}}\right)\right)$$

(4) 최종적으로 산출된값을 통해 내재부도확률(n)을 계산

(1) 자산가치 동학

$$dV/V = \mu \cdot dt + \sigma_A \cdot dW_t$$

(2) 블랙-숄즈 식

$$E = V \cdot N(d_1) - e^{-rT} \cdot F \cdot N(d_2)$$

$$\sigma_E = (V/E) \cdot N(d_1) \cdot \sigma_V$$

(4) 부도확률 π

$$\pi = N\left(-\left(\frac{\ln(V/F) + (r - 0.5 \cdot \sigma_V^2) \cdot T}{\sigma_V \cdot \sqrt{T}}\right)\right)$$

괄호 안 = KMV의 **부도거리(DD)**의 음수값. 부도거리가 짧을수록 π 상승.

V: 자산가치(주식가치 + 부채가치)

F: 부채가치 = (유동부채 + 고정부채*0.5)

r: 무위험이자율 (국고채 3년 수익률)

σ_V : 자산가치 변동성

σ_E : 주식가치변동성

Merton 모형 — 종속변수 산출

STEP 01

입력값 준비

- 주식가치 E = 시가총액
- 주식변동성 σ_E = 일간 수익률 연환산 표준편차
- 부채가치 F = 유동부채 + 고정부채 $\times 0.5$
- 무위험이자율 r = 국고채 3년 수익률
- 만기 T = 1년

STEP 02

자산가치 V · 변동성 σ_V 추정

블랙-숄즈 식과 변동성 관계식의 **연립방정식** 을 Crosbie(2003) 반복 알고리즘으로 수치 최적화.

$$E = V \cdot N(d_1) - e^{-rT} \cdot F \cdot N(d_2)$$

$$\sigma_E = (V/E) \cdot N(d_1) \cdot \sigma_V$$

→ Python scipy 라이브러리로 수치해 도출.

STEP 03 · OUTPUT

부도확률 π 산출

$$\pi = N(-DD)$$

$$DtD \text{ (Distance to Default)} = (\ln(V/F) + (r - 0.5\sigma_V^2) \cdot T) /$$

$(\sigma_V \cdot \sqrt{T})$ 부도거리가 짧을수록 부도확률 π 가 빠르게 상승. 기업별로 **연속형 0-1 부도확률** 이 정답 레이블로 부여된다.

왜 Merton 모형인가?

기존 이진 레이블 방식	MERTON 모형 방식 (본 연구)
부도 발생 여부 0 / 1만 반영	연속형 확률값 0 – 1로 위험 세분화
희소 이벤트 → 데이터 불균형	모든 기업에 확률값 부여 → 불균형 없음
회계정보만 반영	주가·변동성을 통해 시장의 판단 내재화
외적 충격 반영 불가	주가 급락 시 즉시 부도확률 상승 반영
비상장 기업 적용 불가	상장 기업으로 학습 후 재무정보만으로 비상장 기업 추정 가능

대표 변수의 기술통계

〈Table 3〉 Descriptive statistics for representative variables

Division		Obs	Mean	Std. Dev.	Min	Max
V1	Default probability	10,545	0.34819	0.36766	0.0	1.0
V2	Market cap	10,545	761.0	6,550.0	3.3	329,000.0
V3	Current assets	10,545	598.0	4,070.0	0.9	175,000.0
V4	Non-current assets	10,545	926.0	6,240.0	0.1	166,000.0
V5	Current liability	10,545	458.0	2,440.0	0.1	69,100.0
V6	Non-current liability	10,545	348.0	2,940.0	0.0	92,300.0
V7	Capital stock	10,545	49.3	208.0	0.0	3,660.0
V8	Capital surplus	10,545	117.0	425.0	-574.0	7,060.0
V9	Accumulated Other Comprehensive Income	10,545	3.5	165.0	-7,990.0	1,940.0
V10	Retained earnings	10,545	530.0	5,450.0	-3,590.0	243,000.0
V11	Sales	10,545	1,280.0	7,720.0	0.0	244,000.0
V12	Cost of sales	10,545	1,000.0	5,610.0	0.0	138,000.0
V13	Gross profit	10,545	286.0	2,620.0	-1,580.0	111,000.0
V14	Selling, general and administrative expense	10,545	201.0	1,650.0	-273.0	56,600.0
V15	Operating income	10,545	84.9	1,090.0	-3,270.0	58,900.0
V16	Financial income	10,545	25.6	279.0	0.0	11,400.0
V17	Financial cost	10,545	34.5	289.0	0.0	10,700.0
V18	Other income	10,545	22.4	137.0	-0.6	4,220.0
V19	Other expense	10,545	28.1	157.0	0.0	4,420.0
V20	Continuing income and loss before income taxes	10,545	78.5	1,160.0	-4,060.0	61,200.0
V21	Tax expense	10,545	21.5	290.0	-985.0	16,800.0
V22	Net income	10,545	59.0	878.0	-3,080.0	44,300.0
V23	Accumulated other comprehensive income	10,545	-3.2	82.7	-5,500.0	1,990.0
V24	Total comprehensive income	10,545	55.8	842.0	-3,400.0	44,300.0
V25	Cash flow from operating activities	10,545	115.0	1,400.0	-3,460.0	67,000.0
V26	Cash flow from investing activities	10,545	-109.0	1,170.0	-52,200.0	4,330.0
V27	Cash flow from Financing activities	10,545	0.0	356.0	-15,100.0	8,380.0
V28	Cash and cash equivalents	10,545	5.4	168.0	-2,510.0	9,470.0
V29	Cash and cash equivalents at beginning of period	10,545	92.7	682.0	-5.4	32,100.0
V30	Cash and cash equivalents at end of period	10,545	98.1	738.0	-5.5	32,100.0
V31	The number of employees	10,545	876	3961	0	103011


[decimal point, one billion KRW, person]

부도확률, 시가총액, 현금흐름표, 종업원 수 외에

재무상태표의 자산/부채/자본 세부항목을

중분류 단위로 요약한 데이터에 대한 기술통계량

상관관계 분석 · Figure 6



〈Figure 6〉 Correlation analysis results for representative variables

재무지표 간 상관은 높음

매출·자산·이익 계열의 변수들이 강하게 묶여 있어 다중공선성이 광범위하게 존재 한다.

부도확률과의 상관은 약함

첫 번째 행(v1)에서 보듯, 부도확률은 대부분의 재무지표와 강한 상관을 보이지 않는다.


단순 선형 모형으로는 부도확률을 포착하기 어렵다

→ 비선형 ML 모델링의 필요성 이 확인됨.

3개의 베이스 러너 · RF · MLP · CNN

Random Forest


다수의 의사결정 트리를 학습하고, 트리별 예측을 평균/투표로 결합한다. 비선형 관계와 노이즈에 강건.



〈Figure 1〉 Random Forest Method

MLP · 다층 퍼셉트론


입력층 → 은닉층 → 출력층의 완전연결 신경망. 고차원 비선형 함수 근사에 강점.



〈Figure 2〉 Multi-layer Perceptron (MLP) Method


CNN · 합성곱 신경망

입력 변수들을 격자 형태로 재구성하여 국소 패턴(국지적 변수 그룹)을 추출 → 데이터의 내재적 구조 및 패턴 포착에 유리




〈Figure 3〉 Convolutional Neural Networks (CNN) Method

스태킹 앙상블 구조



〈Figure 4〉 Stacking Ensemble Model



스태킹 모델이란 — 서로 다른 모델들을 조합하여 구성할 수 있으며, 이러한 조합을 통해서 각 알고리즘의 장점을 취하면서 약점을 보완함. 이를 통해, 일반적으로 단일 모델보다 성능을 향상시킬 수 있음.

데이터 분할 — Train 셋은 서브모델 학습과 메타러너 학습 데이터 생성의 **이중 역할**을 한다.

Base Learner 학습 (7-Fold CV) — Train을 7개 폴드로 나눠 6 폴드로 RF · MLP · CNN을 학습하고 나머지 1 폴드를 예측. 7번 반복 → 전체에 대한 **과적합 없는 예측값**.

Meta Learner 학습 — 3개의 예측값을 새로운 피처로 삼아 **메타러너(MLP · 노드 20)**를 학습. 어떤 상황에서 어떤 서브모델을 더 신뢰할지 데이터로 학습한다.


최종 예측 — Test 셋에 세 서브모델이 예측값을 만들고, 메타러너가 이를 결합해 **최종 부도확률**을 산출.

대조군: Model1~3 <Table 1> Model comparison

Division	Model 1	Model 2	Model 3	Model 4
	Random Forest (RF)	MLP	CNN	Stacking Ensemble
Main logic	Decision tree	Neural network	Neural network	Combining predictions using MLP
Input data for training	Training set	Training set	Training set	Base learner (RF, MLP, CNN) prediction results using segmented training set (7-fold)
Input data for testing	Test set	Test set	Test set	Base learner prediction results in test set
Training data dimension	(7382, 160)	(7382, 160)	(7382, 160)	(7382, 4)
Test data dimension	(3163, 160)	(3163, 160)	(3163, 160)	(3163, 4)

Credit Risk Prediction · 전체 흐름도

06 모델링 · 평가 · 결론



〈Figure 7〉 Credit risk prediction algorithm

재무제표 + 재무비율


→ Train / Test 분할 (7:3)

→ RF · MLP · CNN 7-Fold 학습


→ 스택킹 메타러너 학습

→ 최종 부도위험 예측값.


Fold별 예측 오차 · MAE · MSE · RMSE



〈Figure 8〉 Prediction errors of meta-learner models (MAE)



〈Figure 9〉 Prediction errors of meta-learner models (MSE)



〈Figure 10〉 Prediction errors of meta-learner models (RMSE)


7개 Fold 전반에 걸쳐 **RF가 가장 낮은 오차**, 다음은 **CNN, MLP** 순.

MLP의 오차가 폴드 전 구간에서 가장 큼 — 고차원 입력에서 학습 안정성이 떨어진다.

RF와 CNN은 모든 폴드에서 안정적으로 낮은 오차를 유지.

최종 오차 결과 · MAE / MSE / RMSE

〈Table 5〉 Results of prediction error				
Division	Model 1	Model 2	Model 3	Model 4
	Random Forest	MLP	CNN	Stacking Ensemble
MAE	0.094751	0.111714	0.134892	0.09079
MSE	0.022263	0.036053	0.037492	0.022175
RMSE	0.149209	0.189877	0.193628	0.148912




(Figure 11) Prediction comparison (Horizontal axis: prediction value, Vertical axis: target value)
대각선에 가까울수록 정확한 예측. 4개 모델 모두 같은 축으로 비교.

모델	MAE	MSE	RMSE
Stacking Ensemble	0.09079	0.022175	0.148912
Random Forest	0.094751	0.022263	0.149209
MLP	0.111714	0.036053	0.189877
CNN	0.134892	0.037492	0.193628

Stacking Ensemble이 MAE · MSE · RMSE 세 지표 모두에서 최저값을 기록. 특히 MLP · CNN과는 큰 격차를 보인다.

스태킹 모델과 Base 모델간 예측값 차이의 통계적 유의성 검정

정규성 검정 : Q-Q Plot 확인 — 세 Pair 모두 정규 분포선 바깥에 위치.정규분포를 따르지 않음을 시사 → 정규성 불충족



〈Table 6〉 Results of normality test (Shapiro-wilk normality test)

Division	Pair composition		Shapiro-wilk normality test		
	Set 1	Set 2	W	p-value	Results
Pair 1	Stacking Ensemble	Random Forest	0.98303	< 2.2e-16	Non-normal
Pair 2	Stacking Ensemble	MLP	0.89026	< 2.2e-16	Non-normal
Pair 3	Stacking Ensemble	CNN	0.95428	< 2.2e-16	Non-normal

〈Table 7〉 Results of wilcoxon rank sum test with continuity correction

Division	Pair composition		Wilcoxon rank sum test		
	Set 1	Set 2	W	p-value	Results
Pair 1	Stacking Ensemble	Random Forest	4920409	0.2596	Non-difference
Pair 2	Stacking Ensemble	MLP	4687668	1.479e-05	difference
Pair 3	Stacking Ensemble	CNN	4753811	0.0006236	difference

정규성 검정 : Shapiro-Wilk 검정 → 모든 Pair에서 정규성 불충족.

정규성 가정이 만족되지 않으므로, 비모수 검정방법인 윌콕슨 순위 합 검정 (Wilcoxon rank sum test)를 통해 두 그룹 간의 차이를 검증해야함

비모수: Wilcoxon Rank Sum Test → Random Forest 와 Stacking Ensemble (Pair1)은 통계적으로 유의미한 차이 보

이지 않음. Pair2,Pair3는 통계적으로 유의미한 차이 보임
Pair1 : Random Forest + Stacking Ensemble
Pair2 : MLP +Stacking Ensemble
Pair3 : CNN + Stacking Ensemble

결론 , 한계 , 후속 연구 방향

결론적으로, Merton 모형으로 시장의 판단을 포착하고, 스택킹 앙상블 기법으로 모델의 안정성을 높인 본 연구의 접근 방식은 기존 머신러닝 기반 부도 예측 모델의 한계를 극복하고, 실무적 활용도를 높일 수 있는 효과적인 대안임을 확인함

한계	내용	후속 연구 방향
출력 형식	부도확률이 0–1 연속값 → AAA ~ D 등급 체계와 불일치	예측값 → 신용등급 매핑 연구
서브모델 제한	RF · MLP · CNN 3가지만 사용	XGBoost · LightGBM · LSTM 등 추가

이 논문에 대한 우리의 의견

모델 해석 가능성 부재 (SHAP 등)

- 금융기관은 대출 거절·신용등급 조정 등의 의사결정 근거를 설명해야 하는데, 모델이 이유를 설명하지 못하면 실무 적용이 어려움

피처 선택, 유의성 검정의 부재

- 160개 변수 모두 사용할 경우, 노이즈 변수와 중복 정보까지 함께 학습하게 되어 과적합 가능성이 증가

전처리 과정 부재 (정규화, 이상치)

- 변수 간 스케일 차이와 극단값의 영향으로 인해 모델 학습이 왜곡 가능성 있음. 이는 예측 안정성과 일반화 성능 저하로 이어질 가능성 있음

THANK YOU · 질문 환영합니다

Q & A

머신러닝 기반 기업 부도위험 예측 — 스택킹 앙상블 모델