

A survey on deep learning for financial risk prediction

Kuashuai Peng & Guofeng Yan , Quantitative Finance and Economics, 2021

발표자 이영경 | 조윤탐

목차

01 논문 선정 이유

02 문제 제기

03 선행 연구

04 머신러닝 소개

05 금융 데이터의
특성별 분석

06 이해결 과제 및
향후 연구 방향

07 한계점

논문 선정 이유

금융 리스크 예측의 사회적 중요도 증가

다양한 딥러닝 모델과 금융 응용 사례

금융 데이터의 3가지 특성별 분류



| 문제 제기

Q1

금융 데이터가 이질성, 다중 소스, 불균형으로 발전하는 이유는 무엇인가

Q2

금융 리스크 예측을 위한 딥러닝 모델의 연구 현황은 어떤가

Q3

데이터 특성별로 더 적합한 딥러닝 모델은 무엇인가

Q4

금융 리스크 예측에서 딥러닝의 향후 연구 방향은 무엇인가

선행 연구

기존 서베이 논문의 한계 대부분의 리뷰 논문은 모델 중심 분류에 집중.

본 논문의 차별점 금융 데이터의 특성(이질성, 다중 소스, 불균형) 관점에서 딥러닝 적용을 최초로 체계적으로 정리한 논문

Qu et al. (2019)

Bankruptcy Prediction

파산 예측 – 실험 모델 기반 문헌 분류

문헌을 실험 모델에 따라 분류하고 범주별로 ML/DL 연구 성과를 검토 .
ML: MDA·로지스틱 회귀·양상블·SVM / DL: DBN·CNN

Sezer et al. (2020)

Time Series Forecasting

금융 시계열 예측 체계적 리뷰 (2005-2019)

딥러닝에 초점을 맞춰 8 가지 DL 모델의 원리·구조를 설명하고
주가 예측·지수 예측 등 구체적 사례 조사 . ML 응용도 간략 소개 .

Jiang (2021)

Stock Market Prediction

주식 시장 예측에서의 딥러닝 최근 동향

신경망 구조와 평가 지표를 분류했을 뿐만 아니라
다양한 데이터 소스도 별도로 범주화한 점이 일반 연구와의 차별점 .

Ozbayoglu et al. (2020) · Leo et al. (2019)


Broad DL in Finance

금융 DL 포괄적 관점 & 은행 리스크 관리


Ozbayoglu: 알고리즘 트레이딩·위험 평가·사기 탐지 등 다수 하위 분야의
현황과 미래 방향 제시 . Leo: 은행 리스크 관리 특화 , 숨겨진 미해결 문제
발굴 시도 .

딥러닝 모델


Multilayer perceptrons




Convolutional neural networks



Recurrent neural networks



Long Short-Term memory



금융 데이터의 세가지 특성

Heterogeneity (이질성)

Multi-source (다출처성)

Imbalance (불균형성)



Heterogeneity (이질성)

정형 데이터	비교기준	비정형 데이터
10 ~ 20 %	비율	80 ~ 90 %
수치, 테이블	형태	텍스트, 이미지, 영상
전통적 ML / 딥러닝	처리 기술	NLP, CNN 등 딥러닝
LSTM / RNN	주요 모델	BERT / CNN / DSCNNs
자금흐름 예측, 리스크 조기경보	활동 예시	파산 예측, 사기 탐지

5. 금융 데이터의 특성별 분석

Study	Main method	Data source	Period	Data content	Performance metric/ Model evaluation
Yang et al. (2019)	LSTM+ARIMA	Yu'e Bao	2013– 2014	Transaction records	Residual noise characteristic test
Li et al. (2021)	LSTM, Word2Vec	ST system in China's stock market	2012– 2018	Annual reports	Accuracy, precision, recall, f1-Score
Mai et al. (2019)	CNN, Word2Vec	Compustat North America, Center for Research in Prices	1994– 2014	Accounting and stock data, textual disclosure	AUC, accuracy, cumulative decile-ranking table
Ahmadi et al. (2018)	Dependency Sensitive CNN	Bundesanzeiger platform Amadeus database	2007– 2015 2004– 2014	Business management reports	Accuracy, precision, recall, f1-Score
Hosaka (2019)	CNN	Nikkei NEEDS Financial QUEST	2002– 2016	Financial statements	Accuracy and F1 scores
Zhao (2020)	CNN	Financial customers	-	Facial features	-
Cao et al. (2021)	-	ST system in China's stock market	-	Financial indicators	-

 : 정형 데이터 사용

 : 비정형 데이터 사용

Multi-source (다출처성)

산업 데이터

개인 데이터

개인 데이터

[소매 투자자] 리스크 예측

Kim et al. (2020)

DNN 으로 소매 투자자가 주식시장에서 리스크를 회피하고 수익을 낼 수 있는지 예측 / 딥러닝의 장점이 소매 금융 구조 데이터에도 일반화 가능성을 입증

[주식시장] 변동성 예측

Zhang (2020) / Liu et al. (2019)

RNN·LSTM 으로 CSI 300 지수 변동성 예측 / 원유시장 고변동성이 BRICS 주식시장 포트폴리오에 큰 영향

[VaR] 위험가치 추정

He et al. (2018)

Deep Belief Network 앙상블로 VaR 추정 / $VaR = \text{특정 기간} \cdot \text{확률 하에 포트폴리오 최대 손실 예상액} / \text{환율} \cdot \text{금리} \cdot \text{원자재 변동 리스크를 단일 숫자로 통합}$

[고객 분류] A/B-BOOK 구분

Cao et al. (2021)

딥러닝으로 시장 조성자에게 높은 리스크인 A-BOOK 고객과 낮은 리스크의 B-BOOK 고객을 구분하는 모델 개발

산업 데이터

[외식업] 파산 예측

Becerra-Vicario et al. (2020)

모델 : DRCNN vs 로지스틱 회귀

결과 : DRCNN 이 더 우수 / 수익성 · 부채 관련 변수가 핵심 예측 인자

[건설업] 파산 예측

Jang et al. (2020)

모델 : LSTM-RNN (1·2·3 년 전 예측)

결과 : 주택착공 (Housing Start) 변수가 가장 큰 영향 / 데이터 불균형 : SMOTE + Tomek Link 사용

[금융기관] 그린 크레딧 리스크

Wang et al. (2019)

모델 : BP 신경망 (딥러닝)

결과 : 친환경 기업 : 저금리 대출 / 고오염 기업 : 징벌적 고금리 / 딥러닝이 전통 방법 대비 높은 예측력

[생명보험] 시스템 리스크

Baranoff et al. (2019)

모델 : 파생상품 헤징 분석

결과 : 2008 금융위기 이전 파생상품 사용이 시스템 리스크에 미친 영향 분석

5. 금융 데이터의 특성별 분석

Study	Industry category	Method	Data source	Period	Data content	Performance metric/ Model evaluation
Kim et al. (2020)	Stock market	DNN	-	2003–2014	Trader classification variables	AUC, Sensitivity, Specificity, Precision, F-score
Zhang (2020)	Stock market	RNN, LSTM	-	2013–2017	CSI 300 index data	-
Yu and Li (2018)	Stock market	GARCH, LSTM	Shanghai Composite index	2011–2015	Stock prices, volume	NMSE, NMAE, LL and LINEX
Cao et al. (2021)	Stock market	SDAE	-	-	Transaction data	Recall, Precision, ROC curve
Becerra-Vicario et al. (2020)	Restaurant industry	Logistic regression, DRCNN	SABI database	2008–2017	Financial variables	RV coefficient, Hosmer-Lemeshow, ROC curve
Jang, Jeong, and Cho (2020)	Construction industry	LSTM, RNN	S&P database US Census Bureau	1980–2016	Accounting data Construction market data	Accuracy and F1-scores
Wang et al. (2019)	Industrial and commercial	Back Propagation	Commercial banks in China	2008–2016	Green credit balance	Accuracy
He et al. (2018)	-	DBN+ EMD	Quandl database	2007–2018	Exchange rates	Accuracy

: 개인 데이터 연구

: 산업 데이터 연구

Imbalance (불균형성)

데이터 수적 불균형

안전 데이터 (정상 기업)

위험 데이터 (부실 기업)

정상 운영 기업 수가 부실 기업 수보다 압도적으로 많아 학습 데이터가 불균형해지는 문제

해결방법

- 언더샘플링
- 오버샘플링
- SMOTE 등 혼합기법

정보 비대칭

업스트림 (기업)

다운스트림 (이해관계자)

기업은 1차 정보를 보유, 가공하여 공개하지만 이해관계자는 필터링된 정보만 접근 가능

해결방법

- 제무제표 사기탐지
- 제무적 부실 예측

데이터 수적 불균형

언더샘플링

안전 데이터에서 일부를 제거하여 두 클래스의 비율을 맞추는 방법

장점

- 학습속도가 빠름
- 계산 비용 절감

단점

- 유용한 데이터 손실 발생
- 학계에서 선호도 낮음

오버샘플링

위험 데이터에서 새로운 데이터를 추가하여 두 클래스의 비율을 맞추는 방법

장점

- 원본데이터 손실 없음
- 학계에서 선호

단점

- 과적합 위험 증가
- 계산 비용 및 시간 증가

SMOTE가 적용된 연구 사례

BSM-SAES — 파산 예측

Smiti & Soui (2020)

모델 : Borderline SMOTE + Stacked AutoEncoder (SAE) + Softmax

결과 : BSM-SAES 가 다른 머신러닝 모델보다 높은 정확도 · 정밀도 달성

딥러닝 vs 앙상블 비교

Aljawazneh et al. (2021)

모델 : LSTM, DBN, MLP vs RF, SVM, KNN, AdaBoost, XGBoost

결과 : 5 가지 오버샘플링 + 2 가지 혼합 + 1 가지 클러스터링 기법 적용하여 데이터 불일치 방지

kNN-SMOTE-LSTM — 신용카드 사기탐지

Chen et al. (2018)

모델 : kNN + SMOTE + LSTM 결합 모델

결과 : SMOTE 의 노이즈 문제를 kNN 으로 보완 / 새 모델의 효과성 · 실현 가능성 검증

CNN — 대용량 파산 예측

Wyrobek (2018)

모델 : CNN (폴란드 기업 데이터셋)

결과 : 대용량 데이터에서도 CNN 이 판별분석 · LR · SVM · 랜덤포레스트보다 우수한 성능

5. 금융 데이터의 특성별 분석

Study	Main method	Data source	Period	Data content	Performance metric/ Model evaluation
Smiti and Soui (2020)	BSM + SAE	UCI Machine Learning Repository	2002–2013	Financial ratios	AUC, time performance
Aljawazneh et al. (2021)	LSTM, DBN, MLP, RF, SVM, K-Nearest Neighbor, Adaptive Boosting	Spain: Infotel database	1998–2003	Independent variables	Accuracy, recall, specificity, precision, Type I error, Type II error
		Taiwan: Taiwan Economic Journal	1999–2009	representing the	
		Polish: Emerging Markets Info Service	2007–2013	company's solvency	
Chen et al. (2018)	kNN + SMOTE + LSTM	Woeldline and Université libre de Bruxelles	Sep. 2013	Credit card Transaction records	Accuracy, recall, precision, AUC, f-score, P-R curve
Jan (2021)	RNN, LSTM	Taiwan Economic Journal	2001–2019	Financial statements	Accuracy, precision, recall, specificity
Wyrobek (2018)	Logistic regression, SVM, RF, CNN,	Orbis database	2008–2017	Financial ratios	Accuracy, Type I/II error
Jan (2021)	DNN, CNN	Taiwan Economic Journal	2000–2019	Financial variables	Accuracy, precision, recall, specificity



: 데이터 수적 불균형 연구



: 정보 비대칭 연구



미해결 과제 및 향후 연구 방향

블랙 박스

현재 문제

딥러닝 모델은 블랙 박스 성격을 가져 내부 구조와 학습 파라미터 설명이 어려움 → 모델 최적화 복잡도 증가

향후 연구 방안

모델 해석 가능성 연구 지속

리스크 전파

현재 문제

현재 연구는 특정 개인, 기업의 리스크 예측에 집중, 금융 리스크가 어떻게 전파되고 차단되는지에 대한 연구 부족

향후 연구 방안

네트워크 이론과 딥러닝을 결합한 리스크 확산 모델링 연구 필요

불완전한 데이터셋

현재 문제

많은 연구가 비정형 데이터만 사용하고 정형 데이터를 무시 / 데이터 불균형을 인지하지 못하고 샘플링 X

향후 연구 방안

정형, 비정형 데이터를 균형있게 활용하고 불균형 여부에 따라 적절한 샘플링 기법 적용 필수

한계점

1	논문 선정 근거 부족
2	정량적 성능 비교 부재
3	최신 모델의 부재
4	인용 사례 및 데이터셋이 중국 데이터에 편중됨

